



ESTIMACIÓN TEMPRANA DEL RENDIMIENTO DE SOJA

Datos satelitales y climáticos aplicados al noroeste bonaerense

Agustín Musanti

Proyecto personal de Data Science aplicado

2026

Nota de versión.....	3
Resumen.....	3
1. Introducción.....	3
1.1. Motivación y contexto.....	3
1.2. Pregunta de investigación.....	4
1.3. Objetivos del proyecto.....	5
1.4. Alcance y limitaciones.....	6
2. Marco conceptual.....	6
2.1. El cultivo de soja en Argentina y la zona de estudio.....	6
2.2. Teledetección aplicada a la agricultura: el índice NDVI.....	8
2.3. Variables climáticas relevantes para el rendimiento de soja.....	10
2.4. Modelos de Machine Learning para predicción de rendimiento.....	12
3. Fuentes de datos.....	13
3.1. Rendimiento histórico: MAGyP.....	13
3.2. Datos climáticos: NASA POWER.....	15
3.3. Datos satelitales: MODIS vía Google Earth Engine.....	16
4. Metodología.....	16
4.1. Zona de estudio y partidos seleccionados.....	16
4.2. Construcción del dataset: ventanas temporales y feature engineering.....	17
4.3. Diseño de la validación: walk-forward temporal.....	19
4.4. Modelos evaluados.....	20
5. Resultados.....	21
5.1. Análisis exploratorio de los datos.....	21
5.2. Comparación de modelos por ventana temporal.....	23
5.3. Curva de anticipación: error vs. momento de predicción.....	24
5.4. Acierto direccional.....	25
5.5. Interpretabilidad: Importancia de variables.....	26
5.6. Aplicación a la campaña 2025/26.....	28
5.7. Simulación: predicción con datos de enero.....	30
5.8. Alternativas evaluadas.....	31
6. Discusión.....	33
6.1. Hallazgos principales.....	33
6.2. Valor para la toma de decisiones en una cooperativa.....	34
6.3. Limitaciones del modelo.....	35
6.4. Trabajo futuro.....	37
7. Conclusiones.....	38
8. Referencias.....	39

Nota de versión

Versión 3. Incorpora una sección de acierto direccional (5.4), el análisis de correlación entre variables y rendimiento (5.1) y los resultados de las alternativas evaluadas para mejorar el modelo: otros algoritmos y una señal satelital filtrada por tipo de cultivo (5.8). Se ajustaron en consecuencia la discusión y las conclusiones.

Versión 2. Corrige un error detectado en la descarga de datos satelitales del partido de Junín: el filtro utilizado recuperaba seis polígonos con ese nombre pertenecientes a otras regiones. Se corrigió la extracción (filtrando por país, provincia y partido), se reconstruyó el dataset y se recalcularon todos los modelos, tablas y figuras.

Resumen

Este trabajo evalúa si es posible estimar el rendimiento de soja a nivel de partido antes de la cosecha utilizando únicamente datos públicos y gratuitos. Se construyó un dataset de 125 observaciones (cinco partidos del noroeste bonaerense, campañas 2000/01 a 2024/25) que combina el rendimiento oficial del MAGyP, variables climáticas de NASA POWER y NDVI del sensor MODIS, organizadas en cinco ventanas temporales acumulativas alineadas al ciclo del cultivo. Bajo validación temporal walk-forward, un modelo Random Forest con datos hasta fines de enero, unos tres meses antes de la cosecha, obtuvo un error medio absoluto de 3,27 qq/ha y anticipó correctamente si la campaña venía por encima o por debajo del promedio histórico en el 71 % de los casos. Se evaluaron además otros algoritmos y una señal satelital filtrada por tipo de cultivo, sin que ninguno superara al modelo base. El resultado es una herramienta de alerta temprana: no busca un valor exacto, sino indicar con anticipación cómo viene la campaña.

1. Introducción

1.1. Motivación y contexto

El sector agrícola argentino es uno de los pilares de la economía nacional. La soja, en particular, representa el principal cultivo en términos de superficie sembrada y valor de exportación, concentrando gran parte de su producción en la región pampeana. En este contexto, las cooperativas agrícolas cumplen un rol clave como intermediarias entre el

productor y el mercado: acopian el grano, asesoran sobre precios y coberturas, y financian insumos para la campaña siguiente.

Sin embargo, a pesar del volumen que manejan y de la relevancia de sus decisiones operativas, muchas de estas organizaciones carecen de herramientas formales para anticipar el resultado de una campaña antes de que llegue la cosecha. Las estimaciones se basan en la experiencia acumulada de los técnicos de campo, en la observación del estado del cultivo y en el seguimiento informal de las precipitaciones. Esta información, aunque valiosa, no está sistematizada ni cuantificada, lo que limita la capacidad de planificación.

El presente proyecto nació de la observación directa de esta realidad. El autor cuenta con vínculo familiar y profesional con el agro del noroeste de la provincia de Buenos Aires, lo que permitió identificar de primera mano la ausencia de sistemas de estimación temprana en una cooperativa de la zona. A partir de esa motivación, se planteó investigar si es posible construir un modelo de predicción de rendimiento de soja utilizando únicamente datos públicos y gratuitos, y si ese modelo puede generar estimaciones útiles con suficiente anticipación como para influir en decisiones reales.

1.2. Pregunta de investigación

La pregunta central que guía este proyecto es: ¿es posible estimar el rendimiento de soja a nivel de partido, antes de la cosecha, utilizando únicamente fuentes de datos públicas y gratuitas?

Esta pregunta general se descompone en dos dimensiones específicas. La primera tiene que ver con la precisión: ¿qué tan confiable puede ser un modelo basado exclusivamente en datos satelitales y climáticos, sin información de campo como densidad de siembra, genética utilizada o aplicaciones de fertilizantes? La segunda, y quizás más relevante desde el punto de vista práctico, tiene que ver con la anticipación: ¿a partir de qué momento del ciclo del cultivo la predicción alcanza un nivel de error aceptable para la toma de decisiones?

Un modelo que predice correctamente pero recién a fines de marzo, cuando la cosecha ya comenzó, tiene escaso valor operativo. En cambio, un modelo que logre una estimación razonable en enero, cuando el cultivo aún transita las etapas reproductivas, podría representar una herramienta concreta para cooperativas y otros actores del

sector.

Cabe precisar el tipo de respuesta que se busca. El objetivo no es predecir el rendimiento exacto de cada partido, que depende de factores que no pueden observarse con datos públicos, sino disponer en enero de una estimación de cómo viene la campaña: si las condiciones acumuladas hasta ese momento (lluvias, temperaturas, vigor del cultivo) apuntan a un rendimiento por encima o por debajo de lo habitual, y en qué magnitud aproximada. El modelo se plantea como una herramienta de apoyo a la decisión, no como un sustituto de la información de cosecha.

1.3. Objetivos del proyecto

El objetivo general de este proyecto es desarrollar un sistema de predicción de rendimiento de soja para la zona de influencia de una cooperativa del noroeste bonaerense, basado en datos satelitales, climáticos e históricos de producción, todos de acceso público y gratuito.

A partir de este objetivo general, se definen los siguientes objetivos específicos:

1. Construir un dataset integrado que combine información de rendimiento histórico por partido, índices de vegetación derivados de imágenes satelitales y variables climáticas diarias, alineados al ciclo fenológico del cultivo de soja.
2. Evaluar distintos modelos de aprendizaje automático mediante un esquema de validación temporal que simula condiciones reales de predicción, evitando la filtración de información futura.
3. Determinar a partir de qué momento del ciclo del cultivo el modelo alcanza un nivel de error útil para la toma de decisiones, construyendo una curva de anticipación que relacione el error de predicción con el avance de la campaña.
4. Analizar la importancia relativa de las variables predictoras para identificar qué factores aportan mayor capacidad predictiva sobre el rendimiento en la zona de estudio.
5. Aplicar el modelo entrenado a una campaña no vista durante el entrenamiento, a modo de validación final en condiciones reales.
6. Evaluar si alternativas metodológicas, como otros algoritmos de aprendizaje automático o una señal satelital restringida a los píxeles de cultivo, permiten mejorar el desempeño del modelo base.

1.4. Alcance y limitaciones

El proyecto se circunscribe a la predicción de rendimiento de soja en cinco partidos del noroeste de la provincia de Buenos Aires: General Arenales, Leandro N. Alem, Junín, Lincoln y General Pinto. Estos partidos conforman la zona de influencia de una cooperativa agrícola de la región y comparten características agroecológicas generales, lo que permite tratarlos como una unidad de análisis coherente.

El período analizado comprende las campañas 2000/01 a 2024/25, totalizando 25 campañas. La elección de este rango responde a la disponibilidad de datos satelitales del sensor MODIS, operativo desde el año 2000, y a la existencia de registros oficiales de rendimiento por partido publicados por el Ministerio de Agricultura, Ganadería y Pesca (MAGyP).

La unidad de análisis es el partido y no el lote individual. El modelo estima un rendimiento promedio para toda la superficie sembrada dentro de un partido, por lo que un productor individual puede obtener un resultado considerablemente distinto de ese promedio. El dataset resultante cuenta con 125 observaciones (5 partidos $\times$ 25 campañas), lo que condiciona el tipo de modelos que pueden entrenarse sin incurrir en sobreajuste.

Las limitaciones metodológicas del enfoque se desarrollan en detalle en la sección 6.3, una vez presentados los resultados.

2. Marco conceptual

2.1. El cultivo de soja en Argentina y la zona de estudio

La soja (*Glycine max*) es el cultivo de mayor relevancia económica en Argentina. Según datos del Ministerio de Agricultura, la superficie sembrada supera regularmente las 16 millones de hectáreas a nivel nacional, y el complejo sojero constituye la principal fuente de divisas por exportación del país, incluyendo el grano, la harina y el aceite de soja.

La zona de estudio se ubica en el noroeste de la provincia de Buenos Aires, en el límite entre la zona núcleo y la denominada Pampa Arenosa. Los cinco partidos seleccionados no son homogéneos en cuanto a suelos: General Arenales, Leandro N. Alem y buena parte de Junín se corresponden con Argiudoles de texturas franco a franco limosas, de alta capacidad de retención hídrica y elevada aptitud agrícola, mientras que Lincoln y

General Pinto presentan mayor proporción de Hapludoles con texturas más gruesas, franco arenosas, con menor capacidad de almacenamiento de agua en el perfil. Esta diferencia edáfica configura un gradiente este-oeste que, como se verá más adelante, se refleja en los rendimientos históricos. El régimen de lluvias promedia entre 800 y 1000 mm anuales en toda la zona.

La soja de primera es el cultivo dominante, sembrada en octubre-noviembre como único cultivo del lote en la campaña. También es frecuente el esquema de doble cultivo trigo/soja de segunda, donde la soja se siembra en diciembre tras la cosecha del cereal de invierno. En los lotes donde se realiza rotación sin doble cultivo, la soja de primera suele alternarse con maíz.

El ciclo del cultivo de soja en esta zona se extiende aproximadamente de octubre a abril, y puede dividirse en dos grandes fases: la fase vegetativa y la fase reproductiva. La fase vegetativa comprende desde la siembra (octubre-noviembre) hasta el inicio de la floración, y durante ella la planta desarrolla su estructura foliar y radicular. La fase reproductiva, que es la determinante del rendimiento final, incluye las siguientes etapas clave:

- **R1 (inicio de floración):** aparece la primera flor en cualquier nudo del tallo principal. Ocurre típicamente entre fines de diciembre y principios de enero.
- **R2 (floración plena):** hay flores abiertas en uno de los dos nudos superiores del tallo.
- **R3 (inicio de formación de vainas):** las vainas comienzan a desarrollarse. El cultivo tiene alta demanda de agua y nutrientes.
- **R4 (vainas completamente desarrolladas):** las vainas alcanzan su longitud máxima en los nudos superiores.
- **R5 (inicio de llenado de grano):** los granos comienzan a crecer dentro de las vainas. Es el período más crítico: el estrés hídrico o térmico en esta etapa tiene impacto directo sobre el rendimiento final.
- **R6 (llenado completo):** las vainas contienen granos verdes que ocupan toda la cavidad.
- **R7 (madurez fisiológica):** el grano alcanza su peso seco máximo. A partir de aquí el rendimiento ya está definido.
- **R8 (madurez comercial):** el 95% de las vainas alcanzaron su color de madurez. El cultivo está listo para cosecha.

El período crítico de determinación del rendimiento en soja se ubica entre R3 y R6, con

máxima sensibilidad en torno a R4,5-R5,5. Si bien R1 y R2 marcan el inicio de la fase reproductiva, la soja posee una elevada capacidad de compensación durante la floración: el aborto de flores tempranas suele compensarse con la fijación de vainas en nudos posteriores. Es durante la formación de vainas y el llenado de granos cuando el cultivo define efectivamente el número de granos por unidad de superficie, que es el principal componente del rendimiento. En la zona de estudio, este período transcurre aproximadamente entre mediados de enero y mediados de febrero.

Una deficiencia hídrica prolongada o temperaturas máximas superiores a 35 °C durante esta ventana pueden provocar aborto de vainas, reducción del número de granos por planta y menor peso individual del grano. Inversamente, condiciones favorables de disponibilidad hídrica y temperatura en este período suelen asociarse a rendimientos por encima del promedio histórico.

Esta asociación entre las condiciones ambientales durante las etapas reproductivas y el rendimiento final es la que fundamenta el enfoque predictivo de este proyecto: si es posible medir esas condiciones a medida que avanza la campaña mediante datos climáticos y satelitales, entonces es posible estimar el rendimiento antes de que la cosecha ocurra.

2.2. Teledetección aplicada a la agricultura: el índice NDVI

La teledetección o percepción remota consiste en la obtención de información sobre la superficie terrestre a partir de sensores montados en satélites. En el contexto agrícola, esta tecnología permite monitorear el estado de los cultivos a gran escala, con frecuencia regular y sin necesidad de recorrer cada lote en persona.

El principal indicador utilizado en teledetección agrícola es el NDVI (Normalized Difference Vegetation Index, o Índice de Vegetación de Diferencia Normalizada). Este índice se calcula a partir de la reflectancia que captura el sensor satelital en dos bandas del espectro electromagnético: la banda roja (RED) y la banda infrarroja cercana (NIR). La fórmula es:

$$\text{NDVI} = (\text{NIR} - \text{RED}) / (\text{NIR} + \text{RED})$$

El fundamento físico es simple: las hojas de las plantas absorben la luz roja para realizar la fotosíntesis y reflejan fuertemente la luz infrarroja cercana. Un cultivo sano y vigoroso absorbe mucha luz roja y refleja mucha infrarroja, lo que resulta en un NDVI alto. Un

cultivo estresado, seco o con baja cobertura foliar refleja más luz roja y menos infrarroja, produciendo un NDVI bajo.

Los valores de NDVI varían entre -1 y 1 . En la práctica agrícola, los rangos relevantes son:

- Valores menores a $0,2$: suelo desnudo, agua o superficies no vegetadas.
- Valores entre $0,2$ y $0,4$: vegetación rala o cultivo en etapas iniciales.
- Valores entre $0,4$ y $0,6$: vegetación moderada, cultivo en crecimiento.
- Valores entre $0,6$ y $0,8$: vegetación densa y sana, cultivo en pleno desarrollo.
- Valores superiores a $0,8$: cobertura vegetal muy densa, típica del pico de desarrollo del cultivo.

En la zona de estudio, la señal de NDVI a nivel de partido sigue un patrón estacional bien definido, con valores bajos durante el invierno, un ascenso a partir de octubre-noviembre a medida que los cultivos de verano cubren el suelo, un máximo entre enero y febrero, y un descenso progresivo hacia marzo-mayo con la madurez y la cosecha. Este comportamiento se observa en la Figura 1.




Figura 1. Ciclo anual promedio del NDVI por partido en la zona de estudio (período 2000-2025). La zona sombreada indica la etapa reproductiva de la soja de primera (diciembre-marzo), dentro de la cual se ubica el período crítico, entre mediados de enero y mediados de febrero. Fuente: elaboración propia a partir de datos MODIS.

Es importante precisar el alcance de esta señal. El NDVI utilizado corresponde al promedio de todos los píxeles contenidos dentro del polígono administrativo de cada partido, lo que incluye no solo lotes de soja sino también maíz, trigo, pasturas, montes, caminos, cuerpos de agua y áreas urbanas. Por lo tanto, la serie debe interpretarse como un indicador agregado del estado de la cobertura vegetal del partido, que funciona como proxy del desempeño general de los cultivos de verano, y no como una medición directa del cultivo de soja. Las diferencias de nivel entre partidos que se observan en la Figura 1 responden, en parte, a la distinta composición de usos del suelo dentro de cada polígono. Las implicancias de esta limitación se retoman en la sección 6.3.

La asociación entre el NDVI durante las etapas reproductivas y el rendimiento final se encuentra documentada en la literatura de teledetección agrícola. Un NDVI máximo más alto durante el período R3-R6 se asocia con mayor biomasa acumulada y, en consecuencia, con mayor producción de grano. De manera inversa, campañas donde el NDVI no alcanza valores elevados o donde se observa una caída abrupta durante el período crítico suelen corresponder a eventos de sequía o estrés térmico que reducen el rendimiento.

Para este proyecto se utilizaron datos del sensor MODIS (Moderate Resolution Imaging Spectroradiometer) a bordo del satélite Terra de la NASA, específicamente el producto MOD13Q1. Este producto provee compuestos de NDVI cada 16 días con una resolución espacial de 250 metros, y está disponible desde febrero del año 2000 de forma gratuita a través de la plataforma Google Earth Engine. La resolución de 250 metros es adecuada para el nivel de análisis por partido, ya que cada partido contiene miles de píxeles que se promedian para obtener un valor representativo de la cobertura vegetal del área.

2.3. Variables climáticas relevantes para el rendimiento de soja

El rendimiento de soja está determinado en gran medida por las condiciones climáticas que experimenta el cultivo durante su ciclo, particularmente durante las etapas reproductivas. Las principales variables climáticas que influyen sobre la producción de grano son las siguientes.

Precipitación. El agua es el factor más limitante para la producción de soja en condiciones de secano, que es el sistema predominante en la zona de estudio (sin riego). La soja requiere entre 450 y 800 mm durante su ciclo completo, con demanda máxima durante el período de floración y llenado de grano (R1-R6). Una deficiencia hídrica

durante este período puede provocar aborto de flores, reducción del número de vainas y menor peso de grano. En la zona de estudio, las precipitaciones promedian entre 800 y 1000 mm anuales, pero su distribución a lo largo de la campaña varía significativamente entre años, lo que explica buena parte de la variabilidad interanual del rendimiento.

Temperatura. La soja es sensible tanto a temperaturas extremas como a la amplitud térmica. El rango óptimo para el desarrollo se ubica entre 20°C y 30°C. Temperaturas máximas superiores a 35°C durante la floración y el llenado de grano generan estrés térmico, que afecta la viabilidad del polen, reduce la tasa de fecundación y acorta el período de llenado. Este efecto se conoce como "golpe de calor" y es una de las principales causas de pérdidas de rendimiento en campañas donde las lluvias fueron adecuadas pero las temperaturas fueron excesivas.

Radiación solar. La radiación fotosintéticamente activa es la fuente de energía para la producción de biomasa. Mayor radiación durante las etapas vegetativas y reproductivas se asocia, en condiciones de buena disponibilidad hídrica, con mayor acumulación de materia seca y rendimiento potencial. Sin embargo, en situaciones de estrés hídrico, una radiación elevada puede agravar el déficit al incrementar la evapotranspiración.

Humedad relativa. Niveles altos de humedad relativa combinados con temperatura elevada pueden favorecer la aparición de enfermedades fúngicas foliares y reducir la radiación incidente (días nublados). Por otro lado, una humedad relativa muy baja intensifica la demanda evaporativa de la atmósfera y puede acelerar el consumo de agua disponible en el suelo.

Para este proyecto se utilizaron datos climáticos diarios provistos por la plataforma NASA POWER (Prediction Of Worldwide Energy Resources), que ofrece información a nivel de punto geográfico desde 1981, con una resolución espacial aproximada de 55 km. Las variables descargadas para cada partido fueron: temperatura media, máxima y mínima a 2 metros de altura, precipitación corregida, radiación solar incidente, humedad relativa y temperatura de punto de rocío.




Figura 2. Ciclo anual promedio de temperatura media y precipitación en la zona de estudio (1999-2025). La zona sombreada indica la etapa reproductiva de la soja. Fuente: elaboración propia a partir de datos NASA POWER.

2.4. Modelos de Machine Learning para predicción de rendimiento

La predicción de rendimiento de cultivos a partir de datos de teledetección y variables climáticas es un campo de investigación activo, con abundante literatura que documenta el uso de técnicas de aprendizaje automático para este fin. El enfoque general consiste en construir un conjunto de variables predictoras (features) derivadas de datos satelitales y climáticos, y entrenar un modelo que aprenda la relación entre esas variables y el rendimiento observado en campañas históricas.

En este proyecto se evaluaron principalmente tres tipos de modelos con distintos niveles de complejidad:

Regresión lineal. Es el modelo más simple y se utiliza como línea de base (baseline) contra la cual comparar los demás. Asume una relación lineal entre las variables predictoras y el rendimiento. Su principal ventaja es la interpretabilidad directa de los coeficientes, pero tiene limitaciones cuando las relaciones entre variables son no lineales o cuando existen interacciones complejas entre predictores. Además, tiende a degradarse cuando el número de variables es grande en relación al número de observaciones, un

fenómeno conocido como sobreajuste.

Random Forest. Es un método de ensamble basado en la construcción de múltiples árboles de decisión, cada uno entrenado con una muestra aleatoria de los datos y un subconjunto aleatorio de las variables. La predicción final se obtiene promediando las predicciones de todos los árboles. Esta aleatorización le otorga robustez frente al sobreajuste y capacidad para capturar relaciones no lineales sin necesidad de especificarlas previamente. Es uno de los modelos más utilizados en la literatura de predicción de rendimiento por su buen balance entre precisión, estabilidad y facilidad de implementación.

Gradient Boosting. A diferencia de Random Forest, que construye árboles independientes en paralelo, Gradient Boosting construye árboles de forma secuencial, donde cada nuevo árbol intenta corregir los errores del anterior. Este enfoque iterativo puede alcanzar mayor precisión en algunos casos, pero es más sensible a la configuración de hiperparámetros y al sobreajuste cuando el dataset es pequeño.

Un aspecto crítico en cualquier aplicación de estos modelos a datos temporales es el esquema de validación. En problemas donde las observaciones tienen un orden cronológico, no es válido utilizar una partición aleatoria de los datos en entrenamiento y test, ya que eso permitiría al modelo "ver" información del futuro durante el entrenamiento. En su lugar, se emplea un esquema de validación temporal conocido como walk-forward, donde el modelo se entrena únicamente con campañas anteriores a la que se desea predecir. Este enfoque será descrito en detalle en la sección de Metodología.

3. Fuentes de datos

3.1. Rendimiento histórico: MAGyP

La variable objetivo del modelo es el rendimiento de soja por partido, expresado en quintales por hectárea (qq/ha). Los datos fueron obtenidos del portal de datos abiertos del Ministerio de Agricultura, Ganadería y Pesca de la Nación (MAGyP), que publica la serie histórica de estimaciones agrícolas por cultivo, provincia y departamento/partido.

El dataset utilizado corresponde a la serie "Soja: siembra, cosecha, producción, rendimiento" y contiene, para cada partido y campaña, la superficie sembrada (en

hectáreas), la superficie cosechada (en hectáreas), la producción total (en toneladas) y el rendimiento promedio (en kg/ha). Para este proyecto, el rendimiento fue convertido a qq/ha dividiendo por 100, ya que es la unidad de referencia habitual en el sector agrícola argentino.

Se filtraron los datos correspondientes a los cinco partidos de la zona de estudio para el período 2000-2024, resultando un total de 125 observaciones (5 partidos × 25 campañas). La Figura 3 muestra la evolución del rendimiento por partido a lo largo de este período.




Figura 3. Evolución del rendimiento de soja por partido en la zona de estudio (campañas 2000-2024). La línea punteada negra representa el promedio de los cinco partidos. Se señalan las campañas afectadas por sequías severas. Fuente: elaboración propia a partir de datos MAGyP.

Los cinco partidos presentan una dinámica interanual similar: cuando las condiciones son favorables, los rendimientos suben en todos; cuando hay sequía, caen en todos. Esta correlación es esperable dada la proximidad geográfica y las condiciones climáticas compartidas. Sin embargo, se distinguen diferencias sistemáticas de nivel: General Arenales y Junín registran rendimientos superiores al promedio zonal, mientras que Lincoln y General Pinto se ubican generalmente por debajo, con una brecha que en campañas normales ronda los 4 qq/ha.

Este gradiente es coherente con la transición edáfica descrita en la sección 2.1: los partidos del este de la zona de estudio, sobre suelos Argiudoles de textura más fina, cuentan con mayor capacidad de retención hídrica que los del oeste, ubicados sobre suelos más arenosos de la Pampa Arenosa. A ello se suman posibles diferencias en la

proporción de superficie destinada a soja de primera respecto de soja de segunda y en las prácticas de manejo predominantes en cada partido.

También se observa una tendencia positiva de largo plazo en el rendimiento, atribuible a la mejora genética de los cultivares y a la evolución de las prácticas de manejo a lo largo del período analizado. Esta tendencia tiene implicancias para el modelado que se discuten en la sección 6.3.

Las campañas 2008/09 y 2022/23 se destacan como las de peor desempeño en toda la serie, con caídas del rendimiento promedio zonal a valores cercanos a 15 qq/ha, aproximadamente la mitad del promedio histórico. Ambas campañas estuvieron marcadas por eventos de sequía severa durante el período reproductivo del cultivo.

3.2. Datos climáticos: NASA POWER

Los datos climáticos diarios fueron obtenidos a través de la API de NASA POWER (Prediction Of Worldwide Energy Resources), un servicio gratuito que provee información meteorológica a nivel global a partir de modelos de reanálisis y observaciones satelitales. Se utilizó la comunidad "AG" (Agroclimatología), diseñada específicamente para aplicaciones agrícolas.

Para cada uno de los cinco partidos se descargaron datos diarios desde septiembre de 1999 hasta abril de 2025, utilizando como punto de referencia el centroide geográfico de cada partido. La resolución espacial del producto es de 0,5° de latitud por 0,625° de longitud (~55 km) para las variables meteorológicas, y de 1° × 1° para la radiación. A esa escala, los datos describen el clima regional de cada partido más que sus condiciones locales; las implicancias se discuten en la sección 4.1.

Las variables descargadas fueron las siguientes:

- **T2M:** temperatura media del aire a 2 metros de altura (°C).
- **T2M_MAX:** temperatura máxima diaria (°C).
- **T2M_MIN:** temperatura mínima diaria (°C).
- **PRECTOTCORR:** precipitación diaria corregida (mm/día).
- **ALLSKY_SFC_SW_DWN:** radiación solar incidente en superficie (MJ/m²/día).
- **RH2M:** humedad relativa a 2 metros de altura (%).
- **T2MDEW:** temperatura de punto de rocío (°C).

El dataset resultante contiene 46.870 registros (9.374 días $\times$ 5 partidos), sin valores faltantes tras reemplazar el código de dato ausente de NASA POWER (–999) por nulos, que resultaron ser inexistentes para el período y las variables seleccionadas.

3.3. Datos satelitales: MODIS vía Google Earth Engine

Los datos de NDVI fueron extraídos del producto MOD13Q1 del sensor MODIS (Moderate Resolution Imaging Spectroradiometer), a bordo del satélite Terra de la NASA. Este producto provee compuestos de NDVI cada 16 días con una resolución espacial de 250 metros, generados mediante la técnica de composición de máximo valor (MVC), que selecciona para cada píxel el valor más alto de NDVI dentro de la ventana de 16 días, minimizando así el efecto de nubes y condiciones atmosféricas adversas.

Los datos fueron accedidos a través de la plataforma Google Earth Engine, que permite el procesamiento de grandes volúmenes de información geoespacial de forma remota sin necesidad de descargar las imágenes completas. Para definir el área de extracción de cada partido se utilizaron los polígonos administrativos de la base de datos FAO GAUL (Global Administrative Unit Layers) nivel 2, disponible dentro de la plataforma.

Para cada imagen MODIS en el período 2000-2025, se calculó el NDVI promedio de todos los píxeles contenidos dentro de cada polígono de partido. Los valores crudos del producto MOD13Q1 se almacenan con un factor de escala de 0,0001, por lo que fueron multiplicados por dicho factor para obtener valores de NDVI en su rango real (–1 a 1).

El dataset resultante contiene 2.900 registros (580 observaciones por partido $\times$ 5 partidos), correspondientes a las composiciones de 16 días disponibles durante 25 años. No se detectaron valores faltantes en la serie.

4. Metodología

4.1. Zona de estudio y partidos seleccionados

La zona de estudio comprende cinco partidos del noroeste de la provincia de Buenos Aires: General Arenales, Leandro N. Alem, Junín, Lincoln y General Pinto. Estos partidos fueron seleccionados por conformar la zona de influencia operativa de una cooperativa agrícola de la región, lo que otorga al proyecto un anclaje concreto en un contexto de

toma de decisiones real.

Los cinco partidos se ubican en un radio de aproximadamente 80 km entre sí y comparten características agroecológicas similares: suelos de aptitud agrícola, clima templado pampeano y predominancia de cultivos extensivos de soja, maíz y trigo. Esta homogeneidad relativa permite tratarlos como una unidad de análisis coherente, donde las diferencias de rendimiento entre partidos responden más a variaciones locales de suelo y manejo que a diferencias climáticas sustanciales.

Los centroides geográficos utilizados para la extracción de datos climáticos de cada partido son los siguientes:

Partido	Latitud	Longitud
General Arenales	-34,31	-61,10
Leandro N. Alem	-34,52	-61,38
Junín	-34,59	-60,95
Lincoln	-34,87	-61,53
General Pinto	-34,76	-61,89

Para la extracción de NDVI, en lugar de utilizar puntos, se emplearon los polígonos administrativos completos de cada partido provenientes de la base FAO GAUL nivel 2, calculando el promedio de todos los píxeles contenidos en cada polígono.

Cabe señalar una limitación derivada de la resolución de los datos climáticos. NASA POWER provee sus parámetros meteorológicos sobre una grilla de 0,5° de latitud por 0,625° de longitud, y los parámetros de radiación sobre una grilla de 1° × 1°. Dado que los cinco partidos se ubican dentro de un radio aproximado de 80 km, varios centroides caen en celdas iguales o contiguas de esa grilla. En consecuencia, la información climática entre partidos es necesariamente similar por construcción, y la capacidad del modelo para discriminar entre ellos a partir de variables climáticas es limitada. Las diferencias de rendimiento entre partidos que el modelo logra capturar provienen, en mayor medida, de la señal de NDVI y de las diferencias estructurales de nivel presentes en la serie histórica.

4.2. Construcción del dataset: ventanas temporales y feature engineering

El dataset de modelado se construyó integrando las tres fuentes de datos descritas en la sección anterior. Cada observación corresponde a un par (partido, campaña), y la variable objetivo es el rendimiento de soja en qq/ha para esa combinación. El dataset final contiene 125 observaciones (5 partidos × 25 campañas).

El aspecto más relevante de la construcción del dataset es la definición de las ventanas temporales. Dado que el objetivo del proyecto no es solo predecir el rendimiento, sino determinar a partir de qué momento del ciclo la predicción es confiable, se definieron cinco ventanas acumulativas alineadas al ciclo fenológico de la soja:

Ventana	Período cubierto	Información disponible
oct_nov	Octubre - Noviembre	Solo datos de siembra y emergencia
oct_dic	Octubre - Diciembre	Siembra + primer mes de crecimiento vegetativo
oct_ene	Octubre - Enero	Hasta formación de vainas (R3-R4), inicio del período crítico
oct_feb	Octubre - Febrero	Hasta llenado de grano (R5-R6), período crítico completo
oct_mar	Octubre - Marzo	Hasta pre-cosecha

Cada ventana es acumulativa: la ventana oct_ene incluye toda la información de oct_nov y oct_dic, más los datos de enero. Esto simula el escenario real de uso del modelo: si estamos en enero, solo disponemos de datos hasta ese momento.

Para cada ventana y cada par (partido, campaña), se calcularon las siguientes variables predictoras:

Variables climáticas (derivadas de NASA POWER):

- Precipitación acumulada en la ventana (mm).
- Temperatura media, máxima media y mínima media (°C).
- Radiación solar media (MJ/m²/día).
- Humedad relativa media (%).
- Cantidad de días con temperatura máxima superior a 35°C (indicador de estrés térmico).

- Cantidad de días sin lluvia (precipitación menor a 1 mm).

Variables de NDVI (derivadas de MODIS):

- NDVI promedio en la ventana.
- NDVI máximo en la ventana.
- NDVI mínimo en la ventana.
- Desvío estándar del NDVI en la ventana (indicador de variabilidad).
- Pendiente de la serie de NDVI en la ventana (indicador de tendencia de crecimiento o deterioro del cultivo).

En total, el dataset de modelado contiene 65 variables predictoras distribuidas a lo largo de las cinco ventanas temporales. La cantidad de features disponibles crece con cada ventana: la ventana oct_nov cuenta con 13 features, mientras que la ventana oct_mar dispone de las 65.

4.3. Diseño de la validación: walk-forward temporal

En problemas de predicción con datos temporales, la validación del modelo requiere un tratamiento particular. A diferencia de una partición aleatoria de los datos en entrenamiento y test, que es válida cuando las observaciones son independientes entre sí, en un contexto temporal es imprescindible respetar la dirección del tiempo: el modelo solo puede entrenarse con campañas pasadas y evaluarse sobre campañas futuras. Utilizar una partición aleatoria permitiría que el modelo acceda a información del futuro durante el entrenamiento, inflando artificialmente las métricas de desempeño.

Para este proyecto se implementó un esquema de validación conocido como walk-forward o ventana expandible. El procedimiento es el siguiente:

1. Se entrena el modelo con todas las campañas desde 2000 hasta 2015 y se predice la campaña 2016.
2. Se amplía el conjunto de entrenamiento incorporando la campaña 2016, y se predice la campaña 2017.
3. Se repite este proceso hasta predecir la campaña 2024.

Este esquema genera 9 campañas de test (2016 a 2024), con 5 predicciones por campaña (una por partido), totalizando 45 predicciones fuera de muestra. Cada predicción fue generada sin que el modelo haya visto en ningún momento el rendimiento real de esa

campaña ni de campañas posteriores.

La elección de 2016 como primera campaña de test responde a la necesidad de garantizar un conjunto de entrenamiento inicial suficiente: 16 campañas (2000-2015) con 5 partidos proporcionan 80 observaciones para el primer entrenamiento, lo cual es adecuado para los modelos evaluados.

Las métricas de evaluación utilizadas fueron:

- **MAE (Mean Absolute Error):** promedio del valor absoluto de los errores. Indica el error típico de predicción en las mismas unidades que la variable objetivo (qq/ha). Es la métrica más interpretable para el usuario final.
- **RMSE (Root Mean Squared Error):** raíz cuadrada del promedio de los errores al cuadrado. Penaliza más los errores grandes que el MAE.
- **R² (coeficiente de determinación):** proporción de la variabilidad del rendimiento que el modelo logra explicar. Un valor de 1 indica predicción perfecta; un valor de 0 indica que el modelo no supera a predecir siempre el promedio.
- **Acierto direccional:** proporción de predicciones en las que el modelo anticipa correctamente si el rendimiento se ubicará por encima o por debajo del promedio histórico del partido, calculado con las campañas anteriores. Es la métrica más alineada con el uso previsto del modelo como herramienta de alerta temprana.

4.4. Modelos evaluados

Se evaluaron tres modelos de distinta complejidad, con el objetivo de comparar el trade-off entre simplicidad e interpretabilidad por un lado, y capacidad predictiva por el otro.

Regresión Lineal fue utilizada como baseline. No se aplicó regularización. Todas las variables fueron estandarizadas previamente (media 0, desvío 1) para homogeneizar las escalas.

Random Forest fue configurado con 100 árboles, profundidad máxima de 5 niveles y semilla aleatoria fija para reproducibilidad. La limitación de profundidad busca controlar el sobreajuste en un dataset de tamaño moderado.

Gradient Boosting fue configurado con 100 estimadores, profundidad máxima de 3

niveles, tasa de aprendizaje de 0,1 y semilla aleatoria fija.

Los tres modelos fueron evaluados bajo el mismo esquema walk-forward descrito anteriormente, y para cada una de las cinco ventanas temporales, generando un total de 15 combinaciones modelo-ventana. En todos los casos, las variables predictoras fueron estandarizadas utilizando únicamente los datos de entrenamiento de cada iteración, para evitar filtración de información.

Una vez establecido el modelo base, se exploraron otros algoritmos (modelos lineales regularizados, XGBoost, SVR y KNN) y variantes de la señal satelital, con el objetivo de evaluar si era posible mejorar su desempeño. Esos resultados se presentan en la sección 5.8.

5. Resultados

5.1. Análisis exploratorio de los datos

Antes de entrenar los modelos, se realizó un análisis exploratorio para verificar la coherencia de los datos y comprender las relaciones entre las variables predictoras y el rendimiento.

La Figura 4 muestra la relación entre tres variables clave y el rendimiento de soja para la ventana oct_feb (octubre a febrero), que cubre el período crítico completo del cultivo.




Figura 4. Relación entre variables predictoras clave (ventana octubre-febrero) y rendimiento de soja por partido. Izquierda: precipitación acumulada. Centro: NDVI máximo. Derecha: días con temperatura máxima superior a 35°C. Fuente: elaboración propia.

Se observan patrones consistentes en las tres variables. La precipitación acumulada muestra una asociación positiva con el rendimiento, con un comportamiento de tipo umbral: la mayoría de las campañas con menos de 400 mm acumulados entre octubre y febrero registraron rendimientos inferiores a 20 qq/ha, correspondientes a campañas de sequía severa, aunque se observan casos puntuales por debajo de ese umbral con rendimientos cercanos al promedio. Por encima de los 500 mm, la relación se atenúa marcadamente y la dispersión aumenta, lo que sugiere que una vez cubierto el requerimiento hídrico básico otros factores pasan a ser limitantes.

El NDVI máximo presenta una asociación positiva con el rendimiento: las campañas donde la cobertura vegetal alcanzó mayor vigor (NDVI superior a 0,78) tienden a registrar rendimientos superiores a 30 qq/ha. Se observan algunos casos con NDVI alto y rendimiento bajo, que podrían corresponder a campañas donde el cultivo se desarrolló adecuadamente durante la fase vegetativa pero sufrió un evento adverso durante el llenado de grano.

La cantidad de días con temperatura máxima superior a 35 °C presenta la asociación bivariada más clara de las tres: a medida que aumentan los días de calor extremo, el rendimiento disminuye. Por encima de los 30 días de estrés térmico entre octubre y febrero, los rendimientos se ubican en general por debajo de 20 qq/ha, con algunas excepciones en torno a ese umbral.

Cabe aclarar que estas relaciones son asociaciones bivariadas observadas en los datos y no permiten, por sí solas, establecer relaciones causales ni aislar el efecto individual de cada variable, dado que las tres se encuentran correlacionadas entre sí: las campañas secas suelen ser también las más cálidas y las de menor desarrollo vegetativo. Su valor en esta instancia es confirmar que las variables seleccionadas contienen información relevante, y que existen patrones no lineales, como el umbral de precipitación, que justifican el uso de modelos capaces de capturarlos.

Para cuantificar estas asociaciones se calculó el coeficiente de correlación de Pearson entre cada variable de la ventana oct_ene y el rendimiento. De las 39 variables, 35 presentan una correlación estadísticamente significativa ($p < 0,05$). Las asociaciones más fuertes corresponden a los días de calor extremo en octubre-noviembre ($r = -0,62$), el NDVI medio hasta enero ($r = +0,58$), los días de calor extremo hasta enero ($r = -0,57$), el NDVI máximo hasta enero ($r = +0,51$), la humedad relativa media ($r = +0,50$) y la precipitación acumulada ($r = +0,47$), todas con el signo esperable desde el punto de vista agronómico. Las variables sin asociación significativa son el NDVI medio, máximo y su

desvío en octubre-noviembre, y los días sin lluvia de ese período, cuando el cultivo recién se implanta. Dado que los cinco partidos de una misma campaña comparten condiciones climáticas, las observaciones no son completamente independientes y los p-valores deben leerse como orientativos; la magnitud de las correlaciones, en cambio, es robusta.

5.2. Comparación de modelos por ventana temporal

Se entrenaron los tres modelos (Regresión Lineal, Random Forest y Gradient Boosting) para cada una de las cinco ventanas temporales, evaluándolos bajo el esquema de validación walk-forward descrito en la sección anterior. La Tabla 1 resume las métricas obtenidas.

Ventana	Modelo	MAE (qq/ha)	RMSE (qq/ha)	R ²
—	Baseline climatológico	4.04	6.15	-0.047
oct_nov	Gradient Boosting	3.33	4.35	0.477
oct_nov	Random Forest	3.66	4.59	0.419
oct_nov	Regresión Lineal	4.9	6.81	-0.282
oct_dic	Gradient Boosting	3.91	4.83	0.354
oct_dic	Random Forest	3.37	4.2	0.513
oct_dic	Regresión Lineal	3.85	5.18	0.258
oct_ene	Gradient Boosting	3.45	4.26	0.498
oct_ene	Random Forest	3.27	4.07	0.542
oct_ene	Regresión Lineal	6.46	7.74	-0.654
oct_feb	Gradient Boosting	3.38	4.45	0.453
oct_feb	Random Forest	3.17	3.92	0.575
oct_feb	Regresión Lineal	6.61	8.14	-0.832
oct_mar	Gradient Boosting	3.67	4.73	0.382
oct_mar	Random Forest	3.1	3.91	0.577
oct_mar	Regresión Lineal	9.72	12.15	-3.079

Tabla 1. Métricas de evaluación por modelo y ventana temporal (validación walk-forward, campañas 2016-2024).

Como referencia se incluyó un baseline climatológico: predecir, para cada partido y campaña, el promedio histórico de rendimiento de ese partido hasta la campaña anterior. Este baseline obtuvo un MAE de 4,04 qq/ha y un R² de -0,047. Conviene precisar qué representa: el promedio histórico es una referencia fija, que no incorpora ninguna información sobre la campaña en curso. En enero predice lo mismo que en octubre, haya

llovido mucho o poco. El modelo, en cambio, actualiza su estimación con las condiciones observadas, y esa es la capacidad que se busca evaluar.

Random Forest obtuvo el mejor desempeño en cuatro de las cinco ventanas temporales. La excepción es oct_nov, donde Gradient Boosting logró un error menor (3,33 frente a 3,66 qq/ha); con tan poca información disponible al inicio de la campaña, las diferencias entre modelos son pequeñas y poco estables. En la ventana oct_ene, Random Forest alcanzó un MAE de 3,27 qq/ha, 0,77 qq/ha (19 %) menos que el baseline.

La Regresión Lineal solo superó al baseline en la ventana oct_dic (MAE de 3,85 qq/ha; R^2 de 0,258). En el resto de las ventanas su desempeño fue inferior a una predicción constante, con R^2 negativos que se profundizan a medida que se agregan variables: -0,282 en oct_nov, -0,654 en oct_ene, -0,832 en oct_feb y -3,079 en oct_mar. Este comportamiento es esperable: con decenas de variables predictoras y solo 125 observaciones, un modelo lineal sin regularización sobreajusta los datos de entrenamiento y generaliza peor que el promedio.

5.3. Curva de anticipación: error vs. momento de predicción

El resultado central de este proyecto es la relación entre el momento del ciclo en que se realiza la predicción y la precisión obtenida. La Figura 5 muestra esta curva de anticipación para el modelo Random Forest.




Figura 5. Error medio absoluto (izquierda) y coeficiente de determinación R^2 (derecha) del modelo Random Forest para cada ventana temporal. La línea punteada indica el error del baseline climatológico (promedio histórico por partido). Fuente: elaboración

propia.

El error del modelo disminuye de manera gradual a medida que avanza la campaña. Con datos hasta noviembre, el MAE es de 3,66 qq/ha y el R^2 de 0,42; con datos hasta diciembre, 3,37 qq/ha y 0,51; hasta enero, 3,27 qq/ha y 0,54; hasta febrero, 3,17 qq/ha y 0,57; y con datos hasta marzo, 3,10 qq/ha y 0,58. En todas las ventanas el modelo supera al baseline climatológico (4,04 qq/ha).

La mayor mejora se produce entre noviembre y diciembre, cuando se incorpora información sobre la implantación y el desarrollo vegetativo temprano del cultivo. A partir de allí, cada mes adicional reduce el error en torno a 0,1 qq/ha. Visto en términos de la ganancia total respecto del baseline, con datos hasta fines de enero el modelo ya logra más del 80 % de la mejora que alcanza con la campaña completa (0,77 de 0,94 qq/ha).

Esta dinámica tiene una lectura agronómica coherente. A fines de enero, la soja de primera transita las etapas R3-R4 y comienza el período crítico. La información acumulada hasta ese momento refleja las condiciones de implantación, el vigor vegetativo alcanzado y el estado hídrico con que el cultivo llega a la etapa reproductiva. Lo que todavía no puede anticipar es el clima de febrero y marzo, que afecta el llenado de grano; de allí la mejora adicional, aunque moderada, de las últimas ventanas.

Desde el punto de vista operativo, esto implica que a fines de enero, unos tres meses antes de la cosecha, es posible disponer de una estimación con un error medio de alrededor de 3,3 qq/ha, levemente mayor que el de una estimación realizada con toda la información de la campaña, pero con mucho más margen para actuar.

5.4. Acierto direccional

Dado que el objetivo del modelo es anticipar cómo viene la campaña más que estimar un valor exacto, se evaluó su capacidad para anticipar la dirección del resultado: si el rendimiento de cada partido se ubicaría por encima o por debajo de su promedio histórico. Con la ventana oct_ene, el modelo acertó la dirección en 32 de las 45 predicciones fuera de muestra (71 %). Un test binomial contra una predicción al azar (50 %) indica que el resultado es estadísticamente significativo ($p = 0,003$), con la misma salvedad sobre la dependencia entre partidos de una misma campaña señalada en la sección 5.1.

El análisis por campaña muestra dónde se concentra el aporte del modelo. En campañas cercanas a lo normal, el promedio histórico ya es una buena aproximación y el modelo no lo mejora de manera sistemática. La diferencia aparece cuando la campaña se aparta marcadamente de lo habitual: en 2022/23, la de peor desempeño del período de test, el promedio histórico erró en promedio por 15,5 qq/ha por partido, mientras que el modelo, con datos hasta enero, redujo ese error a 5,5 qq/ha. Son precisamente esas campañas las que justifican disponer de una estimación temprana.

5.5. Interpretabilidad: Importancia de variables

Para comprender qué variables tienen mayor influencia sobre las predicciones del modelo, se analizó la importancia relativa de cada feature según el criterio de Random Forest, que mide cuánto contribuye cada variable a la reducción del error de predicción a lo largo de todos los árboles del ensamble.

La Figura 6 muestra las 15 variables más importantes del modelo entrenado con la ventana oct_ene.




Figura 6. Top 15 variables con mayor importancia relativa en el modelo Random Forest (ventana octubre-enero). El color distingue el tipo de fuente: dorado para variables

climáticas, verde para NDVI satelital y celeste para precipitación. Fuente: elaboración propia.

La variable con mayor importancia relativa es la humedad relativa media entre octubre y enero, que concentra cerca del 40 % de la importancia total del modelo. Su interpretación agronómica es la de un indicador indirecto del balance hídrico atmosférico: valores bajos de humedad relativa media durante el período octubre-enero identifican veranos secos, con alta demanda evaporativa y mayor consumo de agua del perfil del suelo. El análisis de contribuciones individuales muestra que son precisamente las campañas con humedad relativa baja las que reciben las correcciones negativas más fuertes por parte del modelo, mientras que los valores altos se asocian a predicciones en torno o por encima del promedio. En otras palabras, esta variable actúa como un detector de campañas con déficit hídrico, que son las que concentran las mayores pérdidas de rendimiento en la serie analizada.

En segundo lugar aparece la temperatura máxima media de octubre-noviembre, lo que indica que las condiciones térmicas durante las etapas iniciales del cultivo ya aportan información predictiva sobre el resultado de la campaña.

Entre la tercera y la quinta posición aparecen tres variables satelitales: la pendiente del NDVI entre octubre y enero, el NDVI máximo hasta enero y el NDVI máximo hasta noviembre. La pendiente refleja la velocidad con que la cobertura vegetal se desarrolló a lo largo de la campaña: un aumento rápido del NDVI indica una buena implantación y cierre del canopeo, mientras que una pendiente baja puede señalar un desarrollo lento o condiciones adversas. El NDVI máximo, por su parte, refleja el pico de vigor alcanzado, asociado a mayor biomasa acumulada y mayor potencial de rendimiento. Que tres de las cinco variables más relevantes sean satelitales indica que la información de NDVI aporta capacidad predictiva propia, complementaria a la climática.

Corresponde señalar dos precauciones en la lectura de estos resultados. En primer lugar, la importancia de variables en Random Forest mide la contribución de cada predictor a la reducción del error dentro del modelo, y no constituye evidencia de causalidad: indica qué variables resultan más útiles para predecir, no cuáles determinan biológicamente el rendimiento. En segundo lugar, esta métrica se reparte de manera arbitraria entre variables correlacionadas entre sí. Dado que humedad relativa, temperatura y radiación están fuertemente correlacionadas, el hecho de que la humedad concentre el 40 % de la importancia no implica que sea el factor dominante: es probable que esté absorbiendo la señal compartida de todo el grupo de variables asociadas al balance hídrico estival.

Un aspecto relevante es que las variables con mayor peso son medibles a medida que avanza la campaña: humedad y temperatura están disponibles tanto en NASA POWER como en las estaciones meteorológicas que ya operan algunas cooperativas de la zona, y el NDVI se actualiza cada 16 días de forma gratuita a través de Google Earth Engine. Esto refuerza la viabilidad técnica de implementar el modelo como sistema de estimación temprana.

5.6. Aplicación a la campaña 2025/26

Como validación final, se aplicó el modelo a la campaña 2025/26, que no formó parte del conjunto de entrenamiento ni del esquema de validación walk-forward. Para ello, se descargaron los datos climáticos y satelitales correspondientes al ciclo octubre 2025 – marzo 2026 y se construyeron las features siguiendo el mismo procedimiento utilizado para las campañas históricas.

Dado que al momento de ejecutar la predicción la campaña ya se encontraba finalizada, se dispuso de datos completos hasta marzo, por lo que la predicción corresponde a la ventana oct_mar. Bajo condiciones de uso operativo real, la estimación relevante sería la de la ventana oct_ene, cuyo error medio histórico (3,27 qq/ha) es levemente mayor al de la ventana oct_mar (3,10 qq/ha). La sección 5.7 analiza qué habría estimado el modelo con esa información.

El modelo, entrenado con las 25 campañas anteriores (2000-2024), generó las siguientes predicciones:

Partido	Predicción (qq/ha)	Prom. 25 camp. (qq/ha)	Dif. vs 25 camp.	Prom. últ. 10 (qq/ha)	Dif. vs últ. 10
General Arenales	35.2	33.8	+4.0%	32.5	+8.3%
Leandro N. Alem	34.6	30.9	+11.9%	29.8	+15.9%
Junín	33.9	32.4	+4.7%	33.3	+1.7%
Lincoln	31.8	29.0	+9.6%	29.1	+9.1%
General Pinto	31.3	29.4	+6.4%	28.8	+8.5%
Promedio zona	33.4	31.1	+7.2%	30.7	+8.5%

Tabla 2. Predicción de rendimiento de soja para la campaña 2025/26 por partido (ventana oct_mar), comparada con el promedio de las 25 campañas y con el promedio de las últimas diez. Fuente: elaboración propia.

La Figura 7 muestra la predicción en el contexto de la serie histórica.




Figura 7. Rendimiento promedio zonal real (línea negra) y predicho por el modelo con datos hasta enero (ventana oct_ene, validación walk-forward; línea verde) para las campañas 2016-2024, junto con la predicción para la campaña 2025/26 (punto dorado, ventana oct_mar). La banda sombreada indica $\pm$ el error medio del modelo. Fuente: elaboración propia.

El modelo estimó una campaña por encima del promedio en los cinco partidos, con un rendimiento promedio zonal de 33,4 qq/ha. Como referencia adicional se incluyó el promedio de las últimas diez campañas (30,7 qq/ha), menos afectado por los rendimientos más bajos de principios de la serie. La predicción se ubica por encima de ambas referencias: un 7,2 % sobre el promedio de largo plazo y un 8,5 % sobre el de la última década.

Corresponde leer este resultado con la cautela adecuada. La diferencia entre la estimación y el promedio histórico (+2,3 qq/ha) es menor que el error medio del modelo (3,1 qq/ha), por lo que la predicción debe interpretarse como una señal de dirección, campaña por encima de lo normal, y no como un valor puntual.

Al momento de elaboración de este documento, el MAGyP no había publicado el rendimiento oficial por partido para la campaña 2025/26. El informe de cierre de la Bolsa de Cereales de Buenos Aires ubicó a la región Norte de La Pampa-Oeste de Buenos Aires entre las de mejor desempeño del país, con rendimientos récord para la serie, tanto en soja de primera como de segunda. Esto es coherente con la dirección estimada por el modelo, y sugiere a la vez que la magnitud real podría ser superior a la estimada, algo esperable dada la tendencia de Random Forest a subestimar campañas excepcionales (sección 6.3). La validación cuantitativa quedará pendiente hasta la publicación de los

datos oficiales por partido.

5.7. Simulación: predicción con datos de enero

La predicción presentada en la sección 5.6 fue generada con la ventana oct_mar, dado que la campaña ya había finalizado al momento de ejecutarla. Sin embargo, el valor operativo del modelo depende de lo que puede estimar antes de la cosecha. Surge entonces la pregunta: ¿qué habría predicho el modelo si se lo hubiera ejecutado en enero, con tres meses de anticipación real?

Para responder esto se realizó una simulación retrospectiva. Se tomaron los mismos datos climáticos y satelitales de la campaña 2025/26 pero truncados a dos fechas: el 15 de enero y el 31 de enero de 2026. En cada caso se construyeron las variables predictoras utilizando únicamente la información disponible hasta esa fecha y se generaron las predicciones con el modelo entrenado exclusivamente con la ventana oct_ene. La Tabla 3 muestra los resultados.

Partido	15 de enero (qq/ha)	31 de enero (qq/ha)	Oct-Mar completa (qq/ha)	Prom. histórico (qq/ha)
General Arenales	33.9	34.2	35.2	33.8
Leandro N. Alem	33.6	33.7	34.6	30.9
Junín	34.1	34.2	33.9	32.4
Lincoln	29.7	31.7	31.8	29.0
General Pinto	31.6	33.2	31.3	29.4
Promedio zona	32.6	33.4	33.4	31.1

Tabla 3. Predicción de rendimiento por partido para la campaña 2025/26 según tres escenarios: con datos disponibles al 15 de enero, al 31 de enero, y con datos completos hasta marzo. Fuente: elaboración propia.




Figura 8. Comparación de predicciones de rendimiento por partido según el momento de ejecución del modelo. Fuente: elaboración propia.

Las tres estimaciones coinciden en la dirección: campaña por encima del promedio histórico a nivel zonal. Al 15 de enero, la estimación zonal era de 32,6 qq/ha (1,5 qq/ha sobre el promedio), con General Arenales prácticamente en su promedio histórico. Al 31 de enero, la estimación subió a 33,4 qq/ha, exactamente el mismo valor que se obtiene con los datos completos de la campaña.

La suba entre ambas fechas es coherente con lo ocurrido en la zona: tras un mes de enero con déficit hídrico en gran parte de la región pampeana, las lluvias de fines de enero se concentraron en el oeste bonaerense y sostuvieron el potencial del cultivo. El modelo incorporó esa mejora en su estimación del 31 de enero, y en todos los partidos esta fue igual o superior a la del 15 de enero.

Desde el punto de vista operativo, un modelo ejecutado a fines de enero de 2026 habría emitido la misma señal que el obtenido con toda la información de la campaña: prepararse para una campaña por encima de lo normal. Cabe aclarar que se trata de una sola campaña, por lo que este resultado ilustra el funcionamiento del modelo, pero no constituye por sí mismo una validación estadística.

5.8. Alternativas evaluadas

Para determinar si el desempeño del modelo podía mejorarse, se exploraron dos líneas complementarias: el uso de otros algoritmos y la mejora de la señal satelital.

Otros algoritmos. Bajo el mismo esquema walk-forward y la ventana oct_ene, se evaluaron modelos lineales regularizados (Ridge, Lasso y ElasticNet), XGBoost, máquinas de vectores de soporte (SVR) y vecinos más cercanos (KNN). Ninguno superó a Random Forest. También se evaluó reducir el modelo a las ocho variables más importantes: en una primera prueba el error bajó a 2,90 qq/ha, pero esa mejora resultó aparente, ya que la selección se había hecho con información de todo el período. Al repetir la selección dentro de cada iteración del walk-forward, el error fue de 3,21 qq/ha, equivalente al del modelo con las 39 variables. El modelo Lasso aportó además un resultado coherente con la lectura agronómica: de las 39 variables retuvo solo tres (días de calor extremo en octubre-noviembre, NDVI máximo y NDVI medio hasta enero), en línea con las correlaciones de la sección 5.1. La conclusión es que, con el volumen de datos disponible, el límite de desempeño está dado por la información y no por el algoritmo.

Señal satelital filtrada por cultivo. Como se señaló en la sección 2.2, el NDVI utilizado promedia todos los píxeles del partido. Para evaluar si aislar la señal del cultivo mejoraba el modelo, se utilizaron dos fuentes de clasificación del uso del suelo. Con Dynamic World (Google) se estimó la fracción agrícola de cada partido (verano 2023/24), que va del 86 % en General Arenales al 57 % en Lincoln. Con el Mapa Nacional de Cultivos del INTA, disponible para las campañas de verano 2019/20 a 2023/24, se construyó una máscara de soja a la resolución de MODIS, conservando los píxeles con al menos un 50 % de superficie de soja. El mapa no distingue soja de primera y de segunda. La campaña 2018/19 se excluyó porque su mapa utiliza un esquema de clases distinto, que combina cultivos de invierno y de verano. La fracción de soja resultó estable entre campañas y coherente con el gradiente de la zona: entre 55 % y 61 % en General Arenales y entre 20 % y 27 % en Lincoln.

El NDVI filtrado muestra curvas más coherentes entre partidos: valores más bajos al inicio de la campaña, cuando el lote de soja todavía es suelo desnudo, y más altos en el pico de enero-febrero, sin la dilución de pasturas y otras coberturas. Sin embargo, al utilizarlo como input del modelo entrenado con NDVI sin filtrar, el error medio absoluto aumentó de 3,08 a 3,80 qq/ha en las cinco campañas con máscara disponible. Esto es esperable: el modelo aprendió con una señal que incluye toda la cobertura del partido, y al recibir una señal diferente interpreta los valores como condiciones anómalas. Para

aprovechar la máscara de cultivo sería necesario reentrenar el modelo íntegramente con NDVI filtrado, lo cual requiere una serie más larga que las cinco campañas hoy disponibles.




Figura 9. NDVI de la campaña 2022/23 por partido, filtrado a píxeles de soja según el Mapa Nacional de Cultivos del INTA (izquierda) y sin filtrar (derecha). Fuente: elaboración propia a partir de datos MODIS e INTA.

6. Discusión

6.1. Hallazgos principales

El proyecto permitió construir un sistema de estimación de rendimiento de soja a nivel de partido utilizando exclusivamente datos públicos y gratuitos. Los hallazgos más relevantes se organizan en cuatro ejes.

El primero es la dinámica de anticipación. El error del modelo disminuye de forma gradual a medida que avanza la campaña, sin un punto de quiebre marcado. La mayor mejora ocurre al incorporar diciembre, y con datos hasta fines de enero el modelo ya logra más del 80 % de la mejora total que alcanza sobre el baseline con la campaña completa. En términos prácticos, una estimación con tres meses de anticipación resulta apenas menos precisa que una realizada al final del ciclo (3,27 frente a 3,10 qq/ha de error medio).

El segundo eje se refiere a las variables con mayor poder predictivo. El estrés térmico aparece como la señal individual más fuerte: los días con temperatura máxima superior

a 35 °C entre octubre y noviembre muestran la correlación más alta con el rendimiento ($r = -0,62$), y es una de las tres variables que retuvo el modelo Lasso (sección 5.8). Sin embargo, no figura entre las quince más importantes del Random Forest: al estar fuertemente correlacionada con la humedad relativa y la temperatura máxima, su señal es absorbida por esas variables, que concentran la importancia (sección 5.5). La lectura combinada es consistente: las condiciones de calor y déficit hídrico de la primavera, junto con el NDVI hasta enero, son las que permiten anticipar el resultado con tres meses de antelación.

El tercero es el comportamiento del modelo frente a campañas de distinto tipo. La estimación resultó acertada en campañas de rendimiento extremadamente bajo, como 2022/23, donde el modelo anticipó correctamente una caída pronunciada, aunque subestimando su magnitud. En cambio, en campañas de desvío moderado el desempeño fue menos consistente: en 2017/18, por ejemplo, el modelo predijo un rendimiento por encima del promedio cuando el resultado real se ubicó por debajo. Esto indica que la utilidad del sistema es mayor para detectar campañas claramente anómalas que para discriminar desvíos de menor magnitud.

El cuarto refiere a las alternativas exploradas. Ni otros algoritmos ni la selección de variables superaron al modelo base, lo que indica que el margen de mejora no está en el método sino en la información disponible: más campañas, mayor resolución espacial y variables de manejo.

6.2. Valor para la toma de decisiones en una cooperativa

El valor práctico de un modelo de predicción de rendimiento no reside en la precisión del número en sí, sino en la capacidad de anticipar la dirección del resultado con suficiente tiempo como para actuar. En este sentido, disponer de una estimación razonable en enero, tres meses antes de la cosecha, habilita varias decisiones operativas concretas para una cooperativa agrícola.

En primer lugar, la planificación logística de acopio. Si el modelo indica que la campaña viene por debajo del promedio, la cooperativa puede anticipar que recibirá menos toneladas en sus plantas de acopio, ajustando turnos de recepción, capacidad de secado y necesidades de transporte. Si la campaña viene bien, puede prepararse para un mayor volumen y evitar cuellos de botella en la recepción.

En segundo lugar, la gestión de la posición comercial. Es importante precisar el alcance de este punto: el precio de la soja en el mercado local se forma a partir del FAS teórico, que depende de la cotización internacional, el precio FOB, los derechos de exportación y el tipo de cambio. Una campaña corta circunscripta a cinco partidos no tiene capacidad de influir sobre ese precio. Lo que sí puede verse afectado es la base local, es decir, el diferencial entre el precio de la zona y el de referencia, por efecto de la competencia entre acopios y de las condiciones logísticas cuando la oferta regional es escasa.

El valor más concreto en este plano es el de la gestión del riesgo de la posición tomada. Si la cooperativa ha comprometido volumen a entregar mediante ventas forward y el modelo anticipa en enero una campaña por debajo del promedio, dispone de tiempo para evaluar la cobertura de ese compromiso antes de que el faltante se materialice en cosecha, momento en el cual las alternativas son más costosas.

En tercer lugar, la gestión del riesgo crediticio. Las cooperativas frecuentemente financian insumos (semillas, agroquímicos, fertilizantes) a los productores a cuenta corriente, contra la entrega del grano en cosecha. Una estimación temprana del rendimiento permite dimensionar la exposición crediticia por zona y anticipar potenciales dificultades de cobranza en partidos donde la campaña viene desfavorable.

Es importante señalar que el modelo no pretende reemplazar la experiencia de los técnicos de campo ni las estimaciones que realizan los profesionales del sector. Su valor reside en complementar esas fuentes con una herramienta cuantitativa, objetiva y reproducible, que sistematiza información que hoy se interpreta de manera informal.

6.3. Limitaciones del modelo

Los resultados presentados deben interpretarse a la luz de las siguientes limitaciones.

Escala de análisis. El modelo opera a nivel de partido y estima un rendimiento promedio para toda la superficie sembrada. Un productor individual puede obtener un resultado considerablemente distinto de ese promedio, en función del tipo de suelo de su lote, la fecha de siembra, el cultivar utilizado y el manejo agronómico aplicado. El sistema no es apto para estimaciones a nivel de lote.

Naturaleza de la señal de NDVI. Como se señaló en la sección 2.2, el NDVI utilizado corresponde al promedio de todos los píxeles del polígono de cada partido, sin discriminar el tipo de cobertura. La serie incluye maíz, trigo, pasturas, montes, áreas

urbanas y cuerpos de agua, por lo que constituye un indicador del estado general de la vegetación y no una medición del cultivo de soja. Esto introduce ruido y atenúa la señal, de manera diferente en cada partido según su composición de usos del suelo. Tampoco se aplicó un filtro basado en la banda de confiabilidad del producto MOD13Q1, por lo que algunas observaciones podrían estar afectadas por cobertura nubosa residual. Esta limitación fue abordada de forma exploratoria mediante máscaras de uso del suelo (sección 5.8). La señal filtrada resultó más representativa de la fenología del cultivo, pero no mejoró las predicciones del modelo actual, entrenado con la señal sin filtrar.

Incapacidad de extrapolación del modelo. Random Forest genera predicciones promediando los valores observados en las hojas de sus árboles, lo que implica que no puede predecir valores por fuera del rango presente en los datos de entrenamiento. Dado que la serie de rendimientos presenta una tendencia positiva de largo plazo asociada a la mejora genética y de manejo, y que el modelo no incorpora ninguna variable que represente esa tendencia, existe un sesgo estructural hacia la compresión de las predicciones: el modelo tiende a subestimar las campañas excepcionalmente buenas y a sobreestimar las excepcionalmente malas. Este comportamiento es visible en la Figura 7, particularmente en la campaña 2022/23.

Tamaño del dataset. Con 125 observaciones, no es viable explorar arquitecturas de mayor complejidad sin incurrir en sobreajuste severo. Random Forest con profundidad limitada resultó una elección adecuada para este volumen de datos, pero el margen de mejora por la vía del modelado es acotado mientras no crezca la cantidad de observaciones. Los experimentos con otros algoritmos (sección 5.8) confirman este punto: ninguno superó a Random Forest.

Resolución de los datos climáticos. Tal como se detalló en la sección 4.1, la grilla de NASA POWER es considerablemente más gruesa que la distancia entre los partidos analizados, lo que limita la capacidad del modelo para discriminar condiciones climáticas locales entre ellos.

Ausencia de variables de manejo. La densidad de siembra, la fertilización, el cultivar utilizado, el control de malezas y plagas y la fecha efectiva de siembra son factores relevantes para el rendimiento que no están disponibles en fuentes públicas a la escala requerida. Su ausencia impone un techo a la precisión alcanzable por el modelo.

Agregación de soja de primera y de segunda. El rendimiento publicado por el MAGyP corresponde al total de soja del partido sin distinguir entre ambas. Dado que la soja de segunda se siembra aproximadamente dos meses después y transita su período crítico

más tarde, las ventanas temporales del modelo, alineadas al ciclo de la soja de primera, resultan menos adecuadas para esa fracción de la superficie. El efecto es mayor en los partidos donde el doble cultivo tiene más peso.

Eventos de alto impacto localizado. Granizo, tormentas severas, anegamientos y heladas tempranas pueden afectar severamente el rendimiento de áreas específicas sin quedar reflejados de manera proporcional en las variables climáticas promediadas a nivel de partido.

Clima posterior a la estimación. Una estimación realizada en enero solo dispone de la información ocurrida hasta ese momento. Las lluvias o eventos de estrés que se produzcan durante febrero y marzo, en pleno llenado de grano, pueden modificar sustancialmente el resultado final. La campaña 2025/26 ilustra este punto: el déficit hídrico de enero fue revertido por lluvias posteriores. El modelo ofrece una estimación condicionada a lo observado, no un pronóstico del clima futuro.

6.4. Trabajo futuro

Las alternativas exploradas en la sección 5.8 indican que el margen de mejora del modelo depende de la información disponible más que del método. Por eso, las líneas de desarrollo que siguen están condicionadas a la aparición de datos que hoy no existen o no tienen la extensión suficiente.

Más campañas. Cada nueva campaña publicada por el MAGyP suma cinco observaciones al entrenamiento. La primera será la 2025/26, que permitirá además verificar cuantitativamente la predicción de la sección 5.6; luego, la aplicación del modelo a la campaña 2026/27 en condiciones enteramente prospectivas. Una serie más larga, en particular con más eventos extremos, permitirá al modelo capturar una mayor diversidad de escenarios.

Serie más larga de mapas de cultivos. La señal de NDVI filtrada a soja resultó más representativa del cultivo, pero el Mapa Nacional de Cultivos cubre hoy solo cinco campañas, insuficientes para reentrenar el modelo con esa señal. Si la serie se amplía, será posible entrenar el modelo íntegramente con NDVI de soja y evaluar su aporte de forma consistente.

Rendimientos a escala más fina. Pasar del partido al lote o a zonas homogéneas permitiría usar imágenes de mayor resolución (Sentinel-2, 10 m) y multiplicaría las

observaciones disponibles. Esto requiere datos de rendimiento georreferenciados, como mapas de monitor de cosecha, que no son de acceso público.

7. Conclusiones

Este trabajo se propuso responder si es posible estimar el rendimiento de soja a nivel de partido antes de la cosecha utilizando únicamente fuentes de datos públicas y gratuitas, y a partir de qué momento del ciclo esa estimación alcanza un nivel de error razonable.

La respuesta a la primera pregunta es afirmativa, con las salvedades detalladas en la sección 6.3. Un modelo Random Forest alimentado con NDVI del sensor MODIS y variables climáticas de NASA POWER alcanzó, con datos hasta fines de enero, un error medio absoluto de 3,27 qq/ha y un R^2 de 0,54 bajo validación temporal estricta, y anticipó correctamente si la campaña venía por encima o por debajo del promedio histórico en el 71 % de los casos.

La respuesta a la segunda pregunta es que el desempeño del modelo mejora de manera gradual a lo largo de la campaña, sin un punto de quiebre marcado. Con datos hasta fines de enero, unos tres meses antes de la cosecha, el modelo ya obtiene la mayor parte de su capacidad predictiva: más del 80 % de la mejora que alcanza con la campaña completa. Esto implica que el momento útil para producir una primera estimación es temprano, y que las estimaciones posteriores funcionan como refinamientos de esa primera señal.

El alcance de esta conclusión debe delimitarse con precisión. El modelo demostró capacidad para anticipar campañas claramente anómalas, pero su desempeño fue menos consistente frente a desvíos moderados. Su utilidad, por lo tanto, se ubica más en el terreno de la señal de alerta “esta campaña viene marcadamente por debajo o por encima de lo habitual” que en el de la estimación precisa de un valor puntual. Para las decisiones operativas descritas en la sección 6.2, esa distinción no invalida la herramienta, pero sí define cómo debería utilizarse.

Las alternativas evaluadas, como otros algoritmos, la selección de variables y la señal satelital filtrada por tipo de cultivo, no superaron al modelo base. Esto delimita dónde está el margen de mejora: en la cantidad y calidad de la información disponible más que en la sofisticación del método.

La aplicación a la campaña 2025/26 estimó una campaña por encima de lo normal, lo que resulta coherente con los reportes de cierre de la Bolsa de Cereales, que ubicaron a la región entre las de mejor desempeño del país. La simulación retrospectiva mostró que la estimación de fines de enero coincidió exactamente con la obtenida con datos completos. La verificación cuantitativa quedará pendiente hasta la publicación de los datos oficiales por partido.

Este resultado le da un sustento empírico concreto al hallazgo de la curva de anticipación y refuerza la conclusión central del trabajo. No se trata solo de que las métricas históricas mejoren a partir de enero, sino de que, aplicado a una campaña real, el modelo efectivamente entrega en enero una estimación estable y accionable.

El trabajo no pretende competir con los sistemas de estimación que operan instituciones especializadas con mayores recursos, mayor densidad de datos y relevamientos a campo. Su aporte consiste en mostrar que, a partir de fuentes abiertas y con conocimiento del dominio, es posible construir un sistema funcional y reproducible que aborda un problema concreto para actores que actualmente no disponen de herramientas de este tipo. El pipeline desarrollado está preparado para aplicarse a la campaña 2026/27, cuya siembra comienza en octubre de 2026, lo que permitirá una evaluación en condiciones enteramente prospectivas.

8. Referencias

- Ministerio de Agricultura, Ganadería y Pesca de la Nación (MAGyP). Datos abiertos: estimaciones agrícolas por cultivo, provincia y departamento. Disponible en: <https://datos.magyp.gob.ar/>
- NASA POWER Project. Prediction Of Worldwide Energy Resources — Data Access Viewer. NASA Langley Research Center. Disponible en: <https://power.larc.nasa.gov/>
- Google Earth Engine. Plataforma de análisis geoespacial en la nube. Google. Disponible en: <https://earthengine.google.com/>
- MODIS Vegetation Index Products (MOD13Q1). NASA Land Processes Distributed Active Archive Center (LP DAAC). Disponible en: <https://lpdaac.usgs.gov/products/mod13q1v061/>
- FAO GAUL (Global Administrative Unit Layers). Food and Agriculture Organization of the United Nations. Nivel 2, utilizado para polígonos administrativos de

partidos.

- Bolsa de Cereales de Buenos Aires. Panorama Agrícola Semanal (PAS) — informes de campaña. Disponible en: <https://www.bolsadecereales.com/>
- Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5-32.
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. Annals of Statistics, 29(5), 1189-1232.
- Fehr, W. R. & Caviness, C. E. (1977). Stages of soybean development. Special Report 80, Iowa State University, Cooperative Extension Service.
- Rouse, J. W., Haas, R. H., Schell, J. A. & Deering, D. W. (1974). Monitoring vegetation systems in the Great Plains with ERTS. Proceedings of the Third Earth Resources Technology Satellite-1 Symposium, NASA SP-351, 309-317.
- Brown, C. F. et al. (2022). Dynamic World, Near real-time global 10 m land use land cover mapping. Scientific Data, 9, 251.
- de Abelleyra, D. et al. (2020). Mapa Nacional de Cultivos campaña 2019/2020. Versión 1. Instituto Nacional de Tecnología Agropecuaria (INTA).