

ESTIMACIÓN TEMPRANA DEL RENDIMIENTO DE SOJA

Datos satelitales y climáticos aplicados al noroeste bonaerense

Agustín Musanti

Proyecto personal de Data Science aplicado

2026

Nota de versión....4
Resumen....4
1. Introducción....5
1.1. Motivación y contexto....5
1.2. Pregunta de investigación....6
1.3. Objetivos del proyecto....7
1.4. Alcance y limitaciones....7
2. Marco conceptual....8
2.1. El cultivo de soja en Argentina y la zona de estudio....8
2.2. Teledetección aplicada a la agricultura: el índice NDVI....10
2.3. Variables climáticas relevantes para el rendimiento de soja....13
2.4. Modelos de Machine Learning para predicción de rendimiento....15
3. Fuentes de datos....16
3.1. Rendimiento histórico: MAGyP....16
3.2. Datos climáticos: NASA POWER....18
3.3. Datos satelitales: MODIS vía Google Earth Engine....18
3.4. Índice de El Niño / La Niña: NOAA....19
4. Metodología....20
4.1. Zona de estudio y partidos seleccionados....20
4.2. Construcción del dataset: ventanas temporales y feature engineering....21
4.3. Diseño de la validación: walk-forward temporal....23
4.4. Modelos evaluados....24
4.5. Criterio para evaluar mejoras....25
4.6. Intervalos de predicción....26
5. Resultados....26
5.1. Análisis exploratorio de los datos....26
5.2. Comparación de modelos por ventana temporal....28
5.3. Curva de anticipación: error vs. momento de predicción....30
5.4. Acierto direccional y lectura por campaña....32
5.5. Intervalos de predicción....33
5.6. Interpretabilidad: Importancia de variables....35
5.7. Aplicación a la campaña 2025/26....37
5.8. Simulación: predicción con datos de enero....39
5.9. Evaluación de variables y estructuras alternativas....41
5.10. Otras alternativas evaluadas....46
6. Discusión....48
6.1. Hallazgos principales....48

6.2. Valor para la toma de decisiones en una cooperativa..... 49
6.3. Limitaciones del modelo..... 51
6.4. Trabajo futuro.....53
7. Conclusiones..... 54
8. Referencias..... 56

Nota de versión

Versión 4. Incorpora dos variables agroclimáticas al modelo: el déficit de presión de vapor (VPD) y la anomalía de NDVI respecto de lo normal de cada partido. Su aporte se evaluó contra la versión anterior bajo el mismo esquema de validación, y la mejora se concentra en las estimaciones de fines de noviembre y diciembre. Se agregan intervalos de predicción del 80% a todas las estimaciones (5.5), un análisis de acierto por campaña (5.4) y una sección con las variables, estructuras y algoritmos evaluados y descartados, incluida la señal de El Niño / La Niña (5.9). Se recalcularon todas las métricas, tablas y figuras, y se ajustaron en consecuencia la discusión y las conclusiones.

Versión 3. Incorpora una sección de acierto direccional (5.4), el análisis de correlación entre variables y rendimiento (5.1) y los resultados de las alternativas evaluadas para mejorar el modelo: otros algoritmos y una señal satelital filtrada por tipo de cultivo (5.8). Se ajustaron en consecuencia la discusión y las conclusiones.

Versión 2. Corrige un error detectado en la descarga de datos satelitales del partido de Junín: el filtro utilizado recuperaba seis polígonos con ese nombre pertenecientes a otras regiones. Se corrigió la extracción (filtrando por país, provincia y partido), se reconstruyó el dataset y se recalcularon todos los modelos, tablas y figuras.

Resumen

Este trabajo evalúa si es posible anticipar el rendimiento de soja a nivel de partido antes de la cosecha utilizando únicamente datos públicos y gratuitos. Se construyó un dataset de 125 observaciones (cinco partidos del noroeste bonaerense, campañas 2000/01 a 2024/25) que combina el rendimiento oficial del MAGyP, variables climáticas de NASA POWER y NDVI del sensor MODIS, organizadas en cinco ventanas temporales acumulativas alineadas al ciclo del cultivo. A las variables climáticas y satelitales básicas se sumaron dos indicadores con fundamento agronómico: el déficit de presión de vapor (VPD), que mide la demanda evaporativa a la que está expuesto el cultivo, y la anomalía de NDVI, que compara el vigor de la vegetación con lo normal de cada partido en la misma fecha.

Bajo validación temporal walk-forward, un modelo Random Forest con datos hasta fines de noviembre, unos cinco meses antes de la cosecha, obtuvo un error medio absoluto de 2,42 qq/ha, un 40% menos que el promedio histórico. Este resultado desplaza el momento útil de la primera estimación: ya no a fines de enero, sino a fines de noviembre, con actualizaciones mensuales que incorporan lo ocurrido durante el período crítico. Con

datos hasta fines de enero, el error fue de 3,01 qq/ha y el modelo anticipó si cada partido venía por encima o por debajo de su promedio en el 69% de los casos (p = 0,008). Cada estimación se acompaña de un intervalo de predicción del 80%, construido a partir de los errores reales del modelo, cuya cobertura verificada osciló entre el 77% y el 87% según la ventana.

Se evaluaron además otras variables, estructuras y algoritmos con un criterio fijado de antemano. Ninguno justificó modificar el modelo, aunque Gradient Boosting mostró menor error en todos los cortes y queda como alternativa a confirmar con datos nuevos. El resultado es una herramienta de alerta temprana: no busca un valor exacto, sino indicar con anticipación cómo viene la campaña y con qué margen de incertidumbre.

1. Introducción

1.1. Motivación y contexto

El sector agrícola argentino es uno de los pilares de la economía nacional. La soja, en particular, representa el principal cultivo en términos de superficie sembrada y valor de exportación, concentrando gran parte de su producción en la región pampeana. En este contexto, las cooperativas agrícolas cumplen un rol clave como intermediarias entre el productor y el mercado: acopian el grano, asesoran sobre precios y coberturas, y financian insumos para la campaña siguiente.

Sin embargo, a pesar del volumen que manejan y de la relevancia de sus decisiones operativas, muchas de estas organizaciones carecen de herramientas formales para anticipar el resultado de una campaña antes de que llegue la cosecha. Las estimaciones se basan en la experiencia acumulada de los técnicos de campo, en la observación del estado del cultivo y en el seguimiento informal de las precipitaciones. Esta información, aunque valiosa, no está sistematizada ni cuantificada, lo que limita la capacidad de planificación.

El presente proyecto nació de la observación directa de esta realidad. El autor cuenta con vínculo familiar y profesional con el agro del noroeste de la provincia de Buenos Aires, lo que permitió identificar de primera mano la ausencia de sistemas de estimación temprana en una cooperativa de la zona. A partir de esa motivación, se planteó investigar si es posible construir un modelo de predicción de rendimiento de soja utilizando únicamente datos públicos y gratuitos, y si ese modelo puede generar

estimaciones útiles con suficiente anticipación como para influir en decisiones reales.

1.2. Pregunta de investigación

La pregunta central que guía este proyecto es: ¿es posible estimar el rendimiento de soja a nivel de partido, antes de la cosecha, utilizando únicamente fuentes de datos públicas y gratuitas?

Esta pregunta general se descompone en dos dimensiones específicas. La primera tiene que ver con la precisión: ¿qué tan confiable puede ser un modelo basado exclusivamente en datos satelitales y climáticos, sin información de campo como densidad de siembra, genética utilizada o aplicaciones de fertilizantes? La segunda, y quizás más relevante desde el punto de vista práctico, tiene que ver con la anticipación: ¿a partir de qué momento del ciclo del cultivo la predicción alcanza un nivel de error aceptable para la toma de decisiones?

Un modelo que predice correctamente pero recién a fines de marzo, cuando la cosecha ya comenzó, tiene escaso valor operativo. En cambio, un modelo que logre una estimación razonable entre noviembre y enero, mientras el cultivo transita las etapas vegetativas y el inicio del período reproductivo, podría representar una herramienta concreta para cooperativas y otros actores del sector.

Cabe precisar el tipo de respuesta que se busca. El objetivo no es predecir el rendimiento exacto de cada partido, que depende de factores que no pueden observarse con datos públicos, sino disponer, desde las primeras etapas del ciclo, de una estimación de cómo viene la campaña: si las condiciones acumuladas hasta ese momento (lluvias, temperaturas, vigor del cultivo) apuntan a un rendimiento por encima o por debajo de lo habitual, y en qué magnitud aproximada. El modelo se plantea como una herramienta de apoyo a la decisión, no como un sustituto de la información de cosecha.

Una estimación sin una medida de su incertidumbre es difícil de usar: no es lo mismo esperar 33 qq/ha con un margen de ±1 que con un margen de ±5. Por eso, una tercera dimensión del trabajo es cuantificar ese margen de forma honesta, a partir de los errores que el modelo efectivamente cometió en campañas pasadas.

1.3. Objetivos del proyecto

El objetivo general de este proyecto es desarrollar un sistema de predicción de rendimiento de soja para la zona de influencia de una cooperativa del noroeste bonaerense, basado en datos satelitales, climáticos e históricos de producción, todos de acceso público y gratuito.

A partir de este objetivo general, se definen los siguientes objetivos específicos:

1. Construir un dataset integrado que combine información de rendimiento histórico por partido, índices de vegetación derivados de imágenes satelitales y variables climáticas diarias, alineados al ciclo fenológico del cultivo de soja.
2. Evaluar distintos modelos de aprendizaje automático mediante un esquema de validación temporal que simula condiciones reales de predicción, evitando la filtración de información futura.
3. Determinar a partir de qué momento del ciclo del cultivo el modelo alcanza un nivel de error útil para la toma de decisiones, construyendo una curva de anticipación que relacione el error de predicción con el avance de la campaña.
4. Analizar la importancia relativa de las variables predictoras para identificar qué factores aportan mayor capacidad predictiva sobre el rendimiento en la zona de estudio.
5. Aplicar el modelo entrenado a una campaña no vista durante el entrenamiento, a modo de validación final en condiciones reales.
6. Evaluar si variables agroclimáticas derivadas, otras estructuras de variables, otros algoritmos de aprendizaje automático o una señal satelital restringida a los píxeles de cultivo permiten mejorar el desempeño del modelo, utilizando un criterio de decisión definido antes de observar los resultados.
7. Cuantificar la incertidumbre de cada estimación mediante intervalos de predicción construidos a partir de los errores fuera de muestra del modelo.

1.4. Alcance y limitaciones

El proyecto se circunscribe a la predicción de rendimiento de soja en cinco partidos del noroeste de la provincia de Buenos Aires: General Arenales, Leandro N. Alem, Junín, Lincoln y General Pinto. Estos partidos conforman la zona de influencia de una cooperativa agrícola de la región y comparten características agroecológicas generales, lo que permite tratarlos como una unidad de análisis coherente.

El período analizado comprende las campañas 2000/01 a 2024/25, totalizando 25 campañas. La elección de este rango responde a la disponibilidad de datos satelitales del sensor MODIS, operativo desde el año 2000, y a la existencia de registros oficiales de rendimiento por partido publicados por el Ministerio de Agricultura, Ganadería y Pesca (MAGyP).

La unidad de análisis es el partido y no el lote individual. El modelo estima un rendimiento promedio para toda la superficie sembrada dentro de un partido, por lo que un productor individual puede obtener un resultado considerablemente distinto de ese promedio. El dataset resultante cuenta con 125 observaciones (5 partidos × 25 campañas), lo que condiciona el tipo de modelos que pueden entrenarse sin incurrir en sobreajuste.

Las limitaciones metodológicas del enfoque se desarrollan en detalle en la sección 6.3, una vez presentados los resultados.

2. Marco conceptual

2.1. El cultivo de soja en Argentina y la zona de estudio

La soja (*Glycine max*) es el cultivo de mayor relevancia económica en Argentina. Según datos del Ministerio de Agricultura, la superficie sembrada supera regularmente las 16 millones de hectáreas a nivel nacional, y el complejo sojero constituye la principal fuente de divisas por exportación del país, incluyendo el grano, la harina y el aceite de soja.

La zona de estudio se ubica en el noroeste de la provincia de Buenos Aires, en el límite entre la zona núcleo y la denominada Pampa Arenosa. Los cinco partidos seleccionados no son homogéneos en cuanto a suelos: General Arenales, Leandro N. Alem y buena parte de Junín se corresponden con Argiudoles de texturas franco a franco limosas, de alta capacidad de retención hídrica y elevada aptitud agrícola, mientras que Lincoln y General Pinto presentan mayor proporción de Hapludoles con texturas más gruesas, franco arenosas, con menor capacidad de almacenamiento de agua en el perfil. Esta diferencia edáfica configura un gradiente este-oeste que, como se verá más adelante, se refleja en los rendimientos históricos. El régimen de lluvias promedia entre 800 y 1000 mm anuales en toda la zona.

La soja de primera es el cultivo dominante, sembrada en octubre-noviembre como único

cultivo del lote en la campaña. También es frecuente el esquema de doble cultivo trigo/soja de segunda, donde la soja se siembra en diciembre tras la cosecha del cereal de invierno. En los lotes donde se realiza rotación sin doble cultivo, la soja de primera suele alternarse con maíz.

El ciclo del cultivo de soja en esta zona se extiende aproximadamente de octubre a abril, y puede dividirse en dos grandes fases: la fase vegetativa y la fase reproductiva. La fase vegetativa comprende desde la siembra (octubre-noviembre) hasta el inicio de la floración, y durante ella la planta desarrolla su estructura foliar y radicular. La fase reproductiva, que es la determinante del rendimiento final, incluye las siguientes etapas clave:

- **R1 (inicio de floración):** aparece la primera flor en cualquier nudo del tallo principal. Ocurre típicamente entre fines de diciembre y principios de enero.
- **R2 (floración plena):** hay flores abiertas en uno de los dos nudos superiores del tallo.
- **R3 (inicio de formación de vainas):** las vainas comienzan a desarrollarse. El cultivo tiene alta demanda de agua y nutrientes.
- **R4 (vainas completamente desarrolladas):** las vainas alcanzan su longitud máxima en los nudos superiores.
- **R5 (inicio de llenado de grano):** los granos comienzan a crecer dentro de las vainas. Es el período más crítico: el estrés hídrico o térmico en esta etapa tiene impacto directo sobre el rendimiento final.
- **R6 (llenado completo):** las vainas contienen granos verdes que ocupan toda la cavidad.
- **R7 (madurez fisiológica):** el grano alcanza su peso seco máximo. A partir de aquí el rendimiento ya está definido.
- **R8 (madurez comercial):** el 95% de las vainas alcanzaron su color de madurez. El cultivo está listo para cosecha.

El período crítico de determinación del rendimiento en soja se ubica entre R3 y R6, con máxima sensibilidad en torno a R4,5-R5,5. Si bien R1 y R2 marcan el inicio de la fase reproductiva, la soja posee una elevada capacidad de compensación durante la floración: el aborto de flores tempranas suele compensarse con la fijación de vainas en nudos posteriores. Es durante la formación de vainas y el llenado de granos cuando el cultivo define efectivamente el número de granos por unidad de superficie, que es el principal componente del rendimiento. En la zona de estudio, este período transcurre

aproximadamente entre mediados de enero y mediados de febrero.

Una deficiencia hídrica prolongada o temperaturas máximas superiores a 35 °C durante esta ventana pueden provocar aborto de vainas, reducción del número de granos por planta y menor peso individual del grano. Inversamente, condiciones favorables de disponibilidad hídrica y temperatura en este período suelen asociarse a rendimientos por encima del promedio histórico.

Esta asociación entre las condiciones ambientales durante las etapas reproductivas y el rendimiento final es la que fundamenta el enfoque predictivo de este proyecto: si es posible medir esas condiciones a medida que avanza la campaña mediante datos climáticos y satelitales, entonces es posible estimar el rendimiento antes de que la cosecha ocurra.

2.2. Teledetección aplicada a la agricultura: el índice NDVI

La teledetección o percepción remota consiste en la obtención de información sobre la superficie terrestre a partir de sensores montados en satélites. En el contexto agrícola, esta tecnología permite monitorear el estado de los cultivos a gran escala, con frecuencia regular y sin necesidad de recorrer cada lote en persona.

El principal indicador utilizado en teledetección agrícola es el NDVI (Normalized Difference Vegetation Index, o Índice de Vegetación de Diferencia Normalizada). Este índice se calcula a partir de la reflectancia que captura el sensor satelital en dos bandas del espectro electromagnético: la banda roja (RED) y la banda infrarroja cercana (NIR). La fórmula es:

NDVI = (NIR − RED) / (NIR + RED)

El fundamento físico es simple: las hojas de las plantas absorben la luz roja para realizar la fotosíntesis y reflejan fuertemente la luz infrarroja cercana. Un cultivo sano y vigoroso absorbe mucha luz roja y refleja mucha infrarroja, lo que resulta en un NDVI alto. Un cultivo estresado, seco o con baja cobertura foliar refleja más luz roja y menos infrarroja, produciendo un NDVI bajo.

Los valores de NDVI varían entre −1 y 1. En la práctica agrícola, los rangos relevantes son:

- Valores menores a 0,2: suelo desnudo, agua o superficies no vegetadas.
- Valores entre 0,2 y 0,4: vegetación rala o cultivo en etapas iniciales.
- Valores entre 0,4 y 0,6: vegetación moderada, cultivo en crecimiento.
- Valores entre 0,6 y 0,8: vegetación densa y sana, cultivo en pleno desarrollo.
- Valores superiores a 0,8: cobertura vegetal muy densa, típica del pico de desarrollo del cultivo.

En la zona de estudio, la señal de NDVI a nivel de partido sigue un patrón estacional bien definido, con valores bajos durante el invierno, un ascenso a partir de octubre-noviembre a medida que los cultivos de verano cubren el suelo, un máximo entre enero y febrero, y un descenso progresivo hacia marzo-mayo con la madurez y la cosecha. Este comportamiento se observa en la Figura 1.

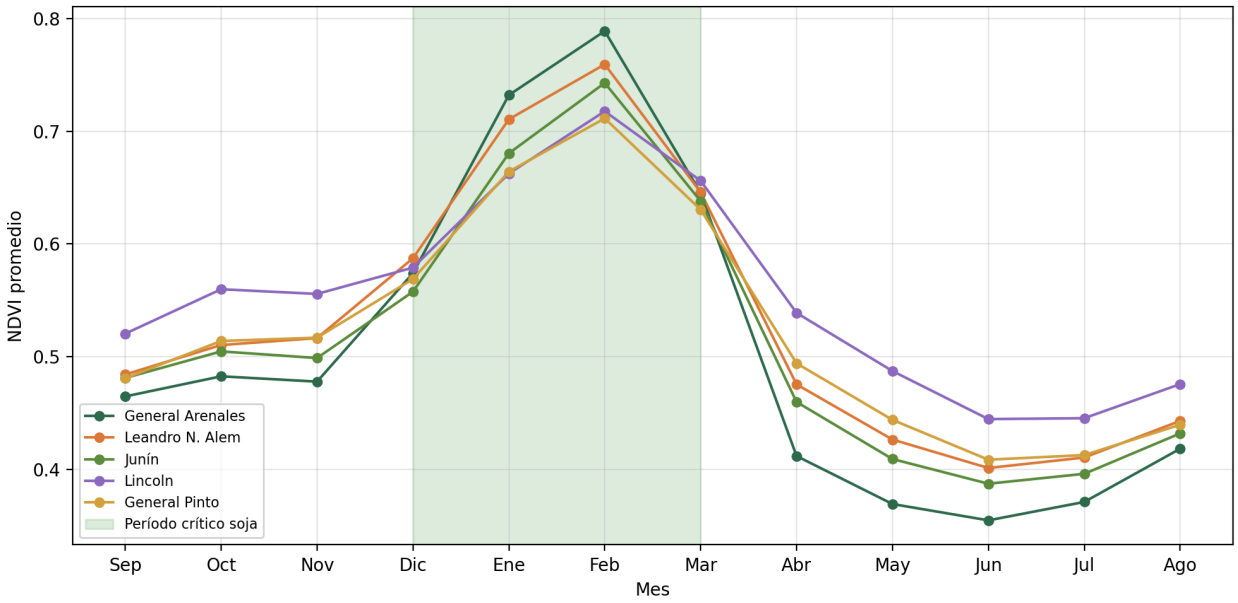


Figura 1. Ciclo anual promedio del NDVI por partido en la zona de estudio (período 2000-2025). La zona sombreada indica la etapa reproductiva de la soja de primera (diciembre-marzo), dentro de la cual se ubica el período crítico, entre mediados de enero y mediados de febrero. Fuente: elaboración propia a partir de datos MODIS.

Es importante precisar el alcance de esta señal. El NDVI utilizado corresponde al promedio de todos los píxeles contenidos dentro del polígono administrativo de cada partido, lo que incluye no solo lotes de soja sino también maíz, trigo, pasturas, montes, caminos, cuerpos de agua y áreas urbanas. Por lo tanto, la serie debe interpretarse como un indicador agregado del estado de la cobertura vegetal del partido, que funciona como

proxy del desempeño general de los cultivos de verano, y no como una medición directa del cultivo de soja. Las diferencias de nivel entre partidos que se observan en la Figura 1 responden, en parte, a la distinta composición de usos del suelo dentro de cada polígono. Las implicancias de esta limitación se retoman en la sección 6.3.

La asociación entre el NDVI durante las etapas reproductivas y el rendimiento final se encuentra documentada en la literatura de teledetección agrícola. Un NDVI máximo más alto durante el período R3-R6 se asocia con mayor biomasa acumulada y, en consecuencia, con mayor producción de grano. De manera inversa, campañas donde el NDVI no alcanza valores elevados o donde se observa una caída abrupta durante el período crítico suelen corresponder a eventos de sequía o estrés térmico que reducen el rendimiento.

Para este proyecto se utilizaron datos del sensor MODIS (Moderate Resolution Imaging Spectroradiometer) a bordo del satélite Terra de la NASA, específicamente el producto MOD13Q1. Este producto provee compuestos de NDVI cada 16 días con una resolución espacial de 250 metros, y está disponible desde febrero del año 2000 de forma gratuita a través de la plataforma Google Earth Engine. La resolución de 250 metros es adecuada para el nivel de análisis por partido, ya que cada partido contiene miles de píxeles que se promedian para obtener un valor representativo de la cobertura vegetal del área.

Un valor de NDVI aislado es difícil de interpretar, porque mezcla dos componentes: el nivel estructural de cada partido, que depende de su composición de usos del suelo (lagunas, montes, pasturas, superficie agrícola), y el estado de la vegetación en la campaña en curso. Un NDVI de 0,60 puede ser bueno para un partido y bajo para otro.

Para aislar el segundo componente se utiliza la anomalía de NDVI: la diferencia entre el valor observado y el valor normal de ese partido en esa misma fecha del año. Una anomalía positiva indica que la vegetación está más vigorosa que lo habitual, y una negativa, que está por debajo. Este enfoque es estándar en el monitoreo de sequías y cultivos, y resulta especialmente informativo al inicio de la campaña. A fines de noviembre la soja recién emerge, y el satélite registra sobre todo pasturas, cultivos de invierno y rastrojos: si esa cobertura está más seca que lo normal, es una señal temprana de que el perfil del suelo llega a la siembra con menos agua.

2.3. Variables climáticas relevantes para el rendimiento de soja

El rendimiento de soja está determinado en gran medida por las condiciones climáticas que experimenta el cultivo durante su ciclo, particularmente durante las etapas reproductivas. Las principales variables climáticas que influyen sobre la producción de grano son las siguientes.

Precipitación. El agua es el factor más limitante para la producción de soja en condiciones de secano, que es el sistema predominante en la zona de estudio (sin riego). La soja requiere entre 450 y 800 mm durante su ciclo completo, con demanda máxima durante el período de floración y llenado de grano (R1-R6). Una deficiencia hídrica durante este período puede provocar aborto de flores, reducción del número de vainas y menor peso de grano. En la zona de estudio, las precipitaciones promedian entre 800 y 1000 mm anuales, pero su distribución a lo largo de la campaña varía significativamente entre años, lo que explica buena parte de la variabilidad interanual del rendimiento.

Temperatura. La soja es sensible tanto a temperaturas extremas como a la amplitud térmica. El rango óptimo para el desarrollo se ubica entre 20°C y 30°C. Temperaturas máximas superiores a 35°C durante la floración y el llenado de grano generan estrés térmico, que afecta la viabilidad del polen, reduce la tasa de fecundación y acorta el período de llenado. Este efecto se conoce como "golpe de calor" y es una de las principales causas de pérdidas de rendimiento en campañas donde las lluvias fueron adecuadas pero las temperaturas fueron excesivas.

Radiación solar. La radiación fotosintéticamente activa es la fuente de energía para la producción de biomasa. Mayor radiación durante las etapas vegetativas y reproductivas se asocia, en condiciones de buena disponibilidad hídrica, con mayor acumulación de materia seca y rendimiento potencial. Sin embargo, en situaciones de estrés hídrico, una radiación elevada puede agravar el déficit al incrementar la evapotranspiración.

Humedad relativa. Niveles altos de humedad relativa combinados con temperatura elevada pueden favorecer la aparición de enfermedades fúngicas foliares y reducir la radiación incidente (días nublados). Por otro lado, una humedad relativa muy baja intensifica la demanda evaporativa de la atmósfera y puede acelerar el consumo de agua disponible en el suelo.

Déficit de presión de vapor (VPD). La temperatura y la humedad relativa no actúan de forma independiente. El VPD combina ambas en un solo indicador: la diferencia entre la cantidad de vapor de agua que el aire podría contener a esa temperatura y la que

efectivamente contiene. Expresa la “demanda” de agua que la atmósfera ejerce sobre el cultivo.

La relación es no lineal. Una humedad relativa del 40% implica una demanda moderada a 20 °C y una demanda muy alta a 33 °C. Cuando el VPD es elevado, la soja cierra los estomas para limitar la pérdida de agua, y con ello reduce la fijación de carbono, el crecimiento y, durante el período crítico, el número de granos. Por eso el VPD es un indicador más directo del estrés hídrico atmosférico que la temperatura o la humedad por separado. Se calcula con la metodología estándar de la FAO (Allen et al., 1998) a partir de las temperaturas máxima, mínima y de punto de rocío.

Para este proyecto se utilizaron datos climáticos diarios provistos por la plataforma NASA POWER (Prediction Of Worldwide Energy Resources), que ofrece información a nivel de punto geográfico desde 1981, con una resolución espacial aproximada de 55 km. Las variables descargadas para cada partido fueron: temperatura media, máxima y mínima a 2 metros de altura, precipitación corregida, radiación solar incidente, humedad relativa y temperatura de punto de rocío. Esta última se utiliza para calcular el VPD.

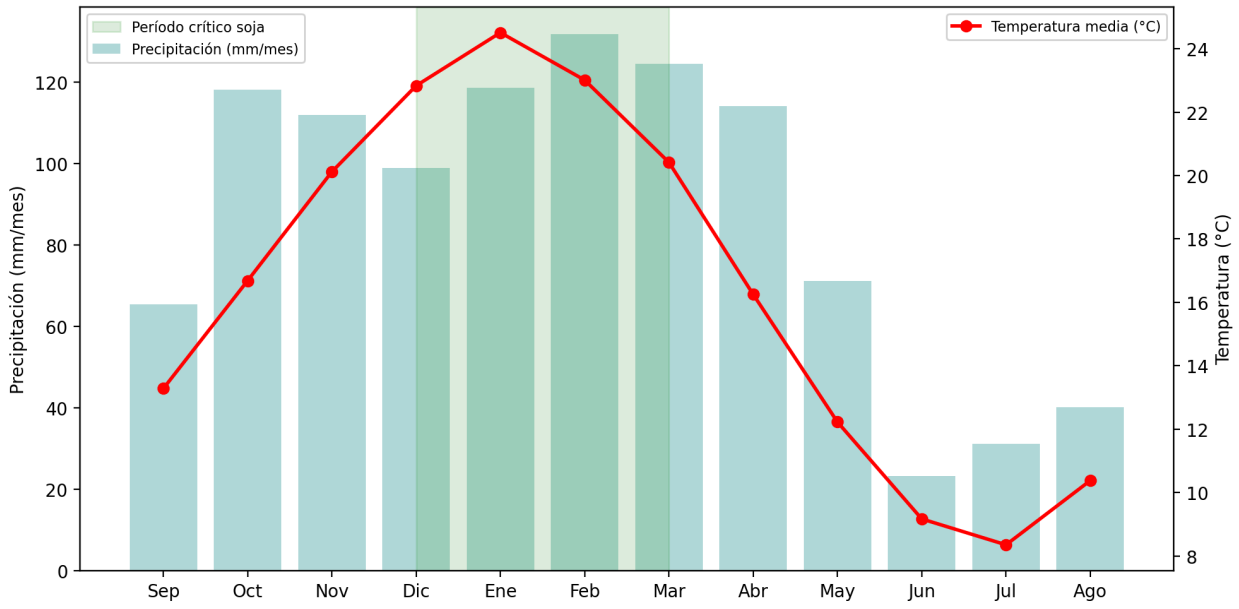


Figura 2. Ciclo anual promedio de temperatura media y precipitación en la zona de estudio (1999-2025). La zona sombreada indica la etapa reproductiva de la soja. Fuente: elaboración propia a partir de datos NASA POWER.

2.4. Modelos de Machine Learning para predicción de rendimiento

La predicción de rendimiento de cultivos a partir de datos de teledetección y variables climáticas es un campo de investigación activo, con abundante literatura que documenta el uso de técnicas de aprendizaje automático para este fin. El enfoque general consiste en construir un conjunto de variables predictoras (features) derivadas de datos satelitales y climáticos, y entrenar un modelo que aprenda la relación entre esas variables y el rendimiento observado en campañas históricas.

En este proyecto se evaluaron principalmente tres tipos de modelos con distintos niveles de complejidad:

Regresión lineal. Es el modelo más simple y se utiliza como línea de base (baseline) contra la cual comparar los demás. Asume una relación lineal entre las variables predictoras y el rendimiento. Su principal ventaja es la interpretabilidad directa de los coeficientes, pero tiene limitaciones cuando las relaciones entre variables son no lineales o cuando existen interacciones complejas entre predictores. Además, tiende a degradarse cuando el número de variables es grande en relación al número de observaciones, un fenómeno conocido como sobreajuste.

Random Forest. Es un método de ensamble basado en la construcción de múltiples árboles de decisión, cada uno entrenado con una muestra aleatoria de los datos y un subconjunto aleatorio de las variables. La predicción final se obtiene promediando las predicciones de todos los árboles. Esta aleatorización le otorga robustez frente al sobreajuste y capacidad para capturar relaciones no lineales sin necesidad de especificarlas previamente. Es uno de los modelos más utilizados en la literatura de predicción de rendimiento por su buen balance entre precisión, estabilidad y facilidad de implementación.

Gradient Boosting. A diferencia de Random Forest, que construye árboles independientes en paralelo, Gradient Boosting construye árboles de forma secuencial, donde cada nuevo árbol intenta corregir los errores del anterior. Este enfoque iterativo puede alcanzar mayor precisión en algunos casos, pero es más sensible a la configuración de hiperparámetros y al sobreajuste cuando el dataset es pequeño.

Un aspecto crítico en cualquier aplicación de estos modelos a datos temporales es el esquema de validación. En problemas donde las observaciones tienen un orden

cronológico, no es válido utilizar una partición aleatoria de los datos en entrenamiento y test, ya que eso permitiría al modelo "ver" información del futuro durante el entrenamiento. En su lugar, se emplea un esquema de validación temporal conocido como walk-forward, donde el modelo se entrena únicamente con campañas anteriores a la que se desea predecir. Este enfoque será descrito en detalle en la sección de Metodología.

Además de la precisión de la estimación puntual, en un problema de anticipación importa cuantificar su incertidumbre. Los **intervalos de predicción** indican un rango dentro del cual se espera que caiga el valor real con una probabilidad determinada. En este trabajo se construyen con un enfoque conformal (Lei et al., 2018): en lugar de suponer una distribución teórica para los errores, se utilizan los errores que el modelo efectivamente cometió al predecir campañas que no había visto. Su validez descansa en un supuesto simple: que los errores futuros se comporten como los pasados.

3. Fuentes de datos

3.1. Rendimiento histórico: MAGyP

La variable objetivo del modelo es el rendimiento de soja por partido, expresado en quintales por hectárea (qq/ha). Los datos fueron obtenidos del portal de datos abiertos del Ministerio de Agricultura, Ganadería y Pesca de la Nación (MAGyP), que publica la serie histórica de estimaciones agrícolas por cultivo, provincia y departamento/partido.

El dataset utilizado corresponde a la serie "Soja: siembra, cosecha, producción, rendimiento" y contiene, para cada partido y campaña, la superficie sembrada (en hectáreas), la superficie cosechada (en hectáreas), la producción total (en toneladas) y el rendimiento promedio (en kg/ha). Para este proyecto, el rendimiento fue convertido a qq/ha dividiendo por 100, ya que es la unidad de referencia habitual en el sector agrícola argentino.

Se filtraron los datos correspondientes a los cinco partidos de la zona de estudio para el período 2000-2024, resultando un total de 125 observaciones (5 partidos × 25 campañas). La Figura 3 muestra la evolución del rendimiento por partido a lo largo de este período.

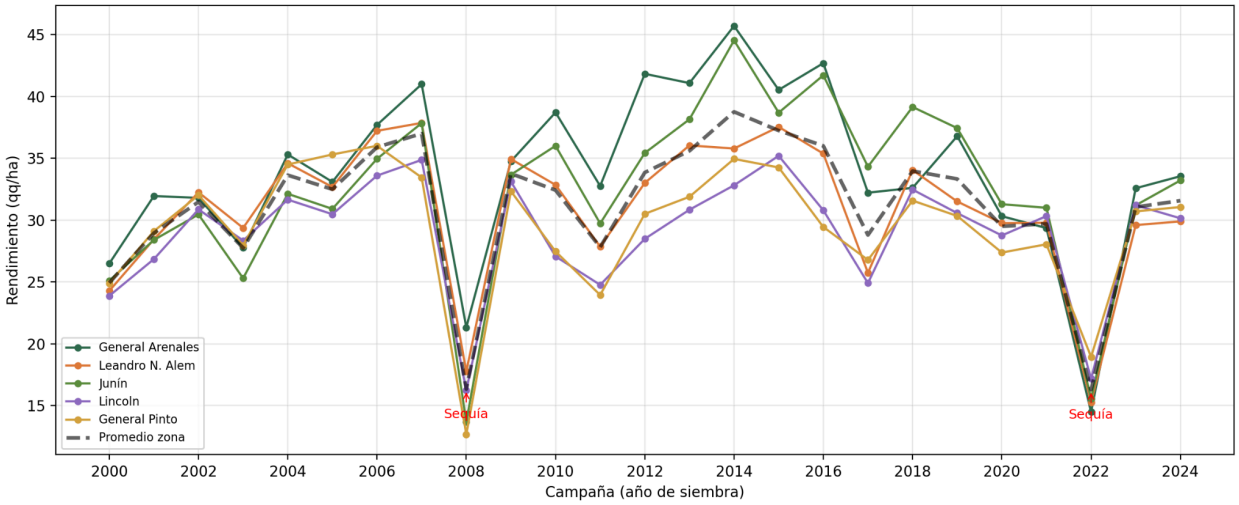


Figura 3. Evolución del rendimiento de soja por partido en la zona de estudio (campañas 2000-2024). La línea punteada negra representa el promedio de los cinco partidos. Se señalan las campañas afectadas por sequías severas. Fuente: elaboración propia a partir de datos MAGyP.

Los cinco partidos presentan una dinámica interanual similar: cuando las condiciones son favorables, los rendimientos suben en todos; cuando hay sequía, caen en todos. Esta correlación es esperable dada la proximidad geográfica y las condiciones climáticas compartidas. Sin embargo, se distinguen diferencias sistemáticas de nivel: General Arenales y Junín registran rendimientos superiores al promedio zonal, mientras que Lincoln y General Pinto se ubican generalmente por debajo, con una brecha que en campañas normales ronda los 4 qq/ha.

Este gradiente es coherente con la transición edáfica descrita en la sección 2.1: los partidos del este de la zona de estudio, sobre suelos Argiudoles de textura más fina, cuentan con mayor capacidad de retención hídrica que los del oeste, ubicados sobre suelos más arenosos de la Pampa Arenosa. A ello se suman posibles diferencias en la proporción de superficie destinada a soja de primera respecto de soja de segunda y en las prácticas de manejo predominantes en cada partido.

También se observa una tendencia positiva de largo plazo en el rendimiento, atribuible a la mejora genética de los cultivares y a la evolución de las prácticas de manejo a lo largo del período analizado. Esta tendencia tiene implicancias para el modelado que se discuten en la sección 6.3.

Las campañas 2008/09 y 2022/23 se destacan como las de peor desempeño en toda la

serie, con caídas del rendimiento promedio zonal a valores cercanos a 15 qq/ha, aproximadamente la mitad del promedio histórico. Ambas campañas estuvieron marcadas por eventos de sequía severa durante el período reproductivo del cultivo.

3.2. Datos climáticos: NASA POWER

Los datos climáticos diarios fueron obtenidos a través de la API de NASA POWER (Prediction Of Worldwide Energy Resources), un servicio gratuito que provee información meteorológica a nivel global a partir de modelos de reanálisis y observaciones satelitales. Se utilizó la comunidad "AG" (Agroclimatología), diseñada específicamente para aplicaciones agrícolas.

Para cada uno de los cinco partidos se descargaron datos diarios desde septiembre de 1999 hasta abril de 2025, utilizando como punto de referencia el centroide geográfico de cada partido. La resolución espacial del producto es de 0,5° de latitud por 0,625° de longitud (~55 km) para las variables meteorológicas, y de 1° × 1° para la radiación. A esa escala, los datos describen el clima regional de cada partido más que sus condiciones locales; las implicancias se discuten en la sección 4.1.

Las variables descargadas fueron las siguientes:

- **T2M:** temperatura media del aire a 2 metros de altura (°C).
- **T2M_MAX:** temperatura máxima diaria (°C).
- **T2M_MIN:** temperatura mínima diaria (°C).
- **PRECTOTCORR:** precipitación diaria corregida (mm/día).
- **ALLSKY_SFC_SW_DWN:** radiación solar incidente en superficie (MJ/m²/día).
- **RH2M:** humedad relativa a 2 metros de altura (%).
- **T2MDEW:** temperatura de punto de rocío (°C), utilizada para calcular el déficit de presión de vapor.

El dataset resultante contiene 46.870 registros (9.374 días × 5 partidos), sin valores faltantes tras reemplazar el código de dato ausente de NASA POWER (−999) por nulos, que resultaron ser inexistentes para el período y las variables seleccionadas.

3.3. Datos satelitales: MODIS vía Google Earth Engine

Los datos de NDVI fueron extraídos del producto MOD13Q1 del sensor MODIS (Moderate Resolution Imaging Spectroradiometer), a bordo del satélite Terra de la NASA. Este producto provee compuestos de NDVI cada 16 días con una resolución espacial de 250 metros, generados mediante la técnica de composición de máximo valor (MVC), que selecciona para cada píxel el valor más alto de NDVI dentro de la ventana de 16 días, minimizando así el efecto de nubes y condiciones atmosféricas adversas.

Los datos fueron accedidos a través de la plataforma Google Earth Engine, que permite el procesamiento de grandes volúmenes de información geoespacial de forma remota sin necesidad de descargar las imágenes completas. Para definir el área de extracción de cada partido se utilizaron los polígonos administrativos de la base de datos FAO GAUL (Global Administrative Unit Layers) nivel 2, disponible dentro de la plataforma.

Para cada imagen MODIS en el período 2000-2025, se calculó el NDVI promedio de todos los píxeles contenidos dentro de cada polígono de partido. Los valores crudos del producto MOD13Q1 se almacenan con un factor de escala de 0,0001, por lo que fueron multiplicados por dicho factor para obtener valores de NDVI en su rango real (−1 a 1).

El dataset resultante contiene 2.900 registros (580 observaciones por partido × 5 partidos), correspondientes a las composiciones de 16 días disponibles durante 25 años. No se detectaron valores faltantes en la serie.

Las composiciones del producto MOD13Q1 se generan en fechas fijas del año (días 1, 17, 33, etc.), lo que permite comparar cada composición con el mismo período de otros años. Sobre esta base se calculó el NDVI normal de cada partido para cada fecha del año como el promedio de las campañas 2000/01 a 2015/16, utilizado para la anomalía de NDVI (sección 4.2).

3.4. Índice de El Niño / La Niña: NOAA

Como información de contexto se utilizó el Índice Oceánico El Niño (ONI) publicado por el Climate Prediction Center de NOAA. El ONI es la anomalía de la temperatura superficial del mar en la región Niño 3.4 del Pacífico ecuatorial, promediada en trimestres móviles. Valores superiores a +0,5 °C indican condiciones de El Niño, e inferiores a −0,5 °C, de La Niña.

En la región pampeana, El Niño suele asociarse a primaveras y veranos más lluviosos y La Niña a condiciones más secas (Podestá et al., 1999). Se utilizó el valor del trimestre

agosto-septiembre-octubre, que se publica a principios de noviembre y está disponible al inicio de la campaña. Esta variable no forma parte del modelo final (sección 5.9).

4. Metodología

4.1. Zona de estudio y partidos seleccionados

La zona de estudio comprende cinco partidos del noroeste de la provincia de Buenos Aires: General Arenales, Leandro N. Alem, Junín, Lincoln y General Pinto. Estos partidos fueron seleccionados por conformar la zona de influencia operativa de una cooperativa agrícola de la región, lo que otorga al proyecto un anclaje concreto en un contexto de toma de decisiones real.

Los cinco partidos se ubican en un radio de aproximadamente 80 km entre sí y comparten características agroecológicas similares: suelos de aptitud agrícola, clima templado pampeano y predominancia de cultivos extensivos de soja, maíz y trigo. Esta homogeneidad relativa permite tratarlos como una unidad de análisis coherente, donde las diferencias de rendimiento entre partidos responden más a variaciones locales de suelo y manejo que a diferencias climáticas sustanciales.

Los centroides geográficos utilizados para la extracción de datos climáticos de cada partido son los siguientes:

Partido	Latitud	Longitud
General Arenales	-34,31	-61,10
Leandro N. Alem	-34,52	-61,38
Junín	-34,59	-60,95
Lincoln	-34,87	-61,53
General Pinto	-34,76	-61,89

Para la extracción de NDVI, en lugar de utilizar puntos, se emplearon los polígonos administrativos completos de cada partido provenientes de la base FAO GAUL nivel 2, calculando el promedio de todos los píxeles contenidos en cada polígono.

Cabe señalar una limitación derivada de la resolución de los datos climáticos. NASA

POWER provee sus parámetros meteorológicos sobre una grilla de 0,5° de latitud por 0,625° de longitud, y los parámetros de radiación sobre una grilla de 1° × 1°. Dado que los cinco partidos se ubican dentro de un radio aproximado de 80 km, varios centroides caen en celdas iguales o contiguas de esa grilla. En consecuencia, la información climática entre partidos es necesariamente similar por construcción, y la capacidad del modelo para discriminar entre ellos a partir de variables climáticas es limitada. Las diferencias de rendimiento entre partidos que el modelo logra capturar provienen, en mayor medida, de la señal de NDVI y de las diferencias estructurales de nivel presentes en la serie histórica.

4.2. Construcción del dataset: ventanas temporales y feature engineering

El dataset de modelado se construyó integrando las tres fuentes de datos descritas en la sección anterior. Cada observación corresponde a un par (partido, campaña), y la variable objetivo es el rendimiento de soja en qq/ha para esa combinación. El dataset final contiene 125 observaciones (5 partidos × 25 campañas).

El aspecto más relevante de la construcción del dataset es la definición de las ventanas temporales. Dado que el objetivo del proyecto no es solo predecir el rendimiento, sino determinar a partir de qué momento del ciclo la predicción es confiable, se definieron cinco ventanas acumulativas alineadas al ciclo fenológico de la soja:

Ventana	Período cubierto	Información disponible
oct_nov	Octubre - Noviembre	Solo datos de siembra y emergencia
oct_dic	Octubre - Diciembre	Siembra + primer mes de crecimiento vegetativo
oct_ene	Octubre - Enero	Hasta formación de vainas (R3-R4), inicio del período crítico
oct_feb	Octubre - Febrero	Hasta llenado de grano (R5-R6), período crítico completo
oct_mar	Octubre - Marzo	Hasta pre-cosecha

Cada ventana es acumulativa: la ventana oct_ene incluye toda la información de oct_nov y oct_dic, más los datos de enero. Esto simula el escenario real de uso del modelo: si

estamos en enero, solo disponemos de datos hasta ese momento.

Para cada ventana y cada par (partido, campaña), se calcularon las siguientes variables predictoras:

Variables climáticas (derivadas de NASA POWER):

- Precipitación acumulada en la ventana (mm).
- Temperatura media, máxima media y mínima media (°C).
- Radiación solar media (MJ/m²/día).
- Humedad relativa media (%).
- Cantidad de días con temperatura máxima superior a 35 °C (indicador de estrés térmico).
- Cantidad de días sin lluvia (precipitación menor a 1 mm).
- Déficit de presión de vapor medio (kPa), calculado diariamente como el promedio de la presión de saturación a temperatura máxima y mínima, menos la presión de vapor real derivada de la temperatura de punto de rocío (FAO-56).

Variables de NDVI (derivadas de MODIS):

- NDVI promedio en la ventana.
- NDVI máximo en la ventana.
- NDVI mínimo en la ventana.
- Desvío estándar del NDVI en la ventana (indicador de variabilidad).
- Pendiente de la serie de NDVI en la ventana (indicador de tendencia de crecimiento o deterioro del cultivo).
- Anomalía media de NDVI en la ventana: promedio de la diferencia entre cada composición y el NDVI normal del partido para esa fecha.
- Anomalía de NDVI a la fecha de corte: la anomalía de la última composición disponible, que refleja el estado de la vegetación en el momento de emitir la estimación.

En total, el dataset de modelado contiene 80 variables predictoras: 16 por ventana (9 climáticas y 7 satelitales) a lo largo de las cinco ventanas temporales. La cantidad de variables disponibles crece con cada ventana: la ventana oct_nov cuenta con 16, la ventana oct_ene con 48 y la ventana oct_mar con las 80.

El NDVI normal utilizado para la anomalía se calculó únicamente con las campañas 2000/01 a 2015/16. Esas campañas forman parte del entrenamiento en todas las iteraciones de la validación (sección 4.3), por lo que la anomalía nunca incorpora información de las campañas que se utilizan para evaluar el modelo.

4.3. Diseño de la validación: walk-forward temporal

En problemas de predicción con datos temporales, la validación del modelo requiere un tratamiento particular. A diferencia de una partición aleatoria de los datos en entrenamiento y test, que es válida cuando las observaciones son independientes entre sí, en un contexto temporal es imprescindible respetar la dirección del tiempo: el modelo solo puede entrenarse con campañas pasadas y evaluarse sobre campañas futuras. Utilizar una partición aleatoria permitiría que el modelo acceda a información del futuro durante el entrenamiento, inflando artificialmente las métricas de desempeño.

Para este proyecto se implementó un esquema de validación conocido como walk-forward o ventana expandible. El procedimiento es el siguiente:

1. Se entrena el modelo con todas las campañas desde 2000 hasta 2015 y se predice la campaña 2016.
2. Se amplía el conjunto de entrenamiento incorporando la campaña 2016, y se predice la campaña 2017.
3. Se repite este proceso hasta predecir la campaña 2024.

Este esquema genera 9 campañas de test (2016 a 2024), con 5 predicciones por campaña (una por partido), totalizando 45 predicciones fuera de muestra. Cada predicción fue generada sin que el modelo haya visto en ningún momento el rendimiento real de esa campaña ni de campañas posteriores.

La elección de 2016 como primera campaña de test responde a la necesidad de garantizar un conjunto de entrenamiento inicial suficiente: 16 campañas (2000-2015) con 5 partidos proporcionan 80 observaciones para el primer entrenamiento, lo cual es adecuado para los modelos evaluados.

Las métricas de evaluación utilizadas fueron:

- **MAE (Mean Absolute Error):** promedio del valor absoluto de los errores. Indica el error típico de predicción en las mismas unidades que la variable objetivo (qq/ha). Es la métrica más interpretable para el usuario final.
- **RMSE (Root Mean Squared Error):** raíz cuadrada del promedio de los errores al cuadrado. Penaliza más los errores grandes que el MAE.
- **R^2 (coeficiente de determinación):** proporción de la variabilidad del rendimiento que el modelo logra explicar. Un valor de 1 indica predicción perfecta; un valor de 0 indica que el modelo no supera a predecir siempre el

promedio.

- **Acierto direccional:** proporción de predicciones en las que el modelo anticipa correctamente si el rendimiento se ubicará por encima o por debajo del promedio histórico del partido, calculado con las campañas anteriores. Es la métrica más alineada con el uso previsto del modelo como herramienta de alerta temprana.

Cada estimación se compara siempre contra el rendimiento final de la campaña. En consecuencia, el error de las ventanas tempranas incluye no solo las limitaciones del modelo, sino también los eventos que ocurren después de la fecha de corte y que ninguna herramienta puede anticipar, como una sequía en febrero. Esta es la comparación relevante para el uso previsto: la decisión se toma con la información disponible en ese momento, y lo que importa es cuánto se aparta el resultado final de lo anticipado.

4.4. Modelos evaluados

Se evaluaron tres modelos de distinta complejidad, con el objetivo de comparar el trade-off entre simplicidad e interpretabilidad por un lado, y capacidad predictiva por el otro.

Regresión Lineal fue utilizada como baseline. No se aplicó regularización. Todas las variables fueron estandarizadas previamente (media 0, desvío 1) para homogeneizar las escalas.

Random Forest fue configurado con 100 árboles, profundidad máxima de 5 niveles y semilla aleatoria fija (42) para reproducibilidad. La limitación de profundidad busca controlar el sobreajuste en un dataset de tamaño moderado. Dado que el resultado del Random Forest varía levemente según la semilla, las comparaciones entre variantes de la sección 5.9 se realizaron promediando las predicciones de cinco semillas distintas.

Gradient Boosting fue configurado con 100 estimadores, profundidad máxima de 3 niveles y tasa de aprendizaje de 0,1. Con esta configuración, que utiliza todas las observaciones y todas las variables en cada árbol, el resultado no depende de la semilla aleatoria.

Los tres modelos fueron evaluados bajo el mismo esquema walk-forward descrito anteriormente, y para cada una de las cinco ventanas temporales, generando un total de 15 combinaciones modelo-ventana. En todos los casos, las variables predictoras fueron

estandarizadas utilizando únicamente los datos de entrenamiento de cada iteración, para evitar filtración de información.

Una vez establecido el modelo base, se evaluaron variables agroclimáticas adicionales, otras estructuras de variables, otros algoritmos y variantes de la señal satelital. El procedimiento y los criterios de decisión se describen en la sección 4.5, y los resultados se presentan en las secciones 5.9 y 5.10.

4.5. Criterio para evaluar mejoras

Con solo nueve campañas de test, una diferencia pequeña en el error puede deberse al azar: cambiar la semilla del Random Forest mueve el MAE algunas décimas. Para evitar adoptar mejoras aparentes, cada variante se comparó contra el modelo vigente bajo cuatro criterios:

1. **Diferencia de MAE** respecto del modelo vigente, con las mismas campañas y partidos de test.
2. **Intervalo de confianza del 80% de esa diferencia**, por bootstrap de campañas: se re-sortean 2.000 veces las nueve campañas de test y se recalcula la diferencia. Se sortean campañas enteras, y no partidos individuales, porque los cinco partidos de una misma campaña comparten clima y sus errores están correlacionados.
3. **Cantidad de campañas en las que la variante mejora**, para distinguir una mejora general de una concentrada en uno o dos años.
4. **Diferencia excluyendo la campaña 2022/23**, para verificar que la mejora no dependa exclusivamente de la sequía más extrema de la serie.

Una mejora se consideró concluyente cuando el intervalo de confianza quedó enteramente por debajo de cero, la variante mejoró en al menos seis de las nueve campañas y la mejora se mantuvo sin 2022/23. Para la última comparación (estructura de variables y algoritmo) se fijó además, antes de observar los resultados, una regla de cambio: modificar el modelo solo si una alternativa mejoraba de forma concluyente en al menos dos de los cinco cortes y no empeoraba en ninguno.

Este procedimiento no elimina un riesgo inherente: cuantas más variantes se prueban sobre las mismas campañas, mayor es la probabilidad de que alguna parezca mejor por azar. Por eso los resultados de la sección 5.9 deben leerse como evidencia favorable, a confirmar con campañas nuevas.

4.6. Intervalos de predicción

Cada estimación se acompaña de un intervalo de predicción del 80%, construido con el método conformal a partir de los residuos fuera de muestra del walk-forward (diferencia entre rendimiento real y predicho):

- **A nivel de partido**, se utilizan los 45 residuos de cada ventana. Los límites del intervalo son los cuantiles correspondientes de esos residuos, con la corrección de muestra finita del método conformal, que ensancha el intervalo cuando hay pocos datos en lugar de prometer una cobertura que no se puede garantizar.
- **A nivel de zona**, se utiliza el residuo promedio de cada campaña (nueve valores). Los cinco partidos se equivocan en el mismo sentido en una misma campaña, por compartir clima, y promediar sus errores como si fueran independientes produciría un intervalo engañosamente angosto. Con nueve valores, el intervalo zonal equivale al rango de errores observado.
- **No se impone simetría:** los límites inferior y superior surgen por separado de los errores observados.

Se eligió un nivel del 80% y no del 95% porque, con 45 residuos, un intervalo del 95% quedaría determinado por uno o dos casos extremos y resultaría demasiado amplio para orientar decisiones.

Para verificar que el 80% se cumpla en la práctica, se realizó un control causal: para cada campaña de test se calculó el intervalo usando solo los errores de campañas anteriores (con un mínimo de tres), y se registró si el rendimiento real cayó dentro de ese intervalo.

5. Resultados

5.1. Análisis exploratorio de los datos

Antes de entrenar los modelos, se realizó un análisis exploratorio para verificar la coherencia de los datos y comprender las relaciones entre las variables predictoras y el rendimiento.

La Figura 4 muestra la relación entre tres variables clave y el rendimiento de soja para la ventana oct_feb (octubre a febrero), que cubre el período crítico completo del cultivo.

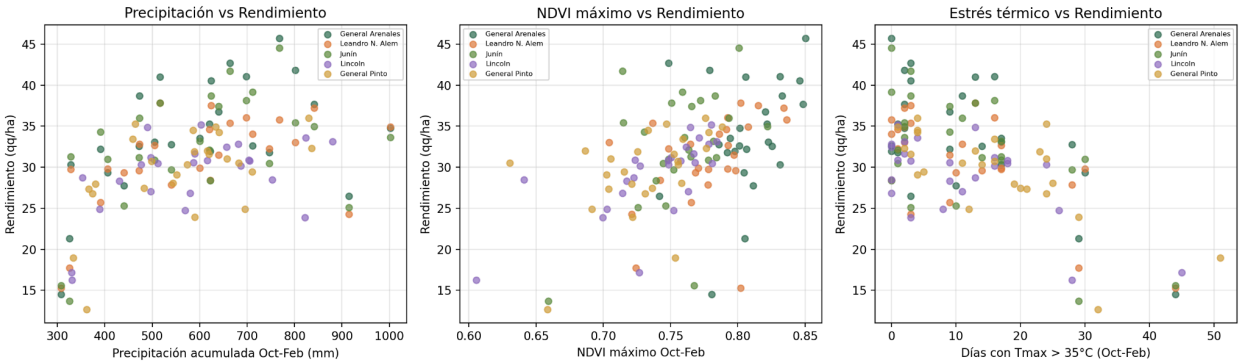


Figura 4. Relación entre variables predictoras clave (ventana octubre-febrero) y rendimiento de soja por partido. Izquierda: precipitación acumulada. Centro: NDVI máximo. Derecha: días con temperatura máxima superior a 35°C. Fuente: elaboración propia.

Se observan patrones consistentes en las tres variables. La precipitación acumulada muestra una asociación positiva con el rendimiento, con un comportamiento de tipo umbral: la mayoría de las campañas con menos de 400 mm acumulados entre octubre y febrero registraron rendimientos inferiores a 20 qq/ha, correspondientes a campañas de sequía severa, aunque se observan casos puntuales por debajo de ese umbral con rendimientos cercanos al promedio. Por encima de los 500 mm, la relación se atenúa marcadamente y la dispersión aumenta, lo que sugiere que una vez cubierto el requerimiento hídrico básico otros factores pasan a ser limitantes.

El NDVI máximo presenta una asociación positiva con el rendimiento: las campañas donde la cobertura vegetal alcanzó mayor vigor (NDVI superior a 0,78) tienden a registrar rendimientos superiores a 30 qq/ha. Se observan algunos casos con NDVI alto y rendimiento bajo, que podrían corresponder a campañas donde el cultivo se desarrolló adecuadamente durante la fase vegetativa pero sufrió un evento adverso durante el llenado de grano.

La cantidad de días con temperatura máxima superior a 35 °C presenta la asociación bivariada más clara de las tres: a medida que aumentan los días de calor extremo, el rendimiento disminuye. Por encima de los 30 días de estrés térmico entre octubre y febrero, los rendimientos se ubican en general por debajo de 20 qq/ha, con algunas excepciones en torno a ese umbral.

Cabe aclarar que estas relaciones son asociaciones bivariadas observadas en los datos y no permiten, por sí solas, establecer relaciones causales ni aislar el efecto individual de

cada variable, dado que las tres se encuentran correlacionadas entre sí: las campañas secas suelen ser también las más cálidas y las de menor desarrollo vegetativo. Su valor en esta instancia es confirmar que las variables seleccionadas contienen información relevante, y que existen patrones no lineales, como el umbral de precipitación, que justifican el uso de modelos capaces de capturarlos.

Para cuantificar estas asociaciones se calculó el coeficiente de correlación de Pearson entre cada variable de la ventana oct_ene y el rendimiento. De las 48 variables, 44 presentan una correlación estadísticamente significativa ($p < 0,05$). Las asociaciones más fuertes corresponden a la anomalía media de NDVI hasta enero ($r = +0,64$), los días de calor extremo en octubre-noviembre ($r = −0,62$), el NDVI medio hasta enero ($r = +0,58$), los días de calor extremo hasta enero ($r = −0,57$) y hasta diciembre ($r = −0,54$), y el VPD medio hasta enero ($r = −0,52$), todas con el signo esperable desde el punto de vista agronómico. Las dos variables incorporadas en esta versión figuran entre las más asociadas al rendimiento: la anomalía de NDVI ocupa el primer lugar, y el VPD muestra una relación negativa consistente en las tres ventanas (r entre $−0,47$ y $−0,52$), es decir, a mayor demanda evaporativa, menor rendimiento.

Las únicas variables sin asociación significativa son el NDVI crudo de octubre-noviembre (medio, máximo y desvío) y los días sin lluvia de ese período, cuando el cultivo recién se implanta. Este contraste es relevante: mientras el NDVI crudo de noviembre no se relaciona con el rendimiento ($r = +0,18$), la anomalía de NDVI a fines de noviembre sí lo hace ($r = +0,51$). A esa altura de la campaña, el valor absoluto del NDVI refleja sobre todo la composición de usos del suelo de cada partido, mientras que su desvío respecto de lo normal refleja el estado de la vegetación y, de forma indirecta, la humedad con que el suelo llega a la siembra. Este resultado anticipa lo que se observa en la curva de anticipación (sección 5.3).

Dado que los cinco partidos de una misma campaña comparten condiciones climáticas, las observaciones no son completamente independientes y los p-valores deben leerse como orientativos; la magnitud de las correlaciones, en cambio, es robusta.

5.2. Comparación de modelos por ventana temporal

Se entrenaron los tres modelos (Regresión Lineal, Random Forest y Gradient Boosting) para cada una de las cinco ventanas temporales, evaluándolos bajo el esquema de validación walk-forward descrito en la sección anterior. La Tabla 1 resume las métricas

obtenidas.

Ventana	Modelo	MAE (qq/ha)	RMSE (qq/ha)	R^2
—	**Baseline climatológico**	**4.04**	**6.15**	**-0.047**
oct_nov	Gradient Boosting	2.37	2.88	0.77
oct_nov	Random Forest	2.42	3.19	0.718
oct_nov	Regresión Lineal	4.51	6.26	-0.084
oct_dic	Gradient Boosting	2.55	3.22	0.712
oct_dic	Random Forest	2.64	3.32	0.695
oct_dic	Regresión Lineal	3.25	4.18	0.517
oct_ene	Gradient Boosting	2.68	3.46	0.67
oct_ene	Random Forest	3.01	3.76	0.609
oct_ene	Regresión Lineal	6.57	7.86	-0.708
oct_feb	Gradient Boosting	2.32	3.18	0.721
oct_feb	Random Forest	2.94	3.7	0.621
oct_feb	Regresión Lineal	7.62	8.66	-1.072
oct_mar	Gradient Boosting	2.73	3.66	0.629
oct_mar	Random Forest	3.02	3.85	0.589
oct_mar	Regresión Lineal	24.73	34.13	-31.218

Tabla 1. Métricas de evaluación por modelo y ventana temporal (validación walk-forward, campañas 2016-2024).

Como referencia se incluyó un baseline climatológico: predecir, para cada partido y campaña, el promedio histórico de rendimiento de ese partido hasta la campaña anterior. Este baseline obtuvo un MAE de 4,04 qq/ha y un R^2 de −0,047. Conviene precisar qué representa: el promedio histórico es una referencia fija, que no incorpora ninguna información sobre la campaña en curso. En enero predice lo mismo que en octubre, haya llovido mucho o poco. El modelo, en cambio, actualiza su estimación con las condiciones observadas, y esa es la capacidad que se busca evaluar.

Random Forest y Gradient Boosting superaron al baseline en todas las ventanas. En la ventana oct_nov, Random Forest alcanzó un MAE de 2,42 qq/ha, un 40% menos que el baseline; en la ventana oct_ene, 3,01 qq/ha, un 25% menos.

En esta evaluación, Gradient Boosting obtuvo un error algo menor que Random Forest en las cinco ventanas (entre 2,32 y 2,73 qq/ha). Se trata de una única comparación sobre nueve campañas. Por eso se sometió a la prueba más exigente descrita en la sección 4.5, cuyo resultado se presenta en la sección 5.9: la mejora resultó concluyente en uno solo de los cinco cortes y no alcanzó la regla de cambio. Random Forest se mantiene como

modelo principal.

La Regresión Lineal solo superó al baseline en la ventana oct_dic (MAE de 3,25 qq/ha; R^2 de 0,517). En el resto de las ventanas su desempeño fue inferior a una predicción constante, con R^2 negativos que se profundizan a medida que se agregan variables, hasta −31,2 en oct_mar. Este comportamiento es esperable: con decenas de variables predictoras y solo 125 observaciones, un modelo lineal sin regularización sobreajusta los datos de entrenamiento y generaliza peor que el promedio.

5.3. Curva de anticipación: error vs. momento de predicción

El resultado central de este proyecto es la relación entre el momento del ciclo en que se realiza la predicción y la precisión obtenida. La Figura 5 muestra esta curva de anticipación para el modelo Random Forest.

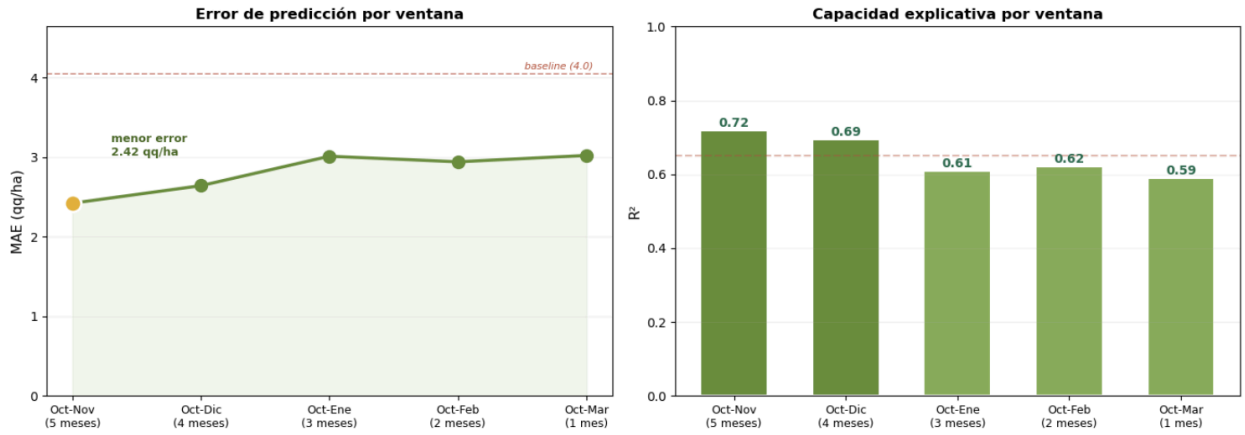


Figura 5. Error medio absoluto (izquierda) y coeficiente de determinación R^2 (derecha) del modelo Random Forest para cada ventana temporal. La línea punteada indica el error del baseline climatológico (4,04 qq/ha) y el punto dorado señala la ventana de menor error. Fuente: elaboración propia.

El error del modelo es bajo desde la primera ventana. Con datos hasta noviembre, el MAE es de 2,42 qq/ha y el R^2 de 0,72; con datos hasta diciembre, 2,64 qq/ha y 0,70; hasta enero, 3,01 qq/ha y 0,61; hasta febrero, 2,94 qq/ha y 0,62; y con datos hasta marzo, 3,02 qq/ha y 0,59. En todas las ventanas el modelo supera al baseline climatológico (4,04 qq/ha).

A diferencia de la versión anterior del modelo, donde el error disminuía de forma

gradual a lo largo de la campaña, la incorporación de la anomalía de NDVI y el VPD hizo que la ventana más temprana sea la de menor error. Este resultado contradice la intuición de que más información siempre produce mejores estimaciones, por lo que se analizó con detalle. Tres elementos permiten interpretarlo.

Primero, la señal más predictiva está disponible temprano. A fines de noviembre la soja de primera recién emerge, y el satélite registra principalmente pasturas, cultivos de invierno y rastrojos. Si esa cobertura está más seca que lo normal para la fecha, es una señal de que el perfil del suelo llega a la siembra con menos agua, y ese estado condiciona buena parte del resultado de la campaña. Los datos respaldan esta lectura: el NDVI crudo de noviembre no se correlaciona con el rendimiento (r = +0,18), pero su anomalía sí (r = +0,51; sección 5.1). Además, incluso en el modelo de la ventana oct_ene, la anomalía de NDVI a fines de noviembre es la tercera variable más importante (sección 5.6).

Segundo, no se trata de un exceso de variables. Una explicación posible era que el modelo se "diluyera" al acumular variables de varias ventanas. Se descartó: usar solo las variables de cada corte empeoró los resultados (sección 5.9), lo que indica que las variables de los cortes anteriores aportan información sobre la trayectoria de la campaña.

Tercero, la información posterior ayuda solo en campañas puntuales. El clima de diciembre a marzo es decisivo en campañas con eventos tardíos, como la sequía de febrero-marzo de 2017/18, que solo se detecta en el corte de febrero (sección 5.4). Pero en el promedio de las nueve campañas de test ese aporte no compensa la dispersión adicional, y el error medio no baja.

Corresponde precisar el alcance de este resultado. Con nueve campañas de test, una o dos campañas atípicas pesan mucho en el promedio, y la diferencia entre 2,42 qq/ha (noviembre) y 3,01 qq/ha (enero) no es estadísticamente distinguible. La conclusión robusta no es que noviembre sea estrictamente mejor que enero, sino que **una estimación temprana ya resulta tan precisa como una tardía**. Además, la estimación de noviembre tiene un punto ciego propio: la soja de segunda, que también forma parte del rendimiento informado por el MAGyP, todavía no se sembró.

Desde el punto de vista operativo, esto cambia el momento útil del sistema. A fines de noviembre, unos cinco meses antes de la cosecha, es posible disponer de una primera estimación con un error medio de alrededor de 2,4 qq/ha. Las estimaciones de los meses siguientes funcionan como actualizaciones que confirman o corrigen esa primera señal

con lo ocurrido durante el período crítico (ver criterio de uso en la sección 6.2).

5.4. Acierto direccional y lectura por campaña

Dado que el objetivo del modelo es anticipar cómo viene la campaña más que estimar un valor exacto, se evaluó su capacidad para anticipar la dirección del resultado: si el rendimiento de cada partido se ubicaría por encima o por debajo de su promedio histórico. Con la ventana oct_ene, el modelo acertó la dirección en 31 de las 45 predicciones fuera de muestra (69%). Un test binomial contra una predicción al azar (50%) indica que el resultado es estadísticamente significativo (p = 0,008), con la misma salvedad sobre la dependencia entre partidos de una misma campaña señalada en la sección 5.1. Con datos hasta fines de noviembre, el acierto fue de 31 de 45 (69%; p = 0,0080)

Esta métrica trata igual un error grosero que uno marginal: una campaña que terminó 0,2% por debajo del promedio y que el modelo estimó apenas por encima cuenta como error. Por eso se complementó con una lectura por campaña, a nivel zonal, que se muestra en la Figura 6.

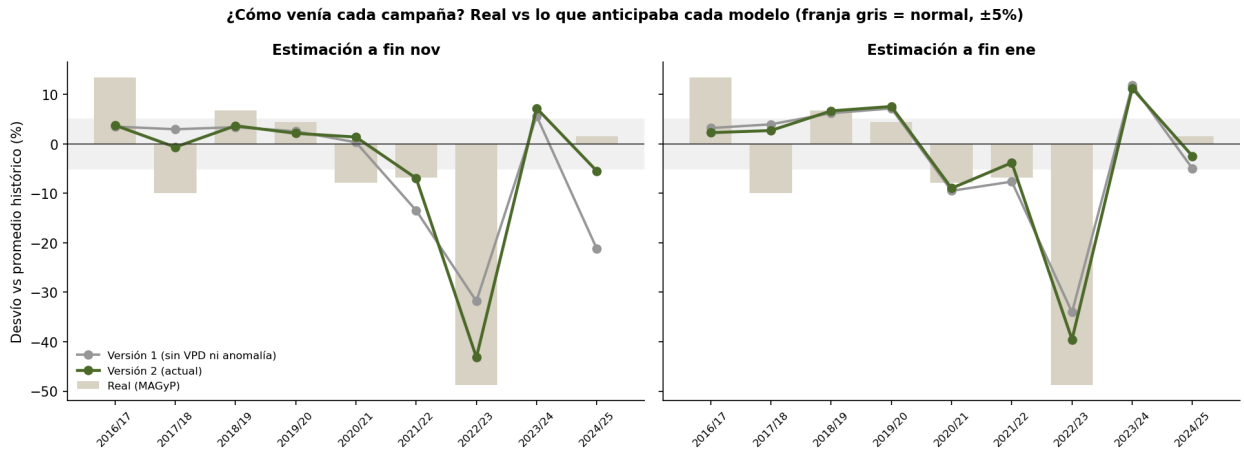


Figura 6. Desvío del rendimiento zonal respecto del promedio histórico para cada campaña de test: real (barras, MAGyP) y anticipado por el modelo (líneas) con datos hasta fines de noviembre (izquierda) y hasta fines de enero (derecha). La línea gris corresponde a la versión anterior del modelo y la verde a la actual. La franja gris indica el rango considerado normal (±5%). Fuente: elaboración propia.

De las nueve campañas de test, seis se apartaron más de un 5% de lo normal. Con datos hasta fines de enero, el modelo anticipó correctamente el sentido del desvío en cinco de ellas.

La excepción fue 2017/18, que terminó un 10% por debajo del promedio mientras el modelo estimaba una campaña levemente superior a lo normal. La sequía de esa campaña afectó principalmente febrero y marzo, después del corte de enero: es un error que ninguna herramienta podía evitar con la información disponible. Con datos hasta fines de febrero, el modelo ya la identificó como una campaña por debajo de lo normal. En total, de las cuatro campañas que terminaron un 5% o más por debajo del promedio, el modelo las marcaba en esa dirección en tres a fines de enero y en las cuatro a fines de febrero.

La diferencia con la versión anterior es más visible en las estimaciones de noviembre:

- **2022/23.** El rendimiento terminó un 49% por debajo de lo normal. A fines de noviembre el modelo actual anticipaba una caída del 43%, contra un 32% de la versión anterior.
- **2024/25.** La versión anterior emitía una falsa alarma a fines de noviembre: anticipaba una caída del 21% en una campaña que terminó en valores normales (+1,5%). El modelo actual estimaba −5,5%; también erró, pero con un desvío mucho menor.

El análisis también muestra una tendencia sistemática a subestimar la magnitud de los desvíos. La campaña 2016/17 terminó un 13% por encima de lo normal y el modelo estimaba entre +2% y +4%. Este comportamiento responde a la limitación de Random Forest para estimar valores fuera del rango observado (sección 6.3).

En 2022/23, la campaña de peor desempeño del período de test, el promedio histórico erró en promedio 15,5 qq/ha por partido, mientras que el modelo, con datos hasta enero, redujo ese error a 3,8 qq/ha. Son precisamente esas campañas las que justifican disponer de una estimación temprana.

5.5. Intervalos de predicción

Siguiendo el procedimiento descrito en la sección 4.6, se construyeron intervalos de predicción del 80% para cada ventana. La Tabla 2 muestra los límites de los intervalos, que se suman a la estimación puntual, y la cobertura verificada con el control causal: el porcentaje de casos en que el rendimiento real cayó dentro del intervalo calculado solo

con campañas anteriores.

Intervalos de predicción (conformal, 80%) y cobertura en validación walk-forward

Ventana	Intervalo partido (qq/ha)	Ancho	Intervalo zonal (qq/ha)	Ancho	Cobertura verificada
Fin nov	−4,6 / +3,8	8,4	−3,1 / +3,1	6,3	**80% (24/30)**
Fin dic	−5,6 / +3,7	9,2	−4,6 / +2,5	7,2	**87% (26/30)**
Fin ene	−5,7 / +3,4	9,1	−4,2 / +3,7	7,8	**77% (23/30)**
Fin feb	−5,3 / +4,0	9,4	−3,6 / +3,9	7,5	**87% (26/30)**
Fin mar	−6,3 / +3,6	9,9	−3,9 / +3,8	7,7	**87% (26/30)**

Tabla 2. Intervalos de predicción del 80% por ventana, expresados como valores a sumar a la estimación puntual, y cobertura verificada en la validación walk-forward (campañas 2019/20 a 2024/25: las tres primeras campañas de test se reservan para calibrar el intervalo). Fuente: elaboración propia.

Cobertura. La cobertura verificada osciló entre el 77% y el 87%, en línea con el nivel nominal del 80%. El intervalo cumple lo que promete sin ser excesivamente conservador.

Asimetría a nivel partido. En todas las ventanas, el margen hacia abajo es mayor que hacia arriba: con datos hasta enero, por ejemplo, el rendimiento real de un partido puede ubicarse hasta 5,7 qq/ha por debajo de la estimación, pero solo hasta 3,4 qq/ha por encima. Este comportamiento tiene una lectura agronómica clara: las sequías y los golpes de calor provocan caídas de rendimiento mucho más profundas que las subas que produce una campaña favorable. A nivel zonal, en cambio, los intervalos resultan aproximadamente simétricos, salvo en diciembre.

Errores correlacionados. La correlación media de los errores entre partidos de una misma campaña fue de 0,36 (ventana oct_ene). Es menor que en la versión anterior del modelo (0,54), lo que sugiere que la anomalía de NDVI permite diferenciar mejor la situación de cada partido. Igual confirma que los partidos tienden a equivocarse en el mismo sentido, y justifica construir el intervalo zonal a partir del error promedio de cada campaña.

Campañas fuera del intervalo. Las campañas en las que la mayoría de los partidos quedaron fuera del intervalo fueron 2024/25, en las ventanas de noviembre y diciembre (una campaña que terminó normal y para la que el modelo anticipaba una caída; sección 5.4), y 2022/23, desde enero en adelante (la sequía más severa del período, cuyo error superó todo lo observado en las campañas de calibración). Es decir, los años más extremos de la serie. El intervalo debe leerse, por lo tanto, como un piso de

incertidumbre: refleja bien la variabilidad de las campañas habituales, pero un evento sin precedentes en la serie puede quedar fuera de él.

5.6. Interpretabilidad: Importancia de variables

Para comprender qué variables tienen mayor influencia sobre las predicciones del modelo, se analizó la importancia relativa de cada feature según el criterio de Random Forest, que mide cuánto contribuye cada variable a la reducción del error de predicción a lo largo de todos los árboles del ensamble.

La Figura 7 muestra las 15 variables más importantes del modelo entrenado con la ventana oct_ene.

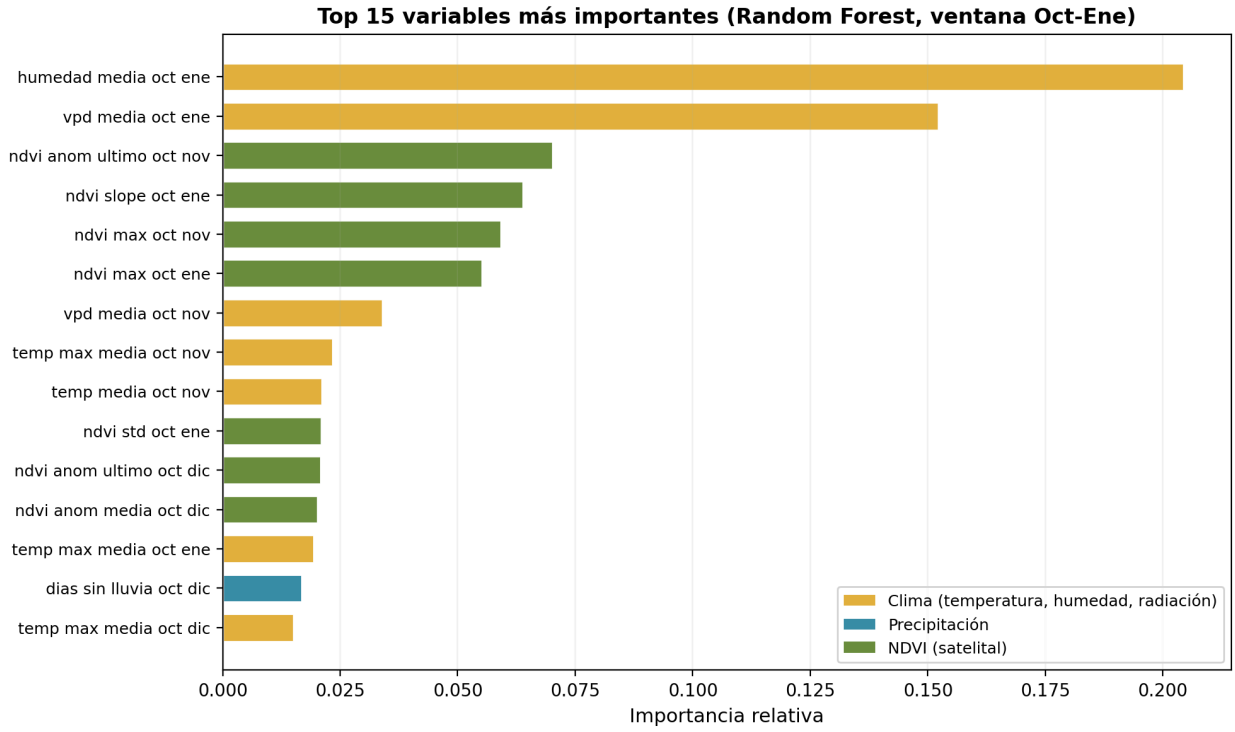


Figura 7. Top 15 variables con mayor importancia relativa en el modelo Random Forest (ventana octubre-enero). El color distingue el tipo de fuente: dorado para variables

climáticas (incluido el VPD), verde para NDVI satelital (incluida su anomalía) y celeste para precipitación. Fuente: elaboración propia.

Las dos variables con mayor importancia relativa son la humedad relativa media entre octubre y enero, con cerca del 20% de la importancia total, y el VPD medio del mismo período, con alrededor del 15%. Ambas miden la misma dimensión del ambiente: la demanda de agua que la atmósfera ejerce sobre el cultivo. Valores bajos de humedad o altos de VPD identifican veranos secos y calurosos, con mayor consumo del agua del perfil del suelo y cierre de estomas. Juntas concentran algo más de un tercio de la importancia del modelo, y actúan como un detector de campañas con déficit hídrico, que son las que concentran las mayores pérdidas de rendimiento en la serie analizada. En la versión anterior, la humedad relativa sola concentraba cerca del 40%. Al incorporar el VPD, esa señal se reparte entre ambas variables, lo que es esperable por su fuerte correlación.

En tercer lugar aparece la anomalía de NDVI a fines de noviembre. Que una variable del primer corte de la campaña figure entre las tres más importantes de un modelo que dispone de información hasta enero refuerza lo observado en la curva de anticipación (sección 5.3): el estado de la vegetación respecto de lo normal al inicio de la campaña contiene información relevante sobre el resultado final.

A continuación aparecen tres variables satelitales: la pendiente del NDVI entre octubre y enero y el NDVI máximo hasta noviembre y hasta enero. La pendiente refleja la velocidad con que la cobertura vegetal se desarrolló a lo largo de la campaña: un aumento rápido del NDVI indica una buena implantación y cierre del canopeo, mientras que una pendiente baja puede señalar un desarrollo lento o condiciones adversas. El NDVI máximo, por su parte, refleja el pico de vigor alcanzado, asociado a mayor biomasa acumulada y mayor potencial de rendimiento. En total, siete de las quince variables más importantes son satelitales, cuatro de ellas anomalías o pendientes, lo que indica que la información de NDVI aporta capacidad predictiva propia, complementaria a la climática.

La presencia del VPD y de la anomalía de NDVI entre las tres variables más importantes es consistente con la mejora observada al incorporarlas (sección 5.9): ambas resumen en un solo indicador información que el modelo anterior debía reconstruir a partir de varias variables correlacionadas.

Corresponde señalar dos precauciones en la lectura de estos resultados. En primer lugar, la importancia de variables en Random Forest mide la contribución de cada predictor a la reducción del error dentro del modelo, y no constituye evidencia de causalidad: indica

qué variables resultan más útiles para predecir, no cuáles determinan biológicamente el rendimiento. En segundo lugar, esta métrica se reparte de manera arbitraria entre variables correlacionadas entre sí. Dado que humedad relativa, VPD, temperatura y radiación están fuertemente correlacionadas, el hecho de que la humedad y el VPD concentren más de un tercio de la importancia no implica que sean los factores dominantes por sí solos: es probable que estén absorbiendo la señal compartida de todo el grupo de variables asociadas al balance hídrico estival. Esto explica también por qué los días de calor extremo, que muestran una de las correlaciones más fuertes con el rendimiento (sección 5.1), no figuran entre las variables más importantes del modelo: su información ya está contenida en la humedad, el VPD y la temperatura.

Un aspecto relevante es que las variables con mayor peso son medibles a medida que avanza la campaña: humedad y temperatura están disponibles tanto en NASA POWER como en las estaciones meteorológicas que ya operan algunas cooperativas de la zona, y el NDVI se actualiza cada 16 días de forma gratuita a través de Google Earth Engine. Esto refuerza la viabilidad técnica de implementar el modelo como sistema de estimación temprana.

5.7. Aplicación a la campaña 2025/26

Como validación final, se aplicó el modelo a la campaña 2025/26, que no formó parte del conjunto de entrenamiento ni del esquema de validación walk-forward. Para ello, se descargaron los datos climáticos y satelitales correspondientes al ciclo octubre 2025 – marzo 2026 y se construyeron las features siguiendo el mismo procedimiento utilizado para las campañas históricas.

Dado que al momento de ejecutar la predicción la campaña ya se encontraba finalizada, se dispuso de datos completos hasta marzo. Esto permitió generar la estimación para cada una de las cinco ventanas y reconstruir qué habría indicado el modelo en cada momento de la campaña.

El modelo, entrenado con las 25 campañas anteriores (2000-2024), generó las siguientes predicciones:

Predicción 2025/26 por partido (ventana oct_mar) vs promedio de 25 campañas

Partido	Predicción (qq/ha)	Prom. 25 camp. (qq/ha)	Diferencia
General Arenales	35,9	33,8	+6,1%
Leandro N. Alem	35,0	30,9	+13,2%
Junín	34,2	32,4	+5,6%
Lincoln	32,4	29,0	+11,7%
General Pinto	32,5	29,4	+10,5%
Promedio zona	**34,0**	**31,1**	**+9,3%**

Tabla 3. Predicción de rendimiento de soja para la campaña 2025/26 por partido (ventana oct_mar), comparada con el promedio de las 25 campañas. Fuente: elaboración propia.

La Figura 8 muestra la estimación zonal para cada ventana junto con su intervalo de predicción del 80%.

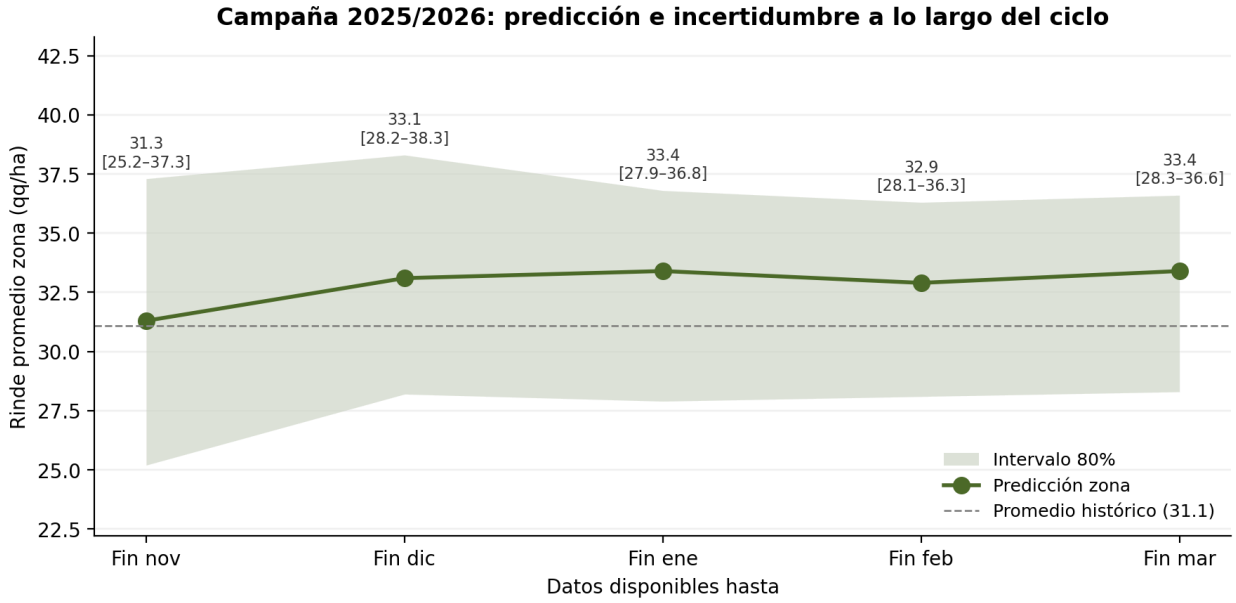


Figura 8. Estimación del rendimiento promedio zonal para la campaña 2025/26 según la información disponible en cada momento, con su intervalo de predicción del 80%. La línea punteada indica el promedio histórico (31,1 qq/ha). Fuente: elaboración propia.

El modelo estimó una campaña por encima del promedio en los cinco partidos, con un rendimiento promedio zonal de 34,0 qq/ha. Como referencia adicional se incluyó el

promedio de las últimas diez campañas (30,7 qq/ha), menos afectado por los rendimientos más bajos de principios de la serie. La predicción se ubica por encima de ambas referencias: un 9,3% sobre el promedio de largo plazo y un 10,7% sobre el de la última década.

La señal de campaña favorable aparece a partir de diciembre y se mantiene estable en los cortes siguientes, entre +7% y +9% sobre lo normal. La estimación de noviembre (31,8 qq/ha) era prácticamente neutral: con la información disponible a esa altura, la campaña no se distinguía de un año normal.

Corresponde leer este resultado con la cautela adecuada. En todas las ventanas, el límite inferior del intervalo del 80% queda por debajo del promedio histórico (por ejemplo, 29,8 qq/ha con datos hasta enero). Esto significa que, con el nivel de confianza adoptado, no puede descartarse una campaña normal. La predicción debe interpretarse como una señal de dirección, campaña probablemente por encima de lo normal, y no como un valor puntual.

Al momento de elaboración de este documento, el MAGyP no había publicado el rendimiento oficial por partido para la campaña 2025/26. El informe de cierre de la Bolsa de Cereales de Buenos Aires ubicó a la región Norte de La Pampa-Oeste de Buenos Aires entre las de mejor desempeño del país, con rendimientos récord para la serie, tanto en soja de primera como de segunda. Esto es coherente con la dirección estimada por el modelo, y sugiere a la vez que la magnitud real podría ser superior a la estimada, algo esperable dada la tendencia de Random Forest a subestimar campañas excepcionales (sección 6.3).

Las referencias regionales disponibles no son directamente comparables con la variable que estima el modelo, por dos razones: abarcan regiones más amplias que los cinco partidos, o informan por separado la soja de primera, mientras que el rendimiento del MAGyP por partido combina soja de primera y de segunda. La validación cuantitativa quedará pendiente hasta la publicación de los datos oficiales por partido.

5.8. Simulación: predicción con datos de enero

La predicción presentada en la sección 5.7 fue generada con la ventana oct_mar, dado que la campaña ya había finalizado al momento de ejecutarla. Sin embargo, el valor operativo del modelo depende de lo que puede estimar antes de la cosecha. Surge

entonces la pregunta: ¿qué habría predicho el modelo si se lo hubiera ejecutado en enero, con tres meses de anticipación real?

Para responder esto se realizó una simulación retrospectiva. Se tomaron los mismos datos climáticos y satelitales de la campaña 2025/26 pero truncados a dos fechas: el 15 de enero y el 31 de enero de 2026. En cada caso se construyeron las variables predictoras utilizando únicamente la información disponible hasta esa fecha y se generaron las predicciones con el modelo entrenado exclusivamente con la ventana oct_ene. La Tabla 4 muestra los resultados.

Partido	15 de enero (qq/ha)	31 de enero (qq/ha)	Oct-Mar completa (qq/ha)	Prom. histórico (qq/ha)
General Arenales	34.1	34.4	35.9	33.8
Leandro N. Alem	33.9	34.0	35.0	30.9
Junín	34.1	34.5	34.2	32.4
Lincoln	31.1	32.5	32.4	29.0
General Pinto	32.5	34.1	32.5	29.4
Promedio zona	**33.1**	**33.9**	**34.0**	**31.1**

Tabla 4. Predicción de rendimiento por partido para la campaña 2025/26 según tres escenarios: con datos disponibles al 15 de enero, al 31 de enero, y con datos completos hasta marzo. Fuente: elaboración propia.

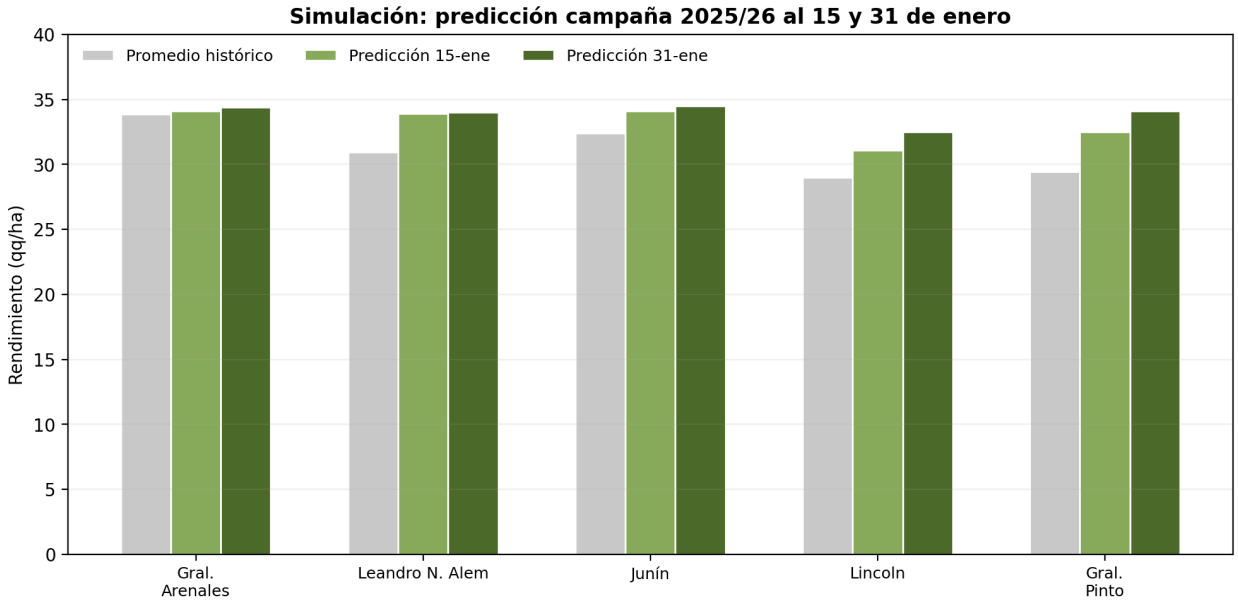


Figura 9. Comparación de predicciones de rendimiento por partido según el momento de ejecución del modelo. Fuente: elaboración propia.

Las tres estimaciones coinciden en la dirección: campaña por encima del promedio histórico a nivel zonal. Al 15 de enero, la estimación zonal era de 33,1 qq/ha (2,0 qq/ha sobre el promedio), con General Arenales prácticamente en su promedio histórico. Al 31 de enero, la estimación subió a 33,9 qq/ha, a 0,1 qq/ha del valor obtenido con los datos completos de la campaña (34,0 qq/ha).

La suba entre ambas fechas es coherente con lo ocurrido en la zona: tras un mes de enero con déficit hídrico en gran parte de la región pampeana, las lluvias de fines de enero se concentraron en el oeste bonaerense y sostuvieron el potencial del cultivo. El modelo incorporó esa mejora en su estimación del 31 de enero, y en todos los partidos esta fue igual o superior a la del 15 de enero.

Desde el punto de vista operativo, un modelo ejecutado a fines de enero de 2026 habría emitido prácticamente la misma señal que el obtenido con toda la información de la campaña: prepararse para una campaña por encima de lo normal. Cabe aclarar que se trata de una sola campaña, por lo que este resultado ilustra el funcionamiento del modelo, pero no constituye por sí mismo una validación estadística.

5.9. Evaluación de variables y estructuras alternativas

Partiendo del modelo de la versión anterior, con 13 variables por ventana, se evaluó si variables agroclimáticas adicionales, otras estructuras de variables u otros algoritmos permitían mejorar la estimación. Todas las comparaciones siguen el criterio descrito en la sección 4.5.

Variables agroclimáticas adicionales. Se definieron siete grupos de variables con fundamento agronómico, calculables a partir de los datos ya disponibles, y cada uno se sumó por separado al modelo para aislar su aporte. La Tabla 5 resume los resultados para la ventana oct_ene.

Experimentos con nuevas variables — cambio en MAE respecto del modelo base (oct_ene)

Grupo de variables	Fundamento agronómico	ΔMAE (oct_ene)	Campañas que mejoran	Resultado
VPD	Demanda evaporativa; cierre estomático	−0,13	7/9	**Mejora concluyente**
Anomalía de NDVI	Vigor respecto de lo normal	−0,04	6/9	Mejora fuerte en nov. y dic. (ver Tabla 6)
Balance hídrico (lluvia − ET_0)	Oferta neta de agua	−0,04	8/9	Mejora mínima, sin impacto práctico
Lluvia pre-siembra (jul–sep)	Recarga del perfil del suelo	−0,01	5/9	Sin efecto
Condiciones del último mes	Inicio del período crítico	−0,01	4/9	Sin efecto
Distribución de lluvias (racha seca, variab.)	Baches hídricos	+0,08	1/9	Empeora
Tendencia tecnológica (sin tendencia lineal)	Mejora genética y de manejo	+1,46	2/9	Empeora mucho

Tabla 5. Aporte de cada grupo de variables sumado por separado al modelo de la versión anterior (ventana oct_ene, promedio de cinco semillas). Valores negativos indican menor error. Fuente: elaboración propia.

Los grados-día de crecimiento (GDD), habituales en modelos de cultivo, no se incluyeron: con ventanas de calendario fijas y temperaturas medias que entre octubre y marzo casi nunca bajan de la temperatura base, el GDD equivale a una transformación lineal de la temperatura media, que el modelo ya utiliza.

La tendencia tecnológica empeoró marcadamente las estimaciones. La tendencia lineal ajustada sobre los años de entrenamiento proyectaba subas de rendimiento que en la zona no se materializaron en el período de test. Que una variable con fundamento agronómico no mejore el modelo no implica que el factor no influya en el rendimiento: puede ocurrir que el modelo ya capture esa información a través de otras variables, o que el volumen de datos no alcance para aprovecharla.

VPD y anomalía de NDVI en todas las ventanas. Las dos variables con mejor resultado se evaluaron, solas y combinadas, en los cinco cortes (Tabla 6 y Figura 10).

Cambio en MAE (qq/ha) al incorporar VPD y anomalía de NDVI, por ventana temporal

Datos hasta	ΔMAE VPD	ΔMAE Anomalía NDVI	ΔMAE VPD + anomalía	IC 80% (VPD + anom.)	Campañas que mejoran
Fin de noviembre	−0,18	−0,89	**−1,02**	[−1,78; −0,32]	6/9
Fin de diciembre	−0,13	−0,66	**−0,73**	[−1,34; −0,10]	6/9
Fin de enero	−0,13	−0,04	−0,16	[−0,39; +0,07]	5/9
Fin de febrero	−0,10	−0,15	−0,22	[−0,52; +0,05]	5/9
Fin de marzo	0,00	−0,04	−0,10	[−0,36; +0,13]	3/9

Tabla 6. Cambio en el MAE (qq/ha) respecto del modelo de la versión anterior al

incorporar VPD, anomalía de NDVI o ambas. Promedio de cinco semillas; intervalo de confianza por bootstrap de campañas. Fuente: elaboración propia.

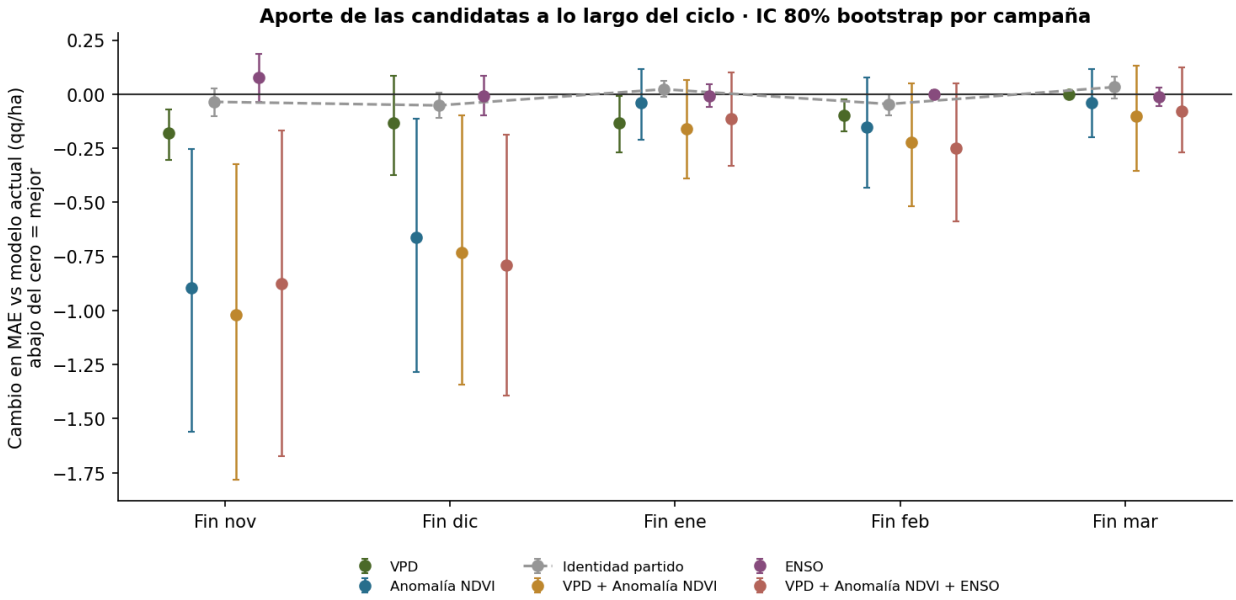


Figura 10. Cambio en el error respecto del modelo anterior para cada variante evaluada y cada momento de la campaña, con intervalos de confianza del 80% por bootstrap de campañas. Valores por debajo de cero indican mejora. Fuente: elaboración propia.

La combinación de ambas variables mostró una mejora concluyente en las ventanas de noviembre y diciembre, que son justamente las de mayor valor para anticipar. A partir de enero, cuando el modelo ya dispone de información del período crítico, la mejora se vuelve marginal y no concluyente.

Se realizó además un control para descartar una explicación alternativa. La anomalía de NDVI resta a cada partido su valor normal, por lo que su aporte podría deberse solo a que el modelo "reconoce" qué partido es, y no a que capta el estado de la campaña. Para evaluarlo, se agregó al modelo directamente la identidad de cada partido. La mejora fue casi nula (−0,04 qq/ha en noviembre), lo que confirma que la anomalía aporta información sobre la campaña en curso.

Corresponde señalar una salvedad: buena parte de la mejora en noviembre se concentra en dos campañas atípicas, 2022/23 y 2024/25, en las que el modelo anterior cometía errores grandes. Que la mejora aparezca justamente en las campañas anómalas es coherente con el propósito del modelo, pero también implica que se apoya en pocos casos. En función de estos resultados, ambas variables se incorporaron al modelo, que

constituye la versión actual.

El Niño / La Niña. Se evaluó si el índice ONI del trimestre agosto-octubre, disponible al inicio de la campaña, aportaba información anticipada. El rendimiento medio de la zona muestra el patrón esperado según la fase de ENSO en la siembra (Tabla 7), aunque la asociación es moderada: correlación de +0,34 entre el ONI y el rendimiento zonal.

Rendimiento medio de la zona según fase ENSO en la siembra (2000–2024)

Fase ENSO en la siembra	Rendimiento medio de la zona	Campañas
La Niña	28,8 qq/ha	6
Neutral	30,7 qq/ha	12
El Niño	33,9 qq/ha	7

Tabla 7. Rendimiento medio zonal según la fase de ENSO en el trimestre agosto-octubre (ONI, NOAA). Fuente: elaboración propia.

Sin embargo, sumar el ONI al modelo no mejoró las estimaciones en ningún corte, y combinado con VPD y anomalía de NDVI empeoró levemente la de noviembre. La explicación más probable es que las variables climáticas y el NDVI ya reflejan el efecto de El Niño o La Niña a medida que se manifiesta, y que con seis y siete campañas de cada fase la señal es demasiado débil para que el modelo la aproveche. Por eso no se incorporó al modelo, pero sí resulta útil como contexto para interpretar una campaña. Para la campaña 2026/27, el ONI de julio-septiembre de 2026 alcanzó +2,16, valor que corresponde a un evento de El Niño fuerte.

Estructura de variables y algoritmo. Finalmente, con las variables de la versión actual, se evaluaron dos decisiones de diseño:

- **La estructura de variables.** Cada ventana incluye las variables de las ventanas anteriores. A fines de enero, por ejemplo, el modelo usa las variables de octubre-noviembre, octubre-diciembre y octubre-enero. Se probó usar solo las 16 variables de cada corte.
- **El algoritmo.** Se comparó Gradient Boosting con Random Forest.

Antes de observar los resultados se fijó la regla de cambio descrita en la sección 4.5. La Figura 11 resume los resultados.

MAE (qq/ha) según estructura de variables y algoritmo — validación walk-forward

Opción	MAE nov	MAE dic	MAE ene	MAE feb	MAE mar	Resultado
RF, acumuladas (actual)	**2,52**	**2,62**	**2,94**	**2,92**	**2,88**	**Referencia**
RF, solo variables del corte	2,52	3,24	3,25	2,76	2,77	Empeora en dic. y ene.
GB, acumuladas	**2,37**	**2,55**	**2,68**	**2,32**	**2,73**	Mejora en 5 cortes; concluyente solo en feb.
GB, solo variables del corte	**2,37**	3,54	3,20	3,20	3,18	Empeora

Tabla 8. MAE (qq/ha) en la validación walk-forward según la estructura de variables y el algoritmo. Random Forest: promedio de cinco semillas. En noviembre, ambas estructuras coinciden porque es la primera ventana. Fuente: elaboración propia.

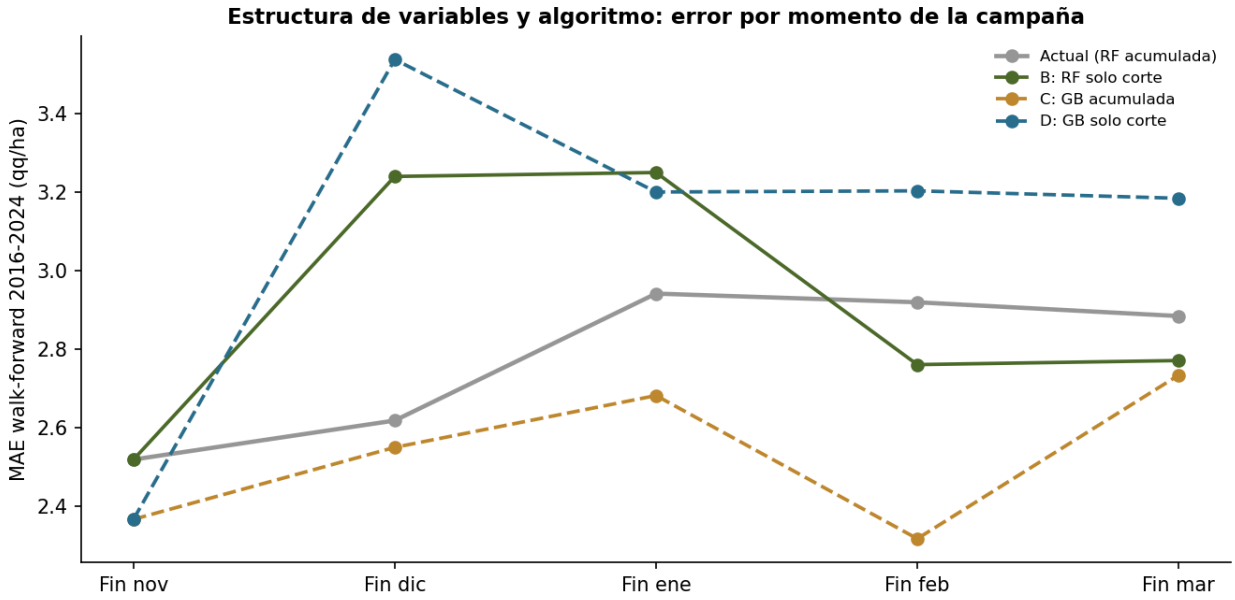


Figura 11. Error por momento de la campaña según la estructura de variables (acumuladas o solo del corte) y el algoritmo (Random Forest o Gradient Boosting). Fuente: elaboración propia.

Usar solo las variables de cada corte empeoró los resultados con ambos algoritmos. Las variables de los cortes anteriores no son redundantes: permiten al modelo distinguir la trayectoria de la campaña, por ejemplo una campaña que arrancó bien y luego se deterioró, información que se pierde al resumir todo el período en un único promedio.

Gradient Boosting con variables acumuladas obtuvo menor error que Random Forest en los cinco cortes, nunca resultó peor, y la mejora se mantuvo al excluir 2022/23. Sin embargo, fue concluyente en un solo corte (febrero: −0,60 qq/ha; intervalo de confianza

del 80% entre −0,92 y −0,29). En los otros cuatro, el intervalo incluyó el cero. Al no cumplir la regla fijada de antemano, se mantuvo Random Forest como modelo principal. Gradient Boosting queda documentado como alternativa candidata: la campaña 2025/26, que ninguno de los dos modelos utilizó en su desarrollo, permitirá compararlos en condiciones independientes cuando se publiquen los datos oficiales.

5.10. Otras alternativas evaluadas

Las pruebas de esta sección se realizaron con la versión anterior del modelo (13 variables por ventana, sin VPD ni anomalía de NDVI). Se presentan como antecedente, ya que sus conclusiones sobre el límite impuesto por el volumen de datos siguen siendo válidas.

Para determinar si el desempeño del modelo podía mejorarse, se exploraron dos líneas complementarias: el uso de otros algoritmos y la mejora de la señal satelital.

Otros algoritmos. Bajo el mismo esquema walk-forward y la ventana oct_ene, se evaluaron modelos lineales regularizados (Ridge, Lasso y ElasticNet), XGBoost, máquinas de vectores de soporte (SVR) y vecinos más cercanos (KNN). Ninguno superó a Random Forest. También se evaluó reducir el modelo a las ocho variables más importantes: en una primera prueba el error bajó a 2,90 qq/ha, pero esa mejora resultó aparente, ya que la selección se había hecho con información de todo el período. Al repetir la selección dentro de cada iteración del walk-forward, el error fue de 3,21 qq/ha, equivalente al del modelo con las 39 variables de esa versión. El modelo Lasso aportó además un resultado coherente con la lectura agronómica: de las 39 variables retuvo solo tres (días de calor extremo en octubre-noviembre, NDVI máximo y NDVI medio hasta enero), en línea con las correlaciones de la sección 5.1. La conclusión de esa etapa fue que, con el volumen de datos disponible, el límite de desempeño estaba dado por la información más que por el algoritmo. La incorporación posterior de VPD y anomalía de NDVI, que mejoró las estimaciones tempranas sin cambiar de algoritmo (sección 5.9), es consistente con esa conclusión: la mejora provino de una mejor representación de la información disponible.

Señal satelital filtrada por cultivo. Como se señaló en la sección 2.2, el NDVI utilizado promedia todos los píxeles del partido. Para evaluar si aislar la señal del cultivo mejoraba el modelo, se utilizaron dos fuentes de clasificación del uso del suelo. Con Dynamic World (Google) se estimó la fracción agrícola de cada partido (verano 2023/24), que va del 86 % en General Arenales al 57 % en Lincoln. Con el Mapa Nacional de

Cultivos del INTA, disponible para las campañas de verano 2019/20 a 2023/24, se construyó una máscara de soja a la resolución de MODIS, conservando los píxeles con al menos un 50 % de superficie de soja. El mapa no distingue soja de primera y de segunda. La campaña 2018/19 se excluyó porque su mapa utiliza un esquema de clases distinto, que combina cultivos de invierno y de verano. La fracción de soja resultó estable entre campañas y coherente con el gradiente de la zona: entre 55 % y 61 % en General Arenales y entre 20 % y 27 % en Lincoln.

El NDVI filtrado muestra curvas más coherentes entre partidos: valores más bajos al inicio de la campaña, cuando el lote de soja todavía es suelo desnudo, y más altos en el pico de enero-febrero, sin la dilución de pasturas y otras coberturas. Sin embargo, al utilizarlo como input del modelo entrenado con NDVI sin filtrar, el error medio absoluto aumentó de 3,08 a 3,80 qq/ha en las cinco campañas con máscara disponible. Esto es esperable: el modelo aprendió con una señal que incluye toda la cobertura del partido, y al recibir una señal diferente interpreta los valores como condiciones anómalas. Para aprovechar la máscara de cultivo sería necesario reentrenar el modelo íntegramente con NDVI filtrado, lo cual requiere una serie más larga que las cinco campañas hoy disponibles.

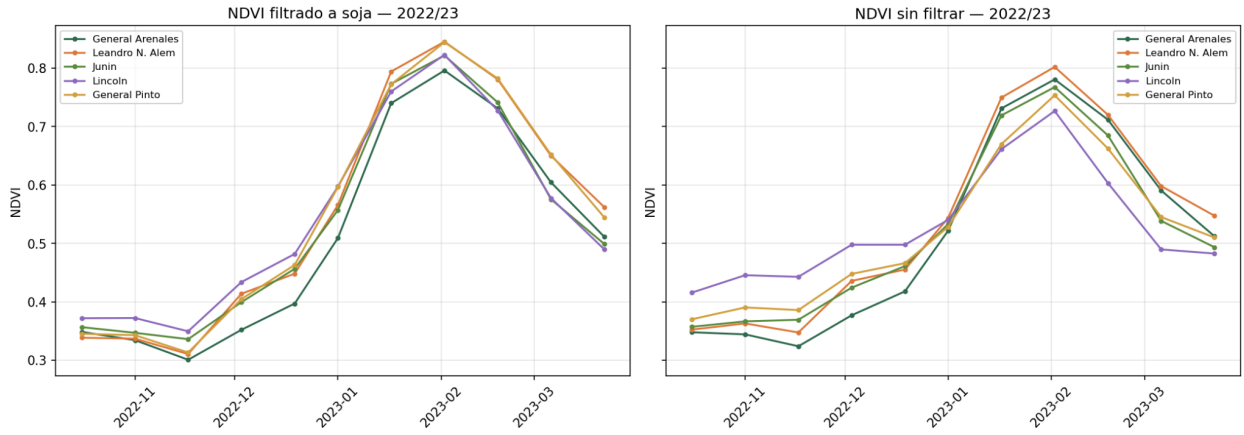


Figura 12. NDVI de la campaña 2022/23 por partido, filtrado a píxeles de soja según el Mapa Nacional de Cultivos del INTA (izquierda) y sin filtrar (derecha). Fuente: elaboración propia a partir de datos MODIS e INTA.

6. Discusión

6.1. Hallazgos principales

El proyecto permitió construir un sistema de estimación de rendimiento de soja a nivel de partido utilizando exclusivamente datos públicos y gratuitos. Los hallazgos más relevantes se organizan en cinco ejes.

El primero es la anticipación, y es el que más cambia respecto de la versión anterior. Con la versión actual, el modelo alcanza su menor error con datos hasta fines de noviembre (2,42 qq/ha, 40% menos que el promedio histórico), cinco meses antes de la cosecha. La versión anterior ubicaba la primera estimación útil a fines de enero; ahora se adelanta dos meses. Las ventanas siguientes no reducen el error de forma sistemática, pero actualizan la estimación con lo ocurrido durante el período crítico. Esa actualización fue decisiva en campañas como 2017/18, cuya sequía tardía solo fue detectable a partir de febrero. El resultado no indica que noviembre sea estrictamente superior a enero, ya que con nueve campañas de test esa diferencia no es distinguible, sino que una estimación temprana ya es tan precisa como una tardía.

El segundo se refiere a las variables con mayor poder predictivo. La anomalía de NDVI hasta enero ($r = +0{,}64$) y los días de calor extremo en octubre-noviembre ($r = -0{,}62$) son las variables más asociadas al rendimiento, seguidas por el NDVI medio, los días de calor extremo de las ventanas siguientes y el VPD ($r = -0{,}52$). En el modelo, la humedad relativa y el VPD concentran más de un tercio de la importancia, como indicadores de la demanda evaporativa estival. La incorporación del VPD y de la anomalía de NDVI mostró que la forma en que se representa la información importa tanto como la información misma. Ambas variables se construyeron con datos que el proyecto ya utilizaba, y sin embargo mejoraron de forma concluyente las estimaciones tempranas, porque expresan directamente conceptos agronómicos (demanda evaporativa, vigor respecto de lo normal) que el modelo no lograba reconstruir con 125 observaciones.

El tercero es el comportamiento del modelo frente a campañas de distinto tipo. La estimación resultó acertada en campañas de rendimiento extremadamente bajo, como 2022/23, donde el modelo anticipó desde noviembre una caída pronunciada, aunque subestimando su magnitud. De las seis campañas de test que se apartaron más de un 5% de lo normal, el modelo anticipó el sentido del desvío en cinco con datos hasta enero. La excepción, 2017/18, corresponde a una sequía posterior a la fecha de corte. El modelo tiende, en cambio, a subestimar la magnitud de los desvíos, y su utilidad es mayor para detectar campañas claramente anómalas que para discriminar desvíos menores.

El cuarto es la cuantificación de la incertidumbre. Los intervalos de predicción del 80%, construidos con los errores reales del modelo, alcanzaron una cobertura verificada

de entre el 77% y el 87% según la ventana, en línea con el nivel nominal. A nivel partido, los intervalos son asimétricos: el margen hacia abajo supera al margen hacia arriba en todas las ventanas, reflejando que las sequías castigan más de lo que un buen año suma. Esto permite acompañar cada estimación con un rango honesto, que en la práctica es tan importante como el valor central.

El quinto refiere a las alternativas exploradas. Ni otros algoritmos ni la selección o reestructuración de variables superaron de forma concluyente al modelo. Gradient Boosting mostró un error menor en todos los cortes, pero no alcanzó el criterio de cambio fijado de antemano y queda como alternativa a confirmar con campañas nuevas.

6.2. Valor para la toma de decisiones en una cooperativa

El valor práctico de un modelo de predicción de rendimiento no reside en la precisión del número en sí, sino en la capacidad de anticipar la dirección del resultado con suficiente tiempo como para actuar. En este sentido, disponer de una primera estimación a fines de noviembre, que se actualiza mes a mes hasta la cosecha, habilita varias decisiones operativas concretas para una cooperativa agrícola.

En primer lugar, la planificación logística de acopio. Si el modelo indica que la campaña viene por debajo del promedio, la cooperativa puede anticipar que recibirá menos toneladas en sus plantas de acopio, ajustando turnos de recepción, capacidad de secado y necesidades de transporte. Si la campaña viene bien, puede prepararse para un mayor volumen y evitar cuellos de botella en la recepción.

En segundo lugar, la gestión de la posición comercial. Es importante precisar el alcance de este punto: el precio de la soja en el mercado local se forma a partir del FAS teórico, que depende de la cotización internacional, el precio FOB, los derechos de exportación y el tipo de cambio. Una campaña corta circunscripta a cinco partidos no tiene capacidad de influir sobre ese precio. Lo que sí puede verse afectado es la base local, es decir, el diferencial entre el precio de la zona y el de referencia, por efecto de la competencia entre acopios y de las condiciones logísticas cuando la oferta regional es escasa.

El valor más concreto en este plano es el de la gestión del riesgo de la posición tomada. Si la cooperativa ha comprometido volumen a entregar mediante ventas forward y el modelo anticipa entre noviembre y enero una campaña por debajo del promedio, dispone de tiempo para evaluar la cobertura de ese compromiso antes de que el faltante

se materialice en cosecha, momento en el cual las alternativas son más costosas.

En tercer lugar, la gestión del riesgo crediticio. Las cooperativas frecuentemente financian insumos (semillas, agroquímicos, fertilizantes) a los productores a cuenta corriente, contra la entrega del grano en cosecha. Una estimación temprana del rendimiento permite dimensionar la exposición crediticia por zona y anticipar potenciales dificultades de cobranza en partidos donde la campaña viene desfavorable.

Es importante señalar que el modelo no pretende reemplazar la experiencia de los técnicos de campo ni las estimaciones que realizan los profesionales del sector. Su valor reside en complementar esas fuentes con una herramienta cuantitativa, objetiva y reproducible, que sistematiza información que hoy se interpreta de manera informal.

Los intervalos de predicción agregan una dimensión de uso concreta. Una cooperativa que planifica capacidad de recepción o compromisos de entrega puede trabajar con el límite inferior del intervalo como escenario prudente, y con el límite superior para dimensionar la capacidad máxima de secado y almacenamiento. El ancho del intervalo le indica, además, cuánto margen de error debe contemplar en cada momento de la campaña.

Criterio de uso a lo largo de la campaña. El hecho de que la estimación de noviembre sea ya tan precisa como las posteriores no implica que deba usarse como valor definitivo. Cada momento de la campaña cumple un rol distinto:

- **Fin de noviembre - primera señal.** Indica si la campaña arranca por encima o por debajo de lo normal. No incluye la soja de segunda, que todavía no se sembró, ni el clima del período crítico. Sirve para empezar a planificar escenarios.
- **Fin de diciembre - confirmación.** Si la dirección se mantiene respecto de noviembre, la señal gana solidez. Si se invierte, conviene esperar al corte siguiente antes de comprometer decisiones.
- **Fin de enero - inicio del período crítico.** Incorpora el estado del cultivo al entrar en floración y formación de vainas. Es un buen momento para decisiones comerciales y crediticias.
- **Fin de febrero y marzo - ajuste final.** Capta eventos tardíos, como la sequía de 2017/18. Útil para la logística de recepción y secado.

En todos los casos, la estimación se interpreta junto con su intervalo de predicción, y una señal que se sostiene a lo largo de varios cortes consecutivos merece más confianza que

una estimación aislada.

El estado de El Niño / La Niña, conocido antes de la siembra, funciona como un contexto complementario. Por ejemplo, para la campaña 2026/27 el índice ONI indica un evento de El Niño fuerte, una fase asociada en la serie analizada a rendimientos superiores al promedio. No reemplaza la estimación del modelo, pero ayuda a leerla.

6.3. Limitaciones del modelo

Los resultados presentados deben interpretarse a la luz de las siguientes limitaciones.

Escala de análisis. El modelo opera a nivel de partido y estima un rendimiento promedio para toda la superficie sembrada. Un productor individual puede obtener un resultado considerablemente distinto de ese promedio, en función del tipo de suelo de su lote, la fecha de siembra, el cultivar utilizado y el manejo agronómico aplicado. El sistema no es apto para estimaciones a nivel de lote.

Naturaleza de la señal de NDVI. Como se señaló en la sección 2.2, el NDVI utilizado corresponde al promedio de todos los píxeles del polígono de cada partido, sin discriminar el tipo de cobertura. La serie incluye maíz, trigo, pasturas, montes, áreas urbanas y cuerpos de agua, por lo que constituye un indicador del estado general de la vegetación y no una medición del cultivo de soja. Esto introduce ruido y atenúa la señal, de manera diferente en cada partido según su composición de usos del suelo. Tampoco se aplicó un filtro basado en la banda de confiabilidad del producto MOD13Q1, por lo que algunas observaciones podrían estar afectadas por cobertura nubosa residual. Esta limitación fue abordada de forma exploratoria mediante máscaras de uso del suelo (sección 5.10). La señal filtrada resultó más representativa de la fenología del cultivo, pero no mejoró las predicciones del modelo actual, entrenado con la señal sin filtrar.

La anomalía de NDVI incorporada en la versión actual mitiga en parte este problema, ya que al comparar cada partido con su propio valor normal neutraliza las diferencias estructurales de composición del suelo. No resuelve, sin embargo, la mezcla de coberturas dentro de cada campaña.

Incapacidad de extrapolación del modelo. Random Forest genera predicciones promediando los valores observados en las hojas de sus árboles, por lo que no puede predecir valores fuera del rango presente en los datos de entrenamiento. Esto produce una compresión sistemática de las predicciones: el modelo tiende a subestimar las

campañas excepcionalmente buenas y a sobreestimar las excepcionalmente malas. Este comportamiento es visible en la Figura 6 (por ejemplo, en 2016/17 y 2022/23). Gradient Boosting, también basado en árboles, comparte esta limitación. Se evaluó incorporar la tendencia de largo plazo de los rendimientos, asociada a la mejora genética y de manejo, mediante la remoción de una tendencia lineal, pero empeoró marcadamente las estimaciones (sección 5.9).

Tamaño del dataset. Con 125 observaciones, no es viable explorar arquitecturas de mayor complejidad sin incurrir en sobreajuste severo. La evaluación descansa además en solo nueve campañas de test, por lo que diferencias pequeñas entre variantes no son concluyentes. Al haberse evaluado varias alternativas sobre las mismas campañas, existe además el riesgo de que alguna parezca mejor por azar. Los criterios de la sección 4.5 reducen ese riesgo pero no lo eliminan: las mejoras reportadas deben confirmarse con campañas nuevas.

Resolución de los datos climáticos. Tal como se detalló en la sección 4.1, la grilla de NASA POWER es considerablemente más gruesa que la distancia entre los partidos analizados, lo que limita la capacidad del modelo para discriminar condiciones climáticas locales entre ellos.

Ausencia de variables de manejo. La densidad de siembra, la fertilización, el cultivar utilizado, el control de malezas y plagas y la fecha efectiva de siembra son factores relevantes para el rendimiento que no están disponibles en fuentes públicas a la escala requerida. Su ausencia impone un techo a la precisión alcanzable por el modelo.

Agregación de soja de primera y de segunda. El rendimiento publicado por el MAGyP corresponde al total de soja del partido sin distinguir entre ambas. Dado que la soja de segunda se siembra aproximadamente dos meses después y transita su período crítico más tarde, las ventanas temporales del modelo, alineadas al ciclo de la soja de primera, resultan menos adecuadas para esa fracción de la superficie. El efecto es mayor en los partidos donde el doble cultivo tiene más peso. Esta limitación es especialmente relevante para la estimación de fines de noviembre: a esa altura la soja de segunda todavía no se sembró, por lo que la estimación descansa en la relación histórica entre las condiciones de inicio de campaña y el rendimiento total. En una campaña con una proporción de soja de segunda atípica, por ejemplo tras un trigo afectado por sequía, esa relación podría no sostenerse.

Eventos de alto impacto localizado. Granizo, tormentas severas, anegamientos y heladas tempranas pueden afectar severamente el rendimiento de áreas específicas sin

quedar reflejados de manera proporcional en las variables climáticas promediadas a nivel de partido.

Clima posterior a la estimación. Una estimación realizada en noviembre o en enero solo dispone de la información ocurrida hasta ese momento. Las lluvias o eventos de estrés que se produzcan durante febrero y marzo, en pleno llenado de grano, pueden modificar sustancialmente el resultado final. La campaña 2025/26 ilustra este punto: el déficit hídrico de enero fue revertido por lluvias posteriores. El modelo ofrece una estimación condicionada a lo observado, no un pronóstico del clima futuro. Como cada estimación se evalúa contra el rendimiento final, el error histórico de las ventanas tempranas ya incluye este efecto, y los intervalos de predicción lo reflejan.

Solidez del resultado de noviembre. La ventaja de la estimación de noviembre se apoya en buena medida en dos campañas atípicas, 2022/23 y 2024/25. El resultado es coherente con la lectura agronómica, pero deberá confirmarse con campañas nuevas antes de considerarlo un patrón estable.

Supuesto de los intervalos de predicción. Los intervalos se construyen bajo el supuesto de que los errores futuros se comportarán como los observados entre 2016/17 y 2024/25. Una campaña con condiciones sin precedentes en la serie podría quedar fuera del intervalo con mayor frecuencia que la indicada por el nivel nominal del 80%.

6.4. Trabajo futuro

Las alternativas exploradas indican que el margen de mejora del modelo depende principalmente de la información disponible y de cómo se representa. Las líneas de desarrollo que siguen están condicionadas a la aparición de datos que hoy no existen o no tienen la extensión suficiente.

Más campañas. Cada nueva campaña publicada por el MAGyP suma cinco observaciones al entrenamiento. La primera será la 2025/26, que permitirá verificar cuantitativamente la predicción de la sección 5.7 y comparar Random Forest con Gradient Boosting en una campaña que no intervino en ninguna decisión de diseño. Luego seguirá la aplicación del modelo a la campaña 2026/27 en condiciones enteramente prospectivas. Una serie más larga, en particular con más eventos extremos, permitirá al modelo capturar una mayor diversidad de escenarios y aprovechar señales como la de El Niño / La Niña, hoy demasiado débiles con 25 campañas.

Más partidos. Ampliar el análisis a otros partidos de características agroclimáticas similares (zona núcleo) aumentaría las observaciones disponibles. Para no introducir ruido, la alternativa más sólida es replicar el mismo procedimiento sobre otro grupo de partidos homogéneo y comparar los resultados, en lugar de mezclar en un único modelo zonas con suelos y regímenes de lluvias distintos.

Serie más larga de mapas de cultivos. La señal de NDVI filtrada a soja resultó más representativa del cultivo, pero el Mapa Nacional de Cultivos cubre hoy solo cinco campañas, insuficientes para reentrenar el modelo con esa señal. Si la serie se amplía, será posible entrenar el modelo íntegramente con NDVI de soja y evaluar su aporte de forma consistente.

Rendimientos a escala más fina. Pasar del partido al lote o a zonas homogéneas permitiría usar imágenes de mayor resolución (Sentinel-2, 10 m) y multiplicaría las observaciones disponibles. Esto requiere datos de rendimiento georreferenciados, como mapas de monitor de cosecha, que no son de acceso público.

7. Conclusiones

Este trabajo se propuso responder si es posible estimar el rendimiento de soja a nivel de partido antes de la cosecha utilizando únicamente fuentes de datos públicas y gratuitas, y a partir de qué momento del ciclo esa estimación alcanza un nivel de error razonable.

La respuesta a la primera pregunta es afirmativa, con las salvedades detalladas en la sección 6.3. Un modelo Random Forest alimentado con NDVI del sensor MODIS, variables climáticas de NASA POWER y dos indicadores derivados con fundamento agronómico (el déficit de presión de vapor y la anomalía de NDVI) alcanzó, con datos hasta fines de noviembre, un error medio absoluto de 2,42 qq/ha y un R^2 de 0,72 bajo validación temporal estricta. Con datos hasta fines de enero, anticipó correctamente si cada partido venía por encima o por debajo de su promedio histórico en el 69% de los casos.

La respuesta a la segunda pregunta es que el modelo ya ofrece una estimación útil a fines de noviembre, unos cinco meses antes de la cosecha. Las estimaciones de los meses siguientes no reducen el error de forma sistemática, pero incorporan lo ocurrido durante el período crítico y permiten detectar eventos tardíos, como la sequía de febrero-marzo de 2017/18. El momento útil para producir una primera estimación es, por lo tanto, temprano, y las estimaciones posteriores funcionan como actualizaciones de esa primera

señal.

Este hallazgo cambia la perspectiva del trabajo respecto de su planteo inicial. La pregunta original suponía que la estimación útil llegaría recién en enero; los resultados muestran que puede emitirse una primera señal dos meses antes, con el mismo nivel de precisión. Para una cooperativa, esa diferencia amplía el margen de acción: permite planificar con la campaña recién implantada en lugar de hacerlo con el cultivo ya en período crítico. Corresponde, sin embargo, usarla con criterio: como una primera señal que los cortes siguientes confirman o corrigen (sección 6.2), y no como un valor definitivo.

Cada estimación se acompaña de un intervalo de predicción del 80%, construido con los errores reales del modelo, que en la validación alcanzó una cobertura de entre el 77% y el 87% según la ventana. Este rango no es un agregado accesorio: define cuánto margen debe contemplar quien utilice la estimación para tomar decisiones.

El alcance de esta conclusión debe delimitarse con precisión. El modelo demostró capacidad para anticipar campañas claramente anómalas, pero su desempeño fue menos consistente frente a desvíos moderados. Su utilidad, por lo tanto, se ubica más en el terreno de la señal de alerta “esta campaña viene marcadamente por debajo o por encima de lo habitual” que en el de la estimación precisa de un valor puntual. Para las decisiones operativas descritas en la sección 6.2, esa distinción no invalida la herramienta, pero sí define cómo debería utilizarse.

Las alternativas evaluadas permitieron delimitar dónde está el margen de mejora. Representar mejor la información disponible, mediante variables con significado agronómico directo, mejoró de forma concluyente las estimaciones tempranas. En cambio, otros algoritmos, la selección o reestructuración de variables y la señal satelital filtrada por cultivo no superaron al modelo. Gradient Boosting mostró menor error en todos los cortes, pero sin alcanzar el criterio de cambio definido de antemano, y queda como alternativa a confirmar con campañas nuevas.

La aplicación a la campaña 2025/26 estimó una campaña por encima de lo normal, entre un 7% y un 9% sobre el promedio desde diciembre, lo que resulta coherente con los reportes de cierre de la Bolsa de Cereales, que ubicaron a la región entre las de mejor desempeño del país. La simulación retrospectiva mostró que la estimación de fines de enero (33,9 qq/ha) prácticamente coincidió con la obtenida con datos completos (34,0 qq/ha). La verificación cuantitativa quedará pendiente hasta la publicación de los datos

oficiales por partido.

Este resultado le da un sustento empírico concreto a la conclusión central del trabajo: aplicado a una campaña real, el modelo entrega desde las primeras etapas del ciclo una estimación estable y accionable, acompañada de una medida explícita de su incertidumbre.

El trabajo no pretende competir con los sistemas de estimación que operan instituciones especializadas con mayores recursos, mayor densidad de datos y relevamientos a campo. Su aporte consiste en mostrar que, a partir de fuentes abiertas y con conocimiento del dominio, es posible construir un sistema funcional y reproducible que aborda un problema concreto para actores que actualmente no disponen de herramientas de este tipo. El pipeline desarrollado está preparado para aplicarse a la campaña 2026/27, cuya siembra comienza en octubre de 2026, lo que permitirá una evaluación en condiciones enteramente prospectivas.

8. Referencias

- Ministerio de Agricultura, Ganadería y Pesca de la Nación (MAGyP). Datos abiertos: estimaciones agrícolas por cultivo, provincia y departamento. Disponible en: https://datos.magyp.gob.ar/
- NASA POWER Project. Prediction Of Worldwide Energy Resources — Data Access Viewer. NASA Langley Research Center. Disponible en: https://power.larc.nasa.gov/
- Google Earth Engine. Plataforma de análisis geoespacial en la nube. Google. Disponible en: https://earthengine.google.com/
- MODIS Vegetation Index Products (MOD13Q1). NASA Land Processes Distributed Active Archive Center (LP DAAC). Disponible en: https://lpdaac.usgs.gov/products/mod13q1v061/
- FAO GAUL (Global Administrative Unit Layers). Food and Agriculture Organization of the United Nations. Nivel 2, utilizado para polígonos administrativos de partidos.
- Bolsa de Cereales de Buenos Aires. Panorama Agrícola Semanal (PAS) — informes de campaña. Disponible en: https://www.bolsadecereales.com/
- Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5-32.
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting

machine. Annals of Statistics, 29(5), 1189-1232.

- Fehr, W. R. & Caviness, C. E. (1977). Stages of soybean development. Special Report 80, Iowa State University, Cooperative Extension Service.
- Rouse, J. W., Haas, R. H., Schell, J. A. & Deering, D. W. (1974). Monitoring vegetation systems in the Great Plains with ERTS. Proceedings of the Third Earth Resources Technology Satellite-1 Symposium, NASA SP-351, 309-317.
- Brown, C. F. et al. (2022). Dynamic World, Near real-time global 10 m land use land cover mapping. Scientific Data, 9, 251.
- de Abelleyra, D. et al. (2020). Mapa Nacional de Cultivos campaña 2019/2020. Versión 1. Instituto Nacional de Tecnología Agropecuaria (INTA).
- Allen, R. G., Pereira, L. S., Raes, D. & Smith, M. (1998). Crop evapotranspiration: Guidelines for computing crop water requirements. FAO Irrigation and Drainage Paper 56. Food and Agriculture Organization of the United Nations, Roma.
- Hargreaves, G. H. & Samani, Z. A. (1985). Reference crop evapotranspiration from temperature. Applied Engineering in Agriculture, 1(2), 96-99.
- Lei, J., G'Sell, M., Rinaldo, A., Tibshirani, R. J. & Wasserman, L. (2018). Distribution-free predictive inference for regression. Journal of the American Statistical Association, 113(523), 1094-1111.
- Efron, B. & Tibshirani, R. J. (1993). An Introduction to the Bootstrap. Chapman & Hall, Nueva York.
- NOAA Climate Prediction Center. Oceanic Niño Index (ONI). Disponible en: https://www.cpc.ncep.noaa.gov/data/indices/oni.ascii.txt
- Podestá, G. P., Messina, C. D., Grondona, M. O. & Magrin, G. O. (1999). Associations between grain crop yields in central-eastern Argentina and El Niño–Southern Oscillation. Journal of Applied Meteorology, 38(10), 1488-1498.